

② Modele de identificare

②.② Noțiuni de Statistică și Prelucrare de Semnal

- Determinarea **gradului de corelare** existent între valorile unui set de date este extrem de importantă pentru aprecierea **predictibilității** acestuia.
- Dacă datele sunt **slab corelate între ele**, predicția valorilor viitoare nu se poate face decât în limitele unei **precizii scăzute**.

Cum se poate caracteriza corelarea dintre date?



Caracterizarea filozofică este fundamentată de următorul **principiu axiomatic**.

Principiul cauzalității din sistemul logic uman

👉 **Sistemul logic uman este incomplet!**

Prezentul și trecutul apropiat influențează mai mult viitorul imediat decât o face trecutul îndepărtat.

Viitorul nu poate influența prezentul sau trecutul.

(Gödel, ~1933)

În IS, caracterizarea fenomenului de corelare dintre date se bazează pe:

Covarianță (încrucișată)

$$r_{u,y}[m,n] \stackrel{\text{def}}{=} E\{u[m]y[n]\} =$$

pivoți

$$= \int \int \mathcal{D}(u[m]) \mathcal{D}(y[n]) \boxed{\mu(u[m], y[n])} u[m]y[n] du[m]dy[n]$$

$\forall m, n \in \mathbb{N}^*$

Arată cât de corelată statistic este ieșirea cu intrarea, ambele aparținând aceluiași set de date măsurate.

Tipuri de densități de probabilitate utilizate în IS

Densitatea simplă de probabilitate

Densitatea de probabilitate a aceleiași realizări

Densitatea de probabilitate încrucișată (intrare-ieșire)

Densitatea de probabilitate încrucișată (intrare-ieșire)

Densitatea de probabilitate a aceleiași realizări

👉 Definiție formulată tot cu ajutorul operatorului de mediere statistică.

2 Modele de identificare

2.2 Noțiuni de Statistică și Prelucrare de Semnal



În IS, caracterizarea fenomenului de corelare dintre date se bazează pe:

Auto-covarianță

Arată **cît de corelate statistic sunt ieșirile** aparținînd aceluiași set de date măsurate.

$$r_y[m, n] \stackrel{\text{def}}{=} E\{y[m]y[n]\} = \int_{\mathcal{D}(y[m])} \int_{\mathcal{D}(y[n])} \boxed{\rho(y[m], y[n])} y[m]y[n] dy[m]dy[n] \quad \forall m, n \in \mathbb{N}^*$$

pivoți

Similar

$$r_u[m, n] \stackrel{\text{def}}{=} E\{u[m]u[n]\} \quad (\text{auto-covarianța datelor de intrare}) \quad \forall m, n \in \mathbb{N}^*$$

Nu este prea complicat?



Desigur, dacă se încearcă evaluarea plecînd de la definiții. Simplificarea este posibilă tot datorită unei versiuni a **IE**.

Ipoteza Ergodică (de covarianță)

Secvența de (auto)-covarianță a unui proces nu depinde decît de **diferența pivoților** (adică procesul este **staționar în covarianță**) și este egală cu **(auto)-covarianța temporală** a oricărei realizări cu un număr infinit de date măsurate.

Tipuri de densități de probabilitate utilizate în IS

Densitatea simplă de probabilitate

Densitatea de probabilitate a aceleiași realizări

Densitatea de probabilitate încrucișată (intrare-ieșire)

Densitatea de probabilitate încrucișată (intrare-ieșire)

Densitatea de probabilitate a aceleiași realizări



2 Modele de identificare

2.2 Noțiuni de Statistică și Prelucrare de Semnal



IE

$$\left\{ \begin{aligned} r_{u,y}[m,n] &= r_{u,y}[m-n] = \lim_{N \rightarrow \infty} \frac{1}{v_{N,m,n}} \sum_{i=1+\max\{m,n\}}^{N+\min\{m,n\}} u[i-n]y[i-m] \\ r_y[m,n] &= r_y[m-n] = \lim_{N \rightarrow \infty} \frac{1}{v_{N,m,n}} \sum_{i=1+\max\{m,n\}}^{N+\min\{m,n\}} y[i-n]y[i-m] \end{aligned} \right. \quad \forall m,n \in \mathbb{N}^*$$

pivot

def

$$m - n = k \in \mathbb{Z}$$

Se poate observa cum se calculează diferența pivoților: prin scăderea argumentelor semnalelor implicate.

+0-

$$r_{u,y}[k] = E\{u[n]y[n-k]\} \cong r_{u,y}^N[k] = \frac{1}{v_{N,k}} \sum_{n=1+\max\{0,k\}}^{N+\min\{0,k\}} u[n]y[n-k] \quad \forall k \in \mathbb{Z}$$

$$r_y[k] = E\{y[n]y[n-k]\} \cong r_y^N[k] = \frac{1}{v_{N,k}} \sum_{n=1+\max\{0,k\}}^{N+\min\{0,k\}} y[n]y[n-k] \quad \forall k \in \mathbb{Z}$$

Numitorul factorului ce precede oricare dintre sume este egal cu numărul de termeni ai sumei.

$$v_{N,m,n} \stackrel{\text{def}}{=} N + \min\{m,n\} - \max\{m,n\}$$

$$v_{N,k} \stackrel{\text{def}}{=} N + \min\{0,k\} - \max\{0,k\}$$

Aproximații
similare

Numitorul factorului ce precede sumele este întotdeauna egal cu dimensiunea orizontului de măsură, N .

Convenție: semnalele se prelungesc cu zerouri în afara orizontului de măsură.

(zero padding)

$$\left\{ \begin{aligned} r_{u,y}[k] &\cong \frac{1}{N} \sum_{n=1}^N u[n]y[n-k] \\ r_y[k] &\cong \frac{1}{N} \sum_{n=1}^N y[n]y[n-k] \end{aligned} \right. \quad \forall k \in \mathbb{Z}$$

Cele două tipuri de aproximații sunt sensibil diferite pentru pivoți depărtați de origine.

2 Modele de identificare

2.2 Noțiuni de Statistică și Prelucrare de Semnal



Cît de precise sunt aceste aproximații?



Precizia aproximației **crește** odată cu numărul de date achiziționate, dar **scade** odată cu îndepărtarea pivotului de origine (deoarece numărul de termeni ai sumei devine din ce în ce mai mic).

Două cazuri

$$r_{u,y}^N[k] = \frac{1}{v_{N,k}} \sum_{n=1+\max\{0,k\}}^{N+\min\{0,k\}} u[n] y[n-k]$$

$\forall k \in \mathbb{Z}$

eșantion **întîrziat** cu k pași pentru $k \geq 0$


eșantion **anticipat** cu $-k$ pași pentru $k < 0$

☞ Datele culisează de-a lungul orizontului de măsură.

Exemplu

$k \geq 0$

Pentru a limita erorile, în practică se evaluează un număr de valori cel mult egal cu **un sfert din dimensiunea orizontului de măsură**.



$$k \in 0, \left\lfloor \frac{N}{4} \right\rfloor$$

Exercițiu

$k < 0$

$$\sum_{n=k+1}^N u[n] y[n-k] \neq 0$$

culisare

2 Modele de identificare

2.2 Noțiuni de Statistică și Prelucrare de Semnal

IE

Proprietăți elementare ale secvenței de (auto-)covarianță

Exerciții

→ Simetrie

Covarianță încrucișată

$$r_{u,y}[-k] = r_{y,u}[k] \quad \forall k \in \mathbb{Z}$$

se schimbă cu

Aceste proprietăți se demonstrează cu ajutorul IE, completând seriile de date cu zerouri și extinzând sumele la infinit.

Auto-covarianță

$$r_y[-k] = r_y[k] \quad \forall k \in \mathbb{Z}$$

Este suficientă evaluarea pentru pivoți nenegativi.

$$r_y^N[k] = \frac{1}{N-k} \sum_{n=k+1}^N y[n]y[n-k] \quad \forall k \in \mathbb{N}$$

→ Mărginirea auto-covarianței

$$|r_y[k]| \leq r_y[0] = \sigma_y^2 \quad \forall k \in \mathbb{Z} \quad (\text{valoarea maximă a auto-covarianței este egală cu dispersia datelor})$$

Auto-corelație

auto-covarianța normalizată

$$\rho_y[k] \stackrel{\text{def}}{=} \frac{r_y[k]}{r_y[0]} = \frac{r_y[k]}{\sigma_y^2} \quad \forall k \in \mathbb{Z}$$



$$|\rho_y[k]| \leq 1 \quad \forall k \in \mathbb{Z}$$

Similar

Corelație (încrucișată)

covarianța (încrucișată) normalizată

$$\rho_{u,y}[k] \stackrel{\text{def}}{=} \frac{r_{u,y}[k]}{\sqrt{r_u[0]}\sqrt{r_y[0]}} = \frac{r_{u,y}[k]}{\sigma_u \sigma_y} \quad \forall k \in \mathbb{Z}$$

2 Modele de identificare

2.2 Noțiuni de Statistică și Prelucrare de Semnal

IE

Proprietăți elementare ale secvenței de (auto-)covarianță (continuare)

Exerciții

→ Periodicitatea auto-covarianței

$$y[n] = y[n \pm P] \quad \forall n \in \mathbb{Z}$$

perioada datelor

$$r_y[k] = r_y[k \pm P] \quad \forall k \in \mathbb{Z}$$

(cu aceeași perioadă ca a datelor)


Proces
ne(auto-)corelat

$$r_y[k] = E\{y[n]y[n-k]\} = \sigma_y^2 \delta_0[k] \quad \forall k \in \mathbb{Z}$$

impulsul unitar discret
(simbolul lui Kronecker)

O singură valoare nenulă,
în origine, egală cu dispersia

Acest tip de proces este **complet impredictibil**
(viitorul nu depinde nici de prezent, nici de trecut).



Proces
(statistic)
independent

$$p(y[m], y[n]) = p(y[m]) \cdot p(y[n]) \quad \forall m, n \in \mathbb{N}^*$$

Probabilitatea de apariție simultană a două valori ale ieșirii pe aceeași realizare este egală cu produsul probabilităților de apariție independentă a valorilor pe acea realizare.

Propoziția 1

Demonstrație

Exercițiu

Un proces independent de medie nulă este și necorelat.

Propoziția 2

Demonstrație

Complicat !

Un proces necorelat avînd distribuție Gaussiană este și independent.

Ce legătură
există între ele?

Două rezultate remarcabile
relevă această legătură.



2 Modele de identificare

2.2 Noțiuni de Statistică și Prelucrare de Semnal

- Datele achiziționate sunt în realitate **semnale** care transportă o anumită **informație** referitoare la comportamentul procesului care le-a produs.

Semnal

Entitate ce transportă informație cu privire la starea sau comportarea unui sistem, atât în **timp** cât și în **frecvență** .

Timp și frecvență?
Nu sunt concepte independente?



Domeniul **“Timp”** și domeniul **“Frecvență”** sunt **duale**.

- Aparent, **DA**.
- În esență, **NU**.

O **“Gaussiană”**

$$g(t) \stackrel{\text{def}}{=} \frac{1}{\sqrt{2\pi}\sigma} \exp\left[-\frac{(t-t_0)^2}{2\sigma^2}\right]$$

Exemplu

Principiul de incertitudine GABOR-HEISENBERG

Semnalul și spectrul său nu pot avea simultan suporturi compacte / finite.

Ambele pot avea, însă, suporturi infinite.

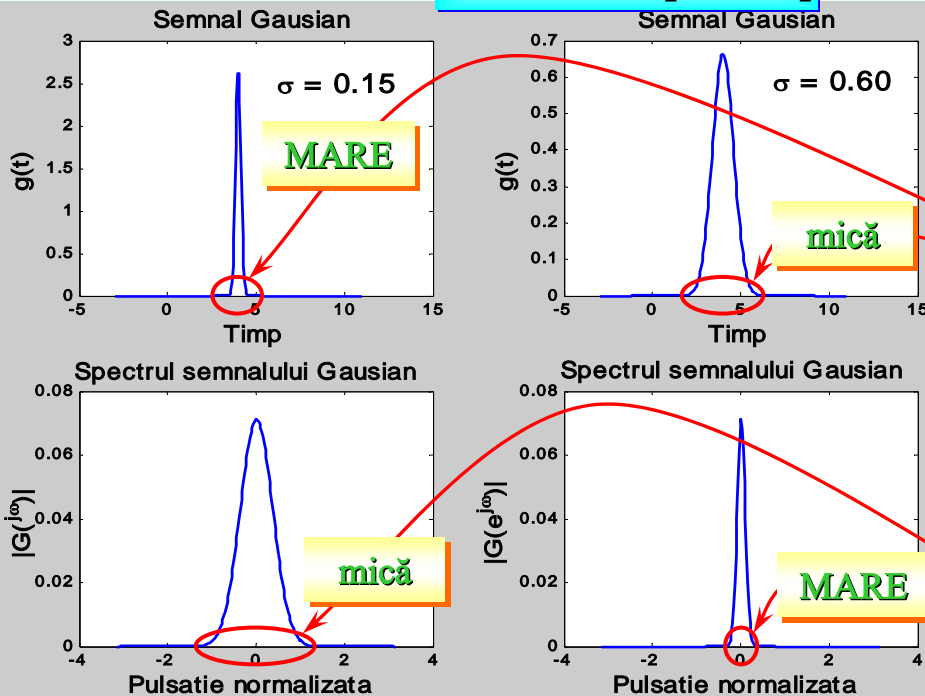
Rezoluție în **“Timp”**

Produsul rezoluțiilor \leq o constantă.

Rezoluție în **“Frecvență”**

Informație temporală **episodică**
(energie concentrată pe o durată scurtă).

Informație frecvențială **persistentă**
(energie disipată pe o bandă largă).



2 Modele de identificare

2.2 Noțiuni de Statistică și Prelucrare de Semnal

- Informația transportată de semnal poate fi mai ușor de **interpretat** într-un domeniu decât în altul.
- **Compresia** semnalului poate fi mai ușor de realizat într-un domeniu decât în altul.

Exemplu

Un FTJ ideal

$$h(t) \stackrel{\text{def}}{=} \frac{A \sin \omega_0 t}{\pi t}$$

Cum poate fi transferată informația între domeniile Timp și Frecvență?

"Timp"

Complicată

Interpretare

Simplă

"Frecvență"

mică


MARE

Rată de compresie


Operator Fourier

\mathcal{F}

Timp



Frecvență



\mathcal{F}^{-1}

Cu ajutorul **transformatorilor**.

Transformată

Operator inversabil care transformă un **semnal temporal** în unul **frecvențial**.

- Există mai multe clase de transformate.
- Una dintre cele mai diverse este clasa **Transformatorilor Fourier (TF)**.

PS

② Modele de identificare

②.② Noțiuni de Statistică și Prelucrare de Semnal



Definiții ale Operatorului Fourier (OF) **direct** (de **analiză**) și **invers** (de **sinteză**)

Semnale continue

Analiză

minus

$$\mathcal{F}(f)(j\Omega) \stackrel{\text{def}}{=} F(j\Omega) = \int_{-\infty}^{+\infty} f(t) e^{-j\Omega t} dt \quad \forall \Omega \in \mathbb{R}$$

Sinteză

plus

$$f(t) = \mathcal{F}^{-1}(F)(t) = \frac{1}{2\pi} \int_{-\infty}^{+\infty} F(j\Omega) e^{+j\Omega t} d\Omega \quad \forall t \in \mathbb{R}$$

Semnale discrete

Analiză

minus

$$\mathcal{F}(x)(e^{j\omega}) \stackrel{\text{def}}{=} X(e^{j\omega}) = \sum_{n \in \mathbb{Z}} x[n] e^{-j\omega n} \quad \forall \omega \in \mathbb{R}$$

Sinteză

plus

$$x[n] = \mathcal{F}^{-1}(X)[n] = \frac{1}{2\pi} \int_{-\pi}^{+\pi} X(e^{j\omega}) e^{+j\omega n} d\omega \quad \forall n \in \mathbb{Z}$$

De regulă, semnalul frecvențial returnat de OF este o funcție cu **valori complexe**.

Semnale continue

$$F(j\Omega) = \text{Re}[F(j\Omega)] + j \text{Im}[F(j\Omega)] = \boxed{|F(j\Omega)|} e^{j\phi_F(\omega)} \quad \forall \Omega \in \mathbb{R}$$

Spectru

Fază

Semnale discrete

$$X(e^{j\omega}) = \text{Re}[X(e^{j\omega})] + j \text{Im}[X(e^{j\omega})] = \boxed{|X(e^{j\omega})|} e^{j\phi_X(\omega)} \quad \forall \omega \in \mathbb{R}$$

2 Modele de identificare

2.2 Noțiuni de Statistică și Prelucrare de Semnal

Caracterizarea în frecvență a sistemelor liniare continue

$$\mathcal{L}(f)(s) = F(s) \stackrel{\text{def}}{=} \int_0^{+\infty} f(t) e^{-st} dt$$



Transformata Laplace (TL)

← instrumentul de caracterizare a transferului intrare-ieșire pentru **sisteme liniare continue**

funcție original
(continuală cauzală)
oarecare

$$f(t) = 0, \quad \forall t < 0$$

$$|f(t)| \leq e^{\alpha t}, \quad \forall t > t_0$$

Convergență
 \mathbb{C}

$$\mathcal{A}_c(f)$$

$$\text{Re}(s) \geq \alpha$$

$\alpha < 0$

⬇️ **Negativ.**

indicele descreșterii relative normalizate

⬆️ **restricția TL la axa imaginară**
(dacă aparține zonei de convergență)


pulsatie $\in \mathbb{R}$

$$F(s)|_{s=j\Omega} = \int_0^{+\infty} f(t) e^{-j\Omega t} dt$$

$$\mathcal{F}(f)(j\Omega) \stackrel{\text{def}}{=} F(j\Omega) \stackrel{\text{def}}{=} \int_0^{+\infty} f(t) e^{-j\Omega t} dt$$

$$\forall \Omega \in \mathbb{R}$$

Caracterizare în domeniul complex



$$H(s) = \frac{Y(s)}{X(s)} = \mathcal{L}(h)(s)$$

⬇️ **Sistem cauzal și stabil.**

$$H(j\Omega) = \frac{Y(j\Omega)}{X(j\Omega)} = \int_0^{+\infty} h(t) e^{-j\Omega t} dt$$

$$\forall \Omega \in \mathbb{R}$$

Răspuns în frecvență

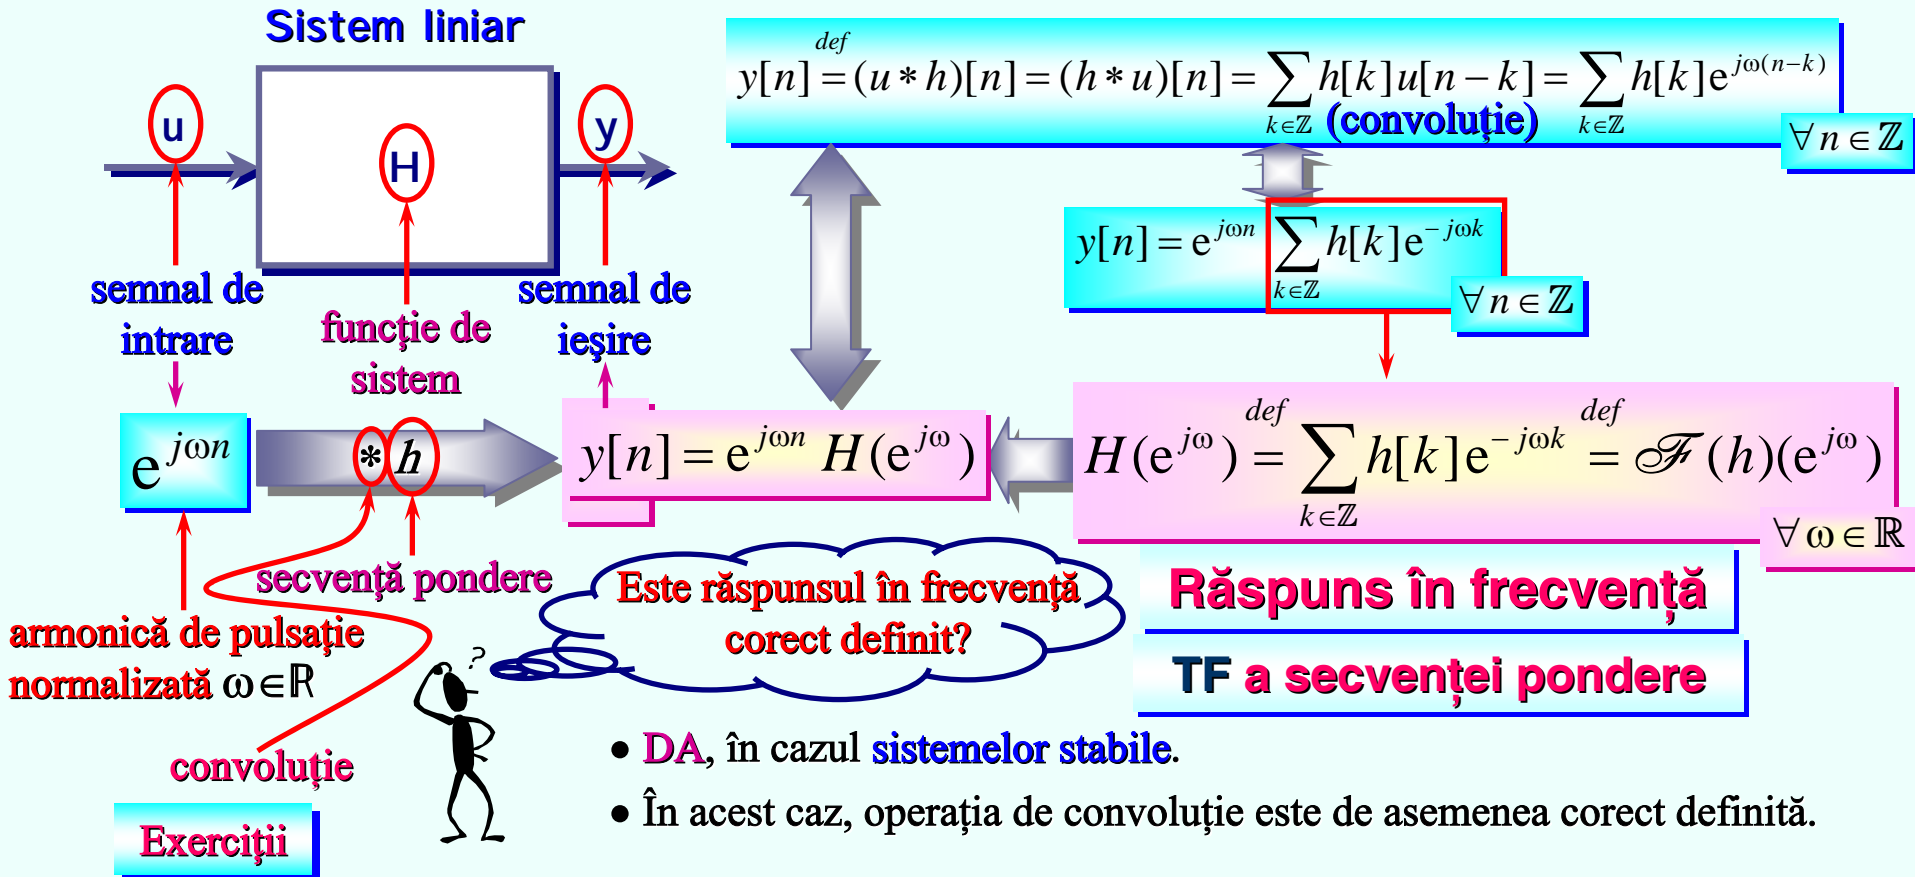
TF a secvenței pondere

② Modele de identificare

②.② Noțiuni de Statistică și Prelucrare de Semnal



Caracterizarea în frecvență a sistemelor liniare discrete



- Deduceți expresia răspunsului în frecvență al unui sistem liniar continuu, respectiv discret, apelând la un raționament similar celui utilizat pentru sistemele liniare discrete, respectiv continue.



Transformata Z (TZ):

$$Z(x)(z) \stackrel{\text{def}}{=} X(z) = \sum_{n \in \mathbb{Z}} x[n] z^{-n}$$

(convergență pe o coroană circulară)



Convoluție continuă:

$$(u * h)(t) \stackrel{\text{def}}{=} \int_{-\infty}^{+\infty} u(\tau) h(t - \tau) d\tau \quad t \in \mathbb{R}$$



Caracterizarea în frecvență a sistemelor liniare discrete (continuare)


2 Modele de identificare

2.2 Noțiuni de Statistică și Prelucrare de Semnal



$$H(q^{-1}) \stackrel{\text{def}}{=} \sum_{k \in \mathbb{Z}} h[k] q^{-k}$$

Funcție de sistem




☞ **Semnal frecvențial continuu.**

$$H(e^{j\omega}) \stackrel{\text{def}}{=} \sum_{k \in \mathbb{Z}} h[k] e^{-j\omega k} \quad \forall \omega \in \mathbb{R}$$

Răspuns în frecvență

$$[a]_{\text{dB}} \stackrel{\text{def}}{=} 20 \lg a$$




Spectru

decibeli

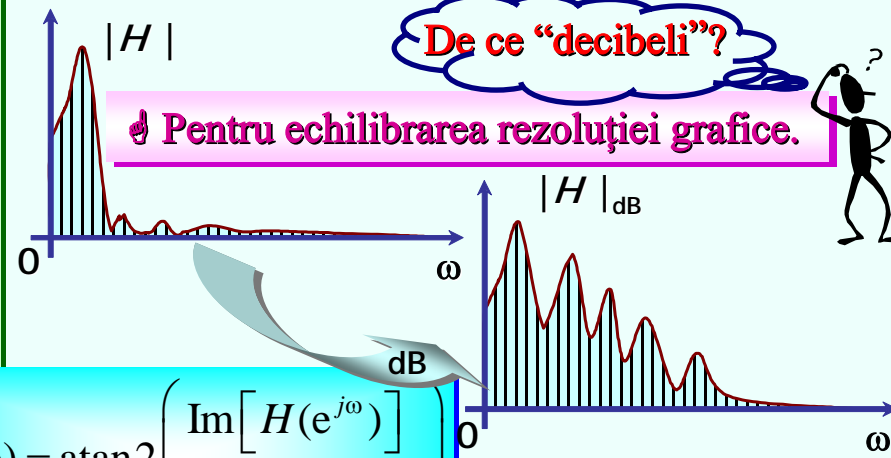
Proprietăți elementare

- **Funcție analitică** (indefinit derivabilă).
- **Periodicitate:** $H(e^{j\omega}) = H(e^{j(\omega+2\pi)})$ $\forall \omega \in \mathbb{R}$

$$|H(e^{j\omega})| = \sqrt{\text{Re}^2[H(e^{j\omega})] + \text{Im}^2[H(e^{j\omega})]}$$



Fază



$$\varphi_H(\omega) = \text{atan2} \left(\frac{\text{Im}[H(e^{j\omega})]}{\text{Re}[H(e^{j\omega})]} \right)$$