

② Modele de identificare

②.② Noțiuni de Statistică și Prelucrare de Semnal



Proprietăți statistice dezirabile ale estimațiilor de parametri necunoscuți

- Deoarece datele pe baza cărora se determină modele de identificare sunt afectate de perturbații stocastice, **parametrii estimați au de asemenea o natură stocastică.**

Adecvanța parametrilor estimați ai unui model de identificare este descrisă prin intermediul a **3 proprietăți.**

Nedeviere (asimptotică)

abaterea față de
media statistică


Consistență

convergența
statistică

Eficiență

viteza de
convergență

Contextul de lucru



2 Modele de identificare

2.2 Noțiuni de Statistică și Prelucrare de Semnal




Proprietăți statistice dezirabile ale estimațiilor de parametri necunoscuți (continuare)

Nedeviere

$$E\{\hat{\theta}_N\} = \theta^* \quad \forall N \in \mathbb{N}^*$$

Exemplu

Cazul parametrului scalar



⚡ Proprietate destul de restrictivă și dificil de verificat în practică.

- Dacă media statistică a parametrilor estimați nu verifică această proprietate, atunci estimația se consideră **deviată**.


Proprietate relaxată

Nedeviere asimptotică

$$\lim_{N \rightarrow \infty} E\{\hat{\theta}_N\} = \theta^*$$

Exemplu

Cazul parametrului scalar



Deviație

$$\Delta_N = \theta^* - E\{\hat{\theta}_N\} \quad \forall N \in \mathbb{N}^*$$

$$\lim_{N \rightarrow \infty} E\{\hat{\theta}_N\} = \theta^* \Leftrightarrow \lim_{N \rightarrow \infty} \Delta_N = 0$$

2 Modele de identificare

2.2 Noțiuni de Statistică și Prelucrare de Semnal



Proprietăți statistice dezirabile ale estimațiilor de parametri necunoscuți (continuare)

Consistență

$$\lim_{N \rightarrow \infty} \hat{\theta}_N = \theta^*$$

- Relevă maniera în care **se grupează** estimațiile în jurul mediei (sau al valorilor adevărate).
- Raportul dintre **consistență** și **nedeviere (asimptotică)** este ilustrat de următoarea proprietate:

Exercițiu

→ Estimațiile consistente pot fi deviate, dar sunt întotdeauna asimptotic nedeviate.

(cleștele consistenței)

- O altă proprietate interesantă este legată de conceptul de **varianță a erorii de estimare**.

$$\sigma^2(\hat{\theta}_N) \stackrel{\text{def}}{=} E\{\|\theta - \theta^*\|^2\} \in \mathbb{R}$$

☞ Produsul interior (scalar).



Matrice de auto-covarianță

$$P(\theta) \stackrel{\text{def}}{=} E\{(\theta - \theta^*)(\theta - \theta^*)^T\} \in \mathbb{R}^{n\theta \times n\theta}$$

☞ Produsul exterior.



Dispersie tot mai mică în jurul mediei.


$$\lim_{N \rightarrow \infty} \sigma^2(\hat{\theta}_N) = 0$$

se poate arăta

☞ Consistența este proprietatea cea mai importantă.

Exemplu

Cazul parametrului scalar



☞ Toate realizările estimațiilor converg la valoarea adevărată.

Exercițiu

$$\lim_{N \rightarrow \infty} \hat{\theta}_N = \theta^* \Leftrightarrow \lim_{N \rightarrow \infty} P(\hat{\theta}_N) = 0$$

2 Modele de identificare

2.2 Noțiuni de Statistică și Prelucrare de Semnal

Proprietăți statistice dezirabile ale estimațiilor de parametri necunoscuți (continuare)

Eficiență

$$\hat{\theta}_N$$

este cel puțin tot atît de eficientă ca $\tilde{\theta}_N$ dacă:

$$P(\hat{\theta}_N) \leq P(\tilde{\theta}_N) \iff P(\tilde{\theta}_N) - P(\hat{\theta}_N) \geq 0$$




$$\lim_{N \rightarrow \infty} \hat{\theta}_N = \theta^* \iff \lim_{N \rightarrow \infty} P(\hat{\theta}_N) = 0$$

♣ În sensul pozitiv (semi-)definirii.

$$\mathbf{x}^T \mathbf{A} \mathbf{x} \geq 0 \\ \forall \mathbf{x} \in \mathbb{R}^n$$

$$\sigma(\mathbf{A}) \subset \mathbb{R}_+ \\ \text{♣ spectrul matricii}$$



$$\Delta_1(\mathbf{A}) \geq 0$$

$$\Delta_2(\mathbf{A}) \geq 0$$

\vdots


$$\det(\mathbf{A}) \geq 0$$

♣ determinanții Sylvester


- **Eficiența** este asimilată cu **viteza de consistență**.

Exemplu

Cazul parametrului scalar



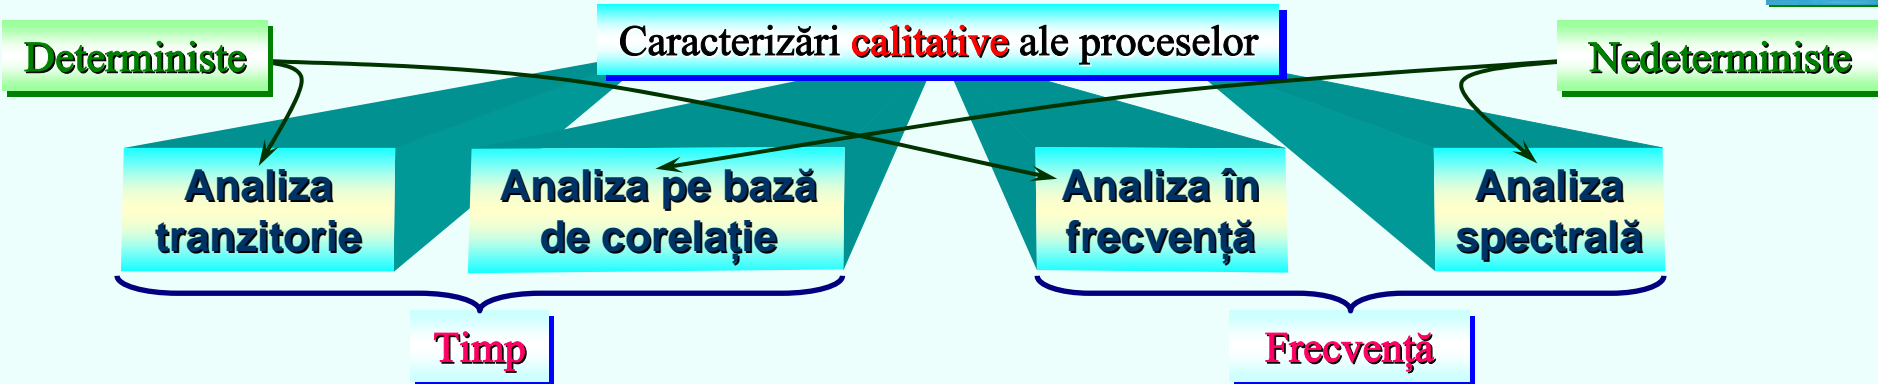
Consistență rapidă.



Consistență lentă.

② Modele de identificare

②.③ Analiza modelelor neparametrice



Analiza tranzitorie

- Analiză care se desfășoară de regulă în cadrul aplicațiilor de TS.



Obiectiv
(TS)

Analiza performanțelor de
stabilitate și robustețe.



Obiectiv
(IS)

Determinarea cu suficientă precizie a unor
mărimi caracteristice (amplificare, constante
de timp, timp mort, etc.).

- Se pleacă de la răspunsurile procesului la o intrare de tip **treaptă unitară** (**răspunsul indicial**) sau **impuls unitar** (**răspunsul causal la impuls** sau **funcția pondere**).
- **Răspunsul indicial** produce o serie de informații privind: tipul de sistem liniar care ar putea fi asociat procesului; caracteristicile sistemului liniar (dacă are ordinul inferior lui 3); timpul mort intrinsec al procesului; timpul de stabilizare, etc.
- **Răspunsul causal la impuls** (**funcția pondere**) oferă informații complementare referitoare la stabilitate, care ar putea fi exploatate ulterior și pentru **identificarea procesului**.

**Sistem liniar
stabil**



$$\lim_{n \rightarrow \infty} h[n] = 0$$



Secvența pondere poate fi **trunchiată**, în vederea
determinării unui număr finit de valori.



84



② Modele de identificare

②.③ Analiza modelelor neparametrice


Analiza tranzitorie (continuare)

Principalul inconvenient: **natura stocastică a datelor măsurate.**




**Lucrarea de
laborator #2**

Transient analysis of an ARX[1,1] model



Operația de **mediere statistică** peste un număr de realizări este **esențială**.



Dacă nu este disponibilă decât o realizare, se apelează la **media temporală a acesteia.**

② Modele de identificare

②.③ Analiza modelelor neparametrice

Analiza în frecvență



Obiectiv Determinarea cu suficientă precizie a **răspunsului în frecvență** corespunzător procesului furnizor de date.

Cum s-ar putea determina răspunsul în frecvență din date corupte de zgomot?

Cu ajutorul unei proprietăți remarcabile a sistemelor liniare discrete.

- În absența zgomotului, sau în cazul unui **zgomot extrem de slab** ($\text{SNR} > 4$) spectrul și faza procesului se pot trasa grafic prin stimularea cu **armonice de diferite frecvențe**.

☞ Faza răspunsului în frecvență se măsoară prin **defazajul** dintre armonica de ieșire și cea de intrare.

De regulă, precizia de determinare a fazei este **inferioară** preciziei de determinare a spectrului.

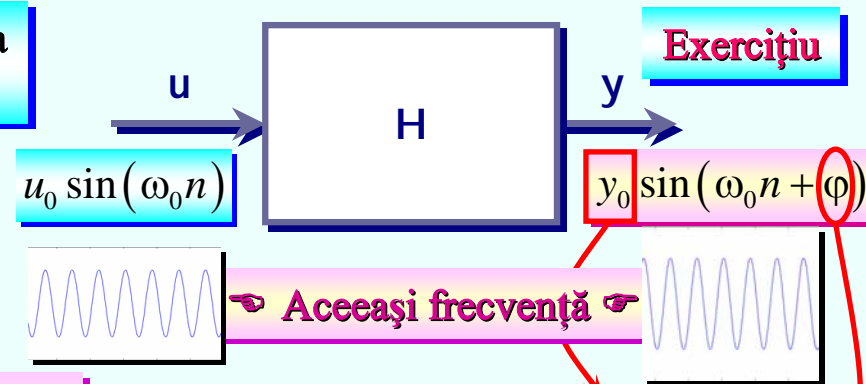
- În prezența zgomotului, există două strategii:

- ➔ Prin mediere directă, aplicată realizărilor spectrului și fazei.
- ➔ Prin mediere indirectă, aplicată proiecției ieșirii pe două armonice deterministe elementare.

$$H(e^{j\omega}) \stackrel{\text{def}}{=} \sum_{k \in \mathbb{Z}} h[k] e^{-j\omega k} \quad \forall \omega \in \mathbb{R}$$

☞ TF a secvenței pondere

Sistem liniar



Exercițiu

$$y_0 = u_0 |H(e^{j\omega_0})|$$
$$\varphi = \varphi_H = \arg H(e^{j\omega_0})$$

$$|H(e^{j\omega})| \quad \varphi_H(\omega)$$

spectru

fază

☞ prin varierea lui ω_0

② Modele de identificare

②.③ Analiza modelelor neparametrice

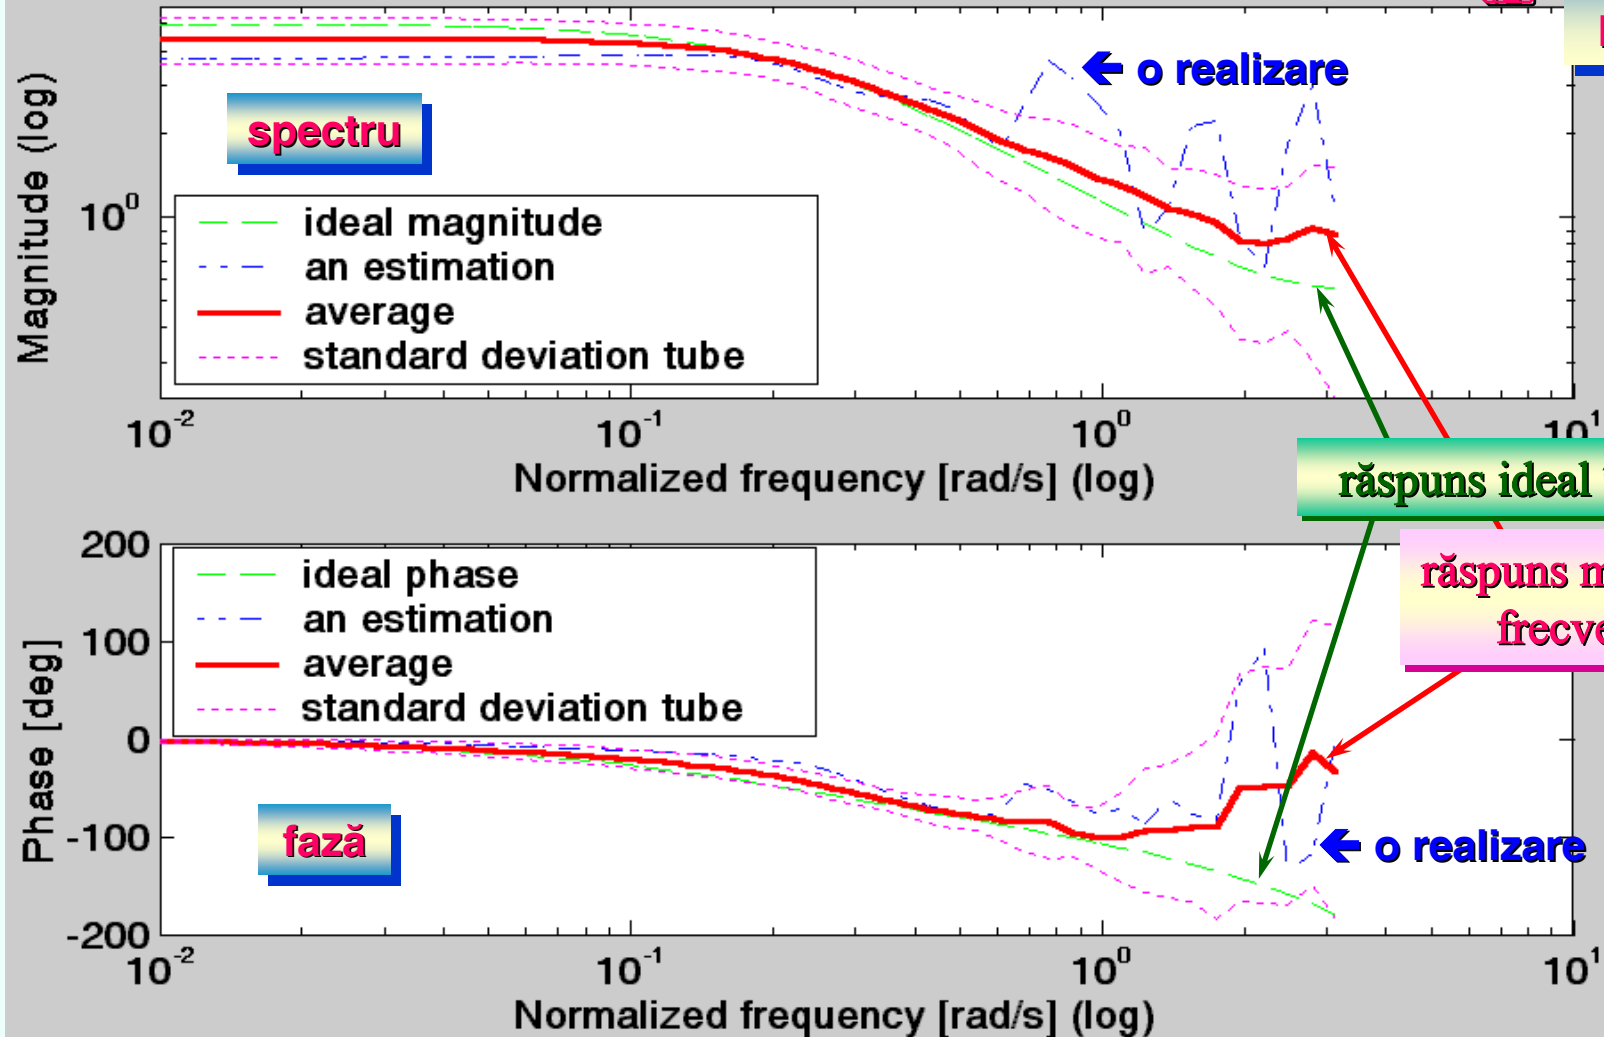
Analiza în frecvență (continuare)

Strategia medierii directe

Spectral analysis with Hamming window of length $M = 30$.



Lucrarea de
laborator #2



⚠ Sensibilitate crescută la zgomote în banda de frecvență înaltă.

2 Modele de identificare

2.3 Analiza modelelor neparametrice

Analiza în frecvență (continuare)

Strategia medierii indirecte

Așadar

$$u[n] = u_0 \sin(\omega_0 n)$$

$$y[n] = y_0 \sin(\omega_0 n + \varphi)$$

$$y_0 = u_0 |H(e^{j\omega_0})|$$

$$\varphi = \arg H(e^{j\omega_0})$$

← Se poate trasa pentru diferite valori ale lui ω_0 .

← **Dificil de estimat!**

Ce se poate face?

Cazul practic al frecvenței raționale

$$\omega_0 = 2\pi m_0 / n_0$$

$$m_0, n_0 \in \mathbb{N}^*$$

Se poate exploata proprietatea oricărei armonice elementare de a avea **medie nulă pe durata unei perioade**.

Dimensiunea orizontului de măsură poate fi aleasă **proporțională cu perioada**.

$$N = m_0 K \left(\frac{2\pi}{\omega_0} \right) = K n_0$$



Se proiectează ieșirea pe armonicele reale elementare de pulsație egală cu pulsația intrării.

$$\begin{cases} y_s[n] \stackrel{\text{def}}{=} y[n] \sin(\omega_0 n) = y_0 \sin(\omega_0 n + \varphi) \sin(\omega_0 n) = \frac{y_0}{2} \cos \varphi - \frac{y_0}{2} \cos(2\omega_0 n + \varphi) \\ y_c[n] \stackrel{\text{def}}{=} y[n] \cos(\omega_0 n) = y_0 \sin(\omega_0 n + \varphi) \cos(\omega_0 n) = \frac{y_0}{2} \sin \varphi + \frac{y_0}{2} \sin(2\omega_0 n + \varphi) \end{cases}$$

trigonometrie

👉 **Rezultatul rămîne totuși sensibil la perturbații.**

mediere temporală

$$\begin{cases} \bar{y}_s = \frac{1}{N} \sum_{n=0}^{N-1} y_s[n] = \frac{y_0}{2} \cos \varphi \\ \bar{y}_c = \frac{1}{N} \sum_{n=0}^{N-1} y_c[n] = \frac{y_0}{2} \sin \varphi \end{cases}$$

$$\varphi = \text{atan2} \left(\frac{\bar{y}_c}{\bar{y}_s} \right) = \text{atan2} \left(\frac{\sum_{n=0}^{N-1} y[n] \cos(\omega_0 n)}{\sum_{n=0}^{N-1} y[n] \sin(\omega_0 n)} \right)$$

2 Modele de identificare

2.3 Analiza modelelor neparametrice

Analiza pe bază de corelație



Obiectiv neparametric

Evaluarea și trasarea grafică a **secvențelor de covarianță** asociate procesului.

$$r_u \quad r_{u,y} \quad r_y$$

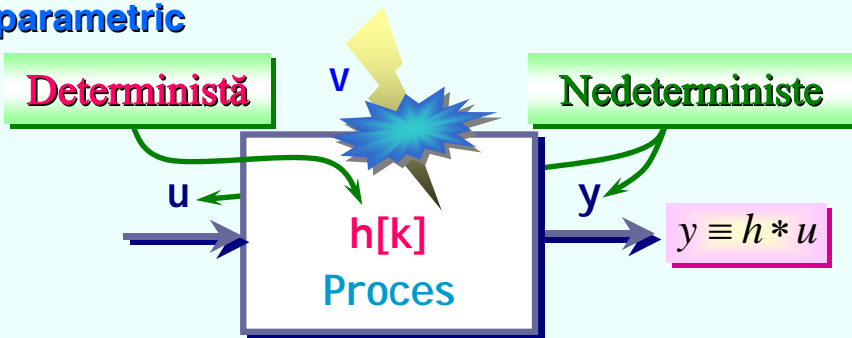
- Graficele covarianțelor permit efectuarea unei analize calitative privind **identificabilitatea** și **predictibilitatea** procesului, prin comparație cu secvența de auto-covarianță a zgomotului alb.



Obiectiv parametric

Determinarea **secvenței pondere** corespunzătoare procesului furnizor de date, dacă acesta ar fi identificat cu un sistem liniar discret **cauzal** și **stabil**.

$$\{h[n]\}_{n \in \mathbb{Z}}$$



$$h[n] = 0 \quad \forall n < 0$$

$$\sum_{n \in \mathbb{Z}} |h[n]| < \infty \quad \text{absolut sumabilă}$$

Secvența pondere poate fi **trunchiată**.

Proprietatea lui Parseval

$$\lim_{n \rightarrow \infty} |h[n]| = 0$$

$$\theta \stackrel{\text{def}}{=} [h[0] \quad h[1] \quad \dots \quad h[M-1]]^T \in \mathbb{R}^M$$

vectorul parametrilor necunoscuți

Cum s-ar putea determina θ din datele măsurate?

Prin transformarea relației **nedeterministe** de convoluție într-o relație similară, dar cu caracter **determinist**.

- Se aplică două operații succesive:

$$\begin{array}{c} \xrightarrow{E} \\ \textcircled{2} \end{array} \quad \begin{array}{c} \xrightarrow{\textcircled{1}} \\ \textcircled{1} \end{array} \quad u[n-k] \times \quad y[n] = \sum_{m \geq 0} h[m] u[n-m]$$


Un raționament propus de **N. Wiener (1894-1964)**.

fondatorul PS și al Ciberneticii

② Modele de identificare

②.③ Analiza modelelor neparametrice

Analiza pe bază de corelație (continuare)


E

$$y[n] = \sum_{m \geq 0} h[m] u[n - m] \quad \forall k \in \mathbb{N}$$

$$r_{y,u}[k] = E\{y[n]u[n - k]\} = \sum_{m \in \mathbb{N}} h[m] E\{u[n - m]u[n - k]\} \quad \forall k \in \mathbb{N}$$

Ecuatiile Wiener-Hopf

$$r_{y,u}[k] = \sum_{m \in \mathbb{N}} h[m] r_u[k - m] \quad \forall k \in \mathbb{N}$$

Relație de convoluție cu caracter **determinist**.

- Din sistemul infinit de ecuații Wiener-Hopf se pot extrage numai **primele** M .
- Fiecare dintre acestea se poate apoi **trunchia**, folosind **proprietatea lui Parseval**.

$$k=0 \quad r_{y,u}[0] = h[0]r_u[0] + h[1]r_u[1] + h[2]r_u[2] + \dots + h[M-1]r_u[M-1]$$

$$k=1 \quad r_{y,u}[1] = h[0]r_u[1] + h[1]r_u[0] + h[2]r_u[1] + \dots + h[M-1]r_u[M-2]$$

⋮

$$k=M-2 \quad r_{y,u}[M-2] = h[0]r_u[M-2] + \dots + h[M-3]r_u[1] + h[M-2]r_u[0] + h[M-1]r_u[1]$$

$$k=M-1 \quad r_{y,u}[M-1] = h[0]r_u[M-1] + \dots + h[M-3]r_u[2] + h[M-2]r_u[1] + h[M-1]r_u[0]$$

☞ S-a utilizat simetria secvenței de auto-covarianță a intrării.

- Sistemul finit obținut **nu este identic** celui corespunzător extras din ecuațiile Wiener-Hopf, dar îl **aproximează** pe acesta.

② Modele de identificare

②.③ Analiza modelelor neparametrice

Analiza pe bază de corelație (continuare)



$$r_{y,u}[0] = h[0]r_u[0] + h[1]r_u[1] + h[2]r_u[2] + \dots + h[M-1]r_u[M-1]$$

$$r_{y,u}[1] = h[0]r_u[1] + h[1]r_u[0] + h[2]r_u[1] + \dots + h[M-1]r_u[M-2]$$

⋮

sistem liniar

$$r_{y,u}[M-2] = h[0]r_u[M-2] + \dots + h[M-3]r_u[1] + h[M-2]r_u[0] + h[M-1]r_u[1]$$

$$r_{y,u}[M-1] = h[0]r_u[M-1] + \dots + h[M-3]r_u[2] + h[M-2]r_u[1] + h[M-1]r_u[0]$$

Exprimare
matricială

Sistemul Wiener-Hopf

$$\mathbf{R}_M(u) \boldsymbol{\theta} = \mathbf{r}_M(y, u)$$

Matricea de auto-covarianță
(a intrării)

Vectorul de covarianță
încrucișată (intrare-ieșire)

$$\mathbf{R}_M(u) \stackrel{\text{def}}{=} \begin{bmatrix} r_u[0] & r_u[1] & r_u[2] & \dots & r_u[M-1] \\ r_u[1] & r_u[0] & r_u[1] & \dots & r_u[M-2] \\ \vdots & \vdots & \vdots & \ddots & \vdots \\ r_u[M-2] & \dots & r_u[1] & r_u[0] & r_u[1] \\ r_u[M-1] & \dots & r_u[2] & r_u[1] & r_u[0] \end{bmatrix} \in \mathbb{R}^{M \times M}$$

$$\mathbf{r}_M(y, u) \stackrel{\text{def}}{=} \begin{bmatrix} r_{y,u}[0] \\ r_{y,u}[1] \\ \vdots \\ r_{y,u}[M-2] \\ r_{y,u}[M-1] \end{bmatrix} \in \mathbb{R}^M$$

Matrice
Toeplitz
simetrică

(elementul generic depinde de diferența indicilor săi)

Matricea se construiește **pe diagonale** și este
complet definită de prima linie sau coloană.

$\mathbf{R}_M(u) > 0$
inversabilă

Intrarea este
**suficient de
persistentă.**

Altă proprietate interesantă

$\mathbf{R}_M(u) \geq 0$ **pozitiv
(semi-)definită**

♣ Inversarea eficientă:
Algoritmul Levinson-Durbin.

$$\hat{\boldsymbol{\theta}}_M = \mathbf{R}_M^{-1}(u) \mathbf{r}_M(y, u)$$

**Soluția sistemului
Wiener-Hopf**

② Modele de identificare

②.③ Analiza modelelor neparametrice

Analiza spectrală



Obiectiv

Determinarea **răspunsului în frecvență** al procesului prin tehnici de diminuare a influenței perturbațiilor din datele măsurate asupra rezultatului.

$$H(e^{j\omega}) \stackrel{\text{def}}{=} \sum_{k \in \mathbb{Z}} h[k] e^{-j\omega k} \quad \forall \omega \in \mathbb{R}$$

Cum s-ar putea diminua influența zgomotelor?

TF a secvenței pondere



În general, prin tehnici de **estimare spectrală**.


În particular (IS), prin exploatarea **proprietăților densităților spectrale**.

Transferul densității spectrale prin sisteme liniare joacă rolul principal.

PS



Sistem liniar



• Rezultatul suferă totuși 3 tipuri de erori:

- ➔ Folosirea de formule aproximative pentru estimarea secvențelor de covarianță.
- ➔ Implementarea definițiilor densităților spectrale, cu ajutorul versiunii discrete a TF.
- ➔ Efecte numerice marginale cauzate de orizontul finit de măsură al datelor.

Mai puțin utilă, deoarece se **pierde informația de fază**.



Ponderarea datelor cu ferestre (vezi **Lucrarea de laborator #2**).