

③ Semnale de stimula

③.④ Clase de semnale persistente

Generarea SPA(B) pe cale hardware


Componenta principală

Registrul de deplasare

♣ Periodic.

SPAB	b_3	b_2	b_1	b_0	SPA
1	0	1	1	1	7
0	1	0	1	1	11
0	0	1	0	1	5
1	0	0	1	0	2
1	1	0	0	1	9
1	1	1	0	0	12
0	1	1	1	0	14
1	0	1	1	1	7

SPAB



XOR

$$\chi(x) = x^3 + x$$

Lost

- Activarea biților care contribuie la producerea valorii MSB este de regulă indicată de **polinomul caracteristic**.

$$\chi(x) = \varepsilon_{N-1}x^{N-1} + \varepsilon_{N-2}x^{N-2} + \dots + \varepsilon_1x + \varepsilon_0$$

parametri de activare (binari)

$N \in \mathbb{N}^*$ → Numărul de biți ai registrului de deplasare.

$2^N - 1 \in \mathbb{N}^*$ → Numărul maxim de valori ale SPA.

$P \in 1, 2^N - 1$ → Perioada SPA(B).

♣ Inițializarea nulă se exculde.

③ Semnale de stimul

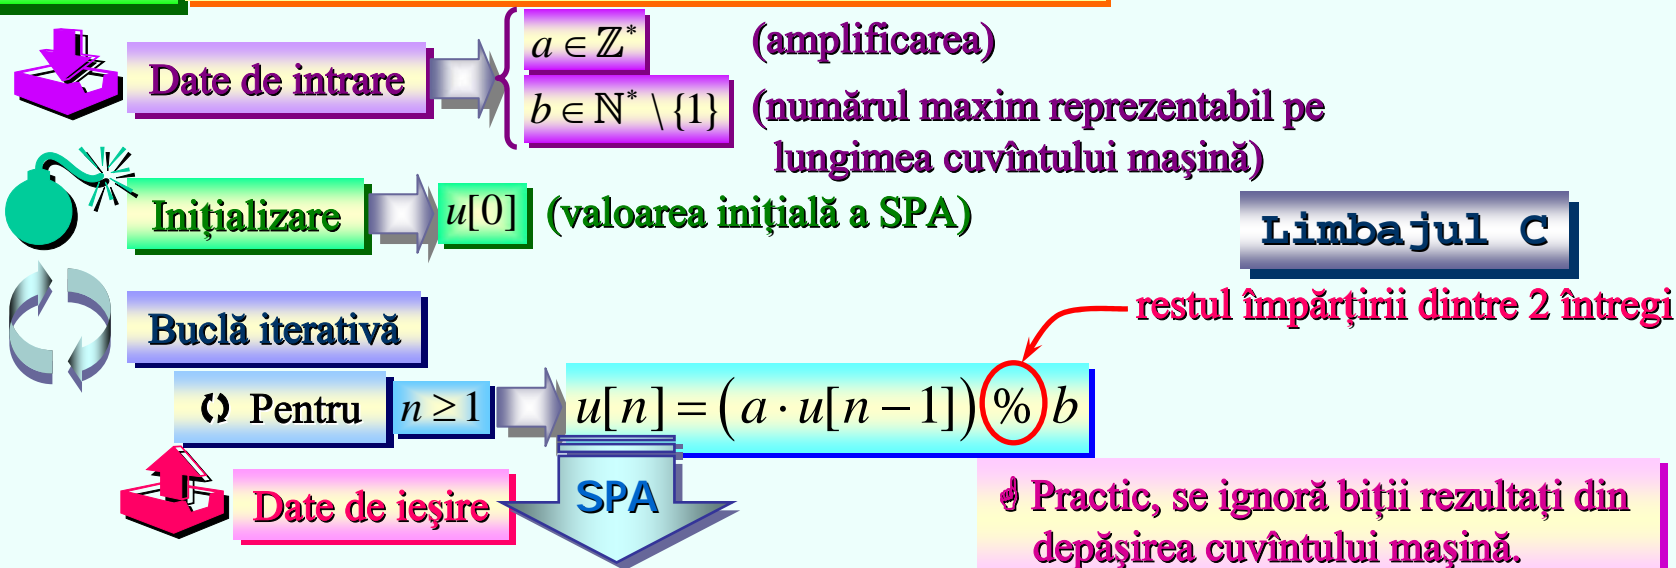
③.④ Clase de semnale persistente

Generarea SPA(B) pe cale software

- Algoritmii derivați sunt destul de numeroși, complexitatea lor variind mult.

Exemplu

Un algoritm bazat pe lungimea cuvîntului mașinii





Limbaajul C

- Semnalul rezultat este periodic, iar perioada este în general **mai mare pentru amplificări negative** decât pentru cele pozitive.

- Algoritmii cablați hardware pot fi de asemenea **emulați** (implementați pe cale software).

SPAB



SPA

③ Semnale de stimul

③.④ Clase de semnale persistente



Proprietăți fundamentale ale SPA(B)

SPA_B₁ Periodicitate

Hardware

$$P \leq 2^N - 1$$

Software

$$P \leq b - 1$$

Sp₂

Ordinul de persistență al unui SPA(B) este **finit** și **cel mult egal cu perioada**.

SPA_B₂ Mărginire

Hardware

$$1 \leq u[n] \leq 2^N - 1$$

Software

$$1 \leq |u[n]| \leq b - 1$$

SPA_B₃ Configurația auto-covarianței


Auto-covarianța unui SPA(B) este **periodică** și de perioadă P .

Mai mult, valorile auto-covarianței pentru **pivoți diferiți de multiplii întregi ai perioadei** sunt **invers proporționale cu perioada**.

$$|r_u[k]| \leq \frac{\alpha_u}{P} \quad \forall k \in \mathbb{Z} \setminus (P\mathbb{Z})$$

Exemplu

SPAB generat prin cablare hardware



♣ Cu cât perioada este mai mare, cu atât ordinul de persistență este mai mare și SPA(B) aproximează mai bine zgomotul alb (în sensul auto-covarianței).

③ Semnale de stimul

③.④ Clase de semnale persistente

Așadar

Atît **ordinul de persistență** al unui SPA(B) cît și **precizia de aproximare** a zgomotului alb **sunt controlabile prin intermediul perioadei.**

Cum s-ar putea genera SPA(B) de perioade maximale?

⚡ Perioada trebuie să fie sensibil mai mare decît dimensiunea orizontului de măsură.

Rezolvînd o **problemă granulară de optimizare.**

→ Funcția criteriu poate fi evaluată în toate punctele domeniului de definiție, dar numărul de valori ale acestuia este **extrem de mare.**

Perioada este determinată de 3 parametri.

Hardware

N → Numărul de biți ai registrului de deplasare.

$\{\varepsilon_n\}_{n \in \overline{0, N-1}}$ → Configurația polinomului caracteristic.

$\{b_{0n}\}_{n \in \overline{0, N-1}}$ → Inițializarea registrului de deplasare.

- De regulă, registrul de deplasare are **16, 32, 64** sau **128** de biți.

Căutarea exhaustivă a perioadei maximale este adesea **ineficientă.**

Tehnicile euristice de IA sau strategiile evoluționiste (AG) sunt **mult mai indicate.**

Software

b → Numărul maxim de valori ce pot fi generate.

a → Amplificarea.

$u[0]$ → Inițializarea algoritmului.

- De regulă, numărul maxim de valori este cel mai mare număr reprezentabil folosind cuvîntul mașină, amplificarea este negativă, iar inițializarea este returnată de ceasul calculatorului pe care este implementat algoritmul.

③ Semnale de stimul

③.④ Clase de semnale persistente

Generarea de SPA(B) cu distribuție de probabilitate dorită

- Tehnicile anterioare de generare a SPA(B) sunt destul de **simple**, dar **rudimentare**.
- Inconvenientul major: **nu se poate atribui secvenței pseudo-aleatoare o densitate de probabilitate dorită** (aceasta fiind **implicit** cea **uniformă**).
- În unele aplicații, densitatea de probabilitate a semnalului de intrare este **impusă**.

Cum s-ar putea genera SPA(B) cu distribuție de probabilitate impusă?



Folosind tehnica **Eșantionării Universale Stocastice** introdusă de **J.E. Baker** în **1987**.

SUS → **Stochastic Universal Sampling**

- Se pleacă de la o mulțime finită de valori numerice:

$$\mathcal{A}_N \stackrel{\text{def}}{=} \{a_n\}_{n \in \overline{1, N}}$$

(mulțimea de selecție: valorile posibile ale SPA(B))

- Acesteia i se atribuie următoarea densitate de probabilitate (de tip frecvență de apariție):

$$\begin{cases} p: \mathcal{A}_N \rightarrow [0, 1] \\ a_n \mapsto p(a_n) = p_n \end{cases} \stackrel{\text{def}}{=} \mathcal{P}_N = \{p_n\}_{n \in \overline{1, N}}$$

(mulțimea frecvențelor de apariție)

pseudo-

histogramă (generalizare)

Problemă

(evenimentul sigur)

$$\sum_{n=1}^N p_n = 1$$

$$\sum_{n=1}^N N p_n = N$$

$$\sum_{n=1}^N p_n = M$$


Implementarea mecanismului **SUS**, care constă în generarea de numere din mulțimea \mathcal{A}_N cu frecvențele de apariție corespunzătoare valorilor din \mathcal{P}_N (fie că aceste valori sunt sau nu returnate de o densitate de probabilitate).


⚡ Nu neapărat întregi, dar nenegative.

③ Semnale de stimul

③.④ Clase de semnale persistente

Generarea de SPA(B) cu distribuție de probabilitate dorită (continuare)

- Mecanismul SUS este simulat cu ajutorul unei **rulete virtuale**.
- Discul ruletei este segmentat în sectoare avînd suprafețe **proporționale** cu valorile frecvențelor de apariție / pseudo-histogramei impuse.
- Suprafața totală a discului este fie **unitară**,
fie, mai general, **un număr întreg oarecare**. 
$$\sum_{n=1}^N p_n = M$$
- Fiecare sector corespunde unui număr din mulțimea de selecție. \mathcal{A}_N
- Un **selector (bila ruletei)** se mișcă liber, dar amortizat, în jurul discului, indicînd în final numărul ce trebuie extras din mulțimea de selecție pentru a defini valoarea curentă a **SPA(B)**.
- Fiecare din numerele mulțimii de selecție **are șansa de a fi selectat** (chiar dacă frecvența sa de apariție este mică), numai că **această șansă este proporțională cu aria sectorului care îl reprezintă**.
- Dacă se efectuează **suficient de multe extrageri** de numere din folosind ruleta, **histograma** numerelor selecționate **se apropie de graficul densității de probabilitate / pseudo-histogramei impuse**.



Poate fi implementat mecanismul SUS în această formă?



Din cauză că **nu se poate opera cu valori fracționare ale ariilor sectoarelor de disc**.


✎ **Mecanismul trebuie exprimat în formă implementabilă, prin reconsiderarea elementelor ruletei.**

③ Semnale de stimul

③.④ Clase de semnale persistente

Generarea de SPA(B) cu distribuție de probabilitate dorită (continuare)

- De această dată, discul ruletei va trebui să conțină un număr de sectoare echivalente (adică de arii identice) egal cu N (numărul de valori de selecție) sau M (suma valorilor pseudo-histogramei).
- Aria unui sector nu mai are importanță, deoarece fiecare sector este ocupat de câte un număr din **mulțimea valorilor SPA(B)**.



⚡ Un același număr poate fi atribuit mai multor sectoare.

$s_n \in \mathbb{N}$ → Numărul de sectoare ocupate de valoarea a_n .

⚡ Poate fi și nul, dacă valorii corespunzătoare a SPA(B) i s-a atribuit o probabilitate prea mică de apariție.

$\mathcal{S}_N = \left\{ s_n \right\}_{n \in \overline{1, N}}^{\text{def}}$ → Histograma dorită a SPA(B).

⚡ Valorile histogramei dorite fiind întregi, aceasta este în general ușor diferită de pseudo-histograma impusă.



$$\mathcal{U}_N \subseteq \mathcal{A}_N$$

Unele valori din mulțimea de selecție pot lipsi.

$$\mathcal{S}_N \neq \mathcal{P}_N$$

- Cu toate acestea, **suma valorilor histogramei este egală cu suma valorilor pseudo-histogramei impuse.**
- Selectorul alege acum unul dintre sectoarele echivalente care indică în mod direct o anumită valoare a SPA(B).

$$\sum_{n=1}^N s_n = N \sum_{n=1}^N p_n = N$$

distribuție de probabilitate

sau

$$\sum_{n=1}^N s_n = \sum_{n=1}^N p_n = M$$

pseudo-histogramă

⚡ Nu este necesar ca sectoarele ocupate de o anumită valoare să fie adiacente sau grupate în aceeași zonă a discului.

- Practic, acum se selectează sectoare cu **distribuție uniformă**, dar o valoare a SPA(B) poate ocupa mai multe sectoare.

③ Semnale de stimul

③.④ Clase de semnale persistente

Generarea de SPA(B) cu distribuție de probabilitate dorită (continuare)

Cum se îmbunătățește implementabilitatea mecanismului SUS în noua filozofie?

Obiectivul principal este acum cel de generare a **mulțimii valorilor posibile ale SPA(B)**.

$$\mathcal{U}_N = ?$$

- **Prin convenție**, în această mulțime, **elementele de selecție se pot repeta**, astfel că mulțimea constituie o reprezentare a discului ruletei sub forma unui șir de numere.

$$\mathcal{U}_N = \underbrace{\{a_1, a_1, \dots, a_1\}}_{s_1 \text{ ori}}, \underbrace{\{a_2, a_2, \dots, a_2\}}_{s_2 \text{ ori}}, \dots, \underbrace{\{a_N, a_N, \dots, a_N\}}_{s_N \text{ ori}}$$

- Practic, plecînd de la pseudo-histograma impusă, trebuie construită histograma dorită.
- Odată mulțimea valorilor **SPA(B)** construită, selecția acestora se poate efectua **folosind o distribuție uniformă**.


$$\mathcal{P}_N \Rightarrow \mathcal{S}_N = ?$$

Exemplu

O metodă hardware se poate implementa/emula pentru a genera **adresele valorilor SPA(B)** care trebuie returnate.

$$\mathcal{U}_N = \{ \overset{1}{a_1}, \overset{2}{a_1}, \dots, a_1, a_2, a_2, \dots, a_2, \overset{n}{a_N}, a_N, a_N, \dots, a_N, \overset{M}{a_N} \}$$

$$u[n] = a_{k_n}$$

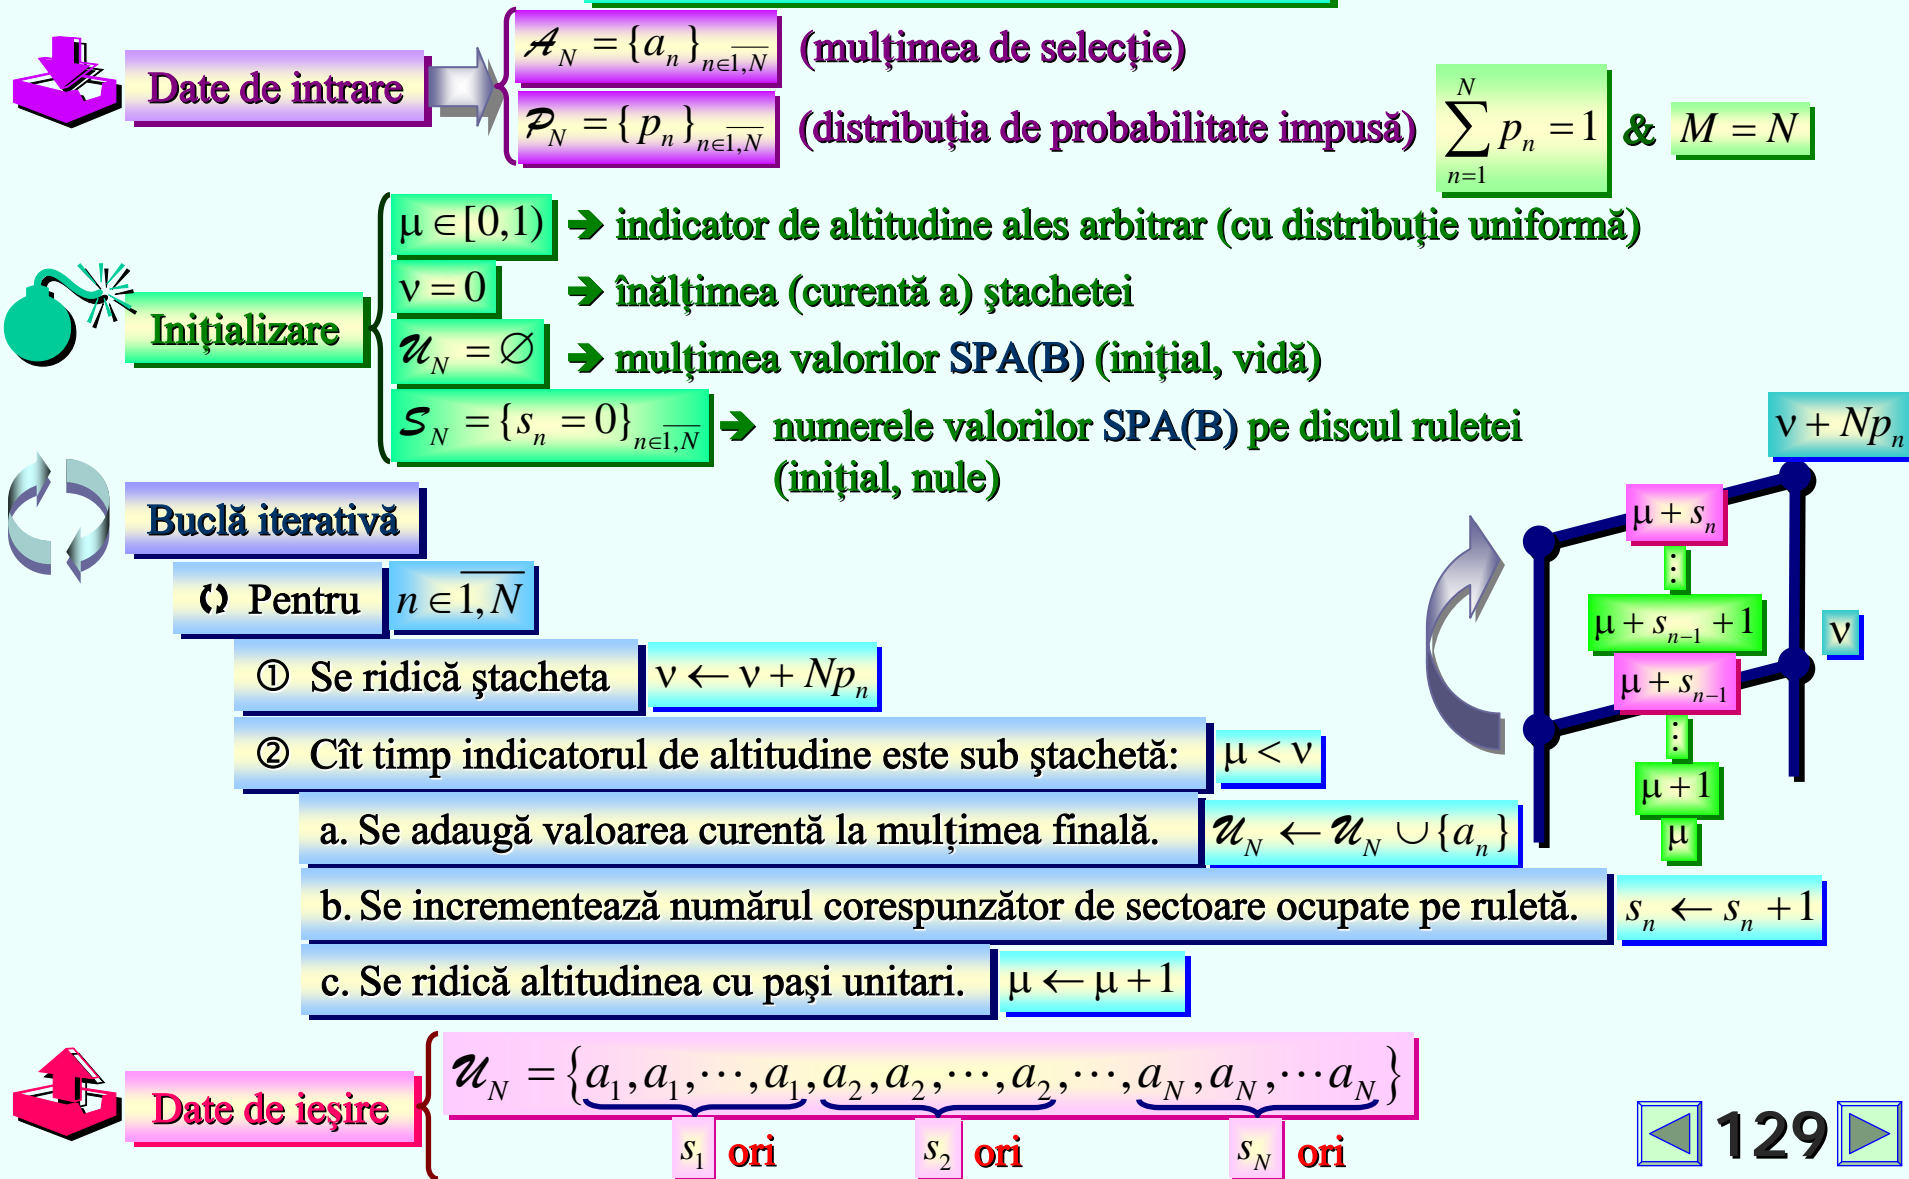


Generarea de SPA(B) cu distribuție de probabilitate dorită (continuare)

3 Semnale de stimul

3.4 Clase de semnale persistente

Algoritmul (clasic al) lui Baker

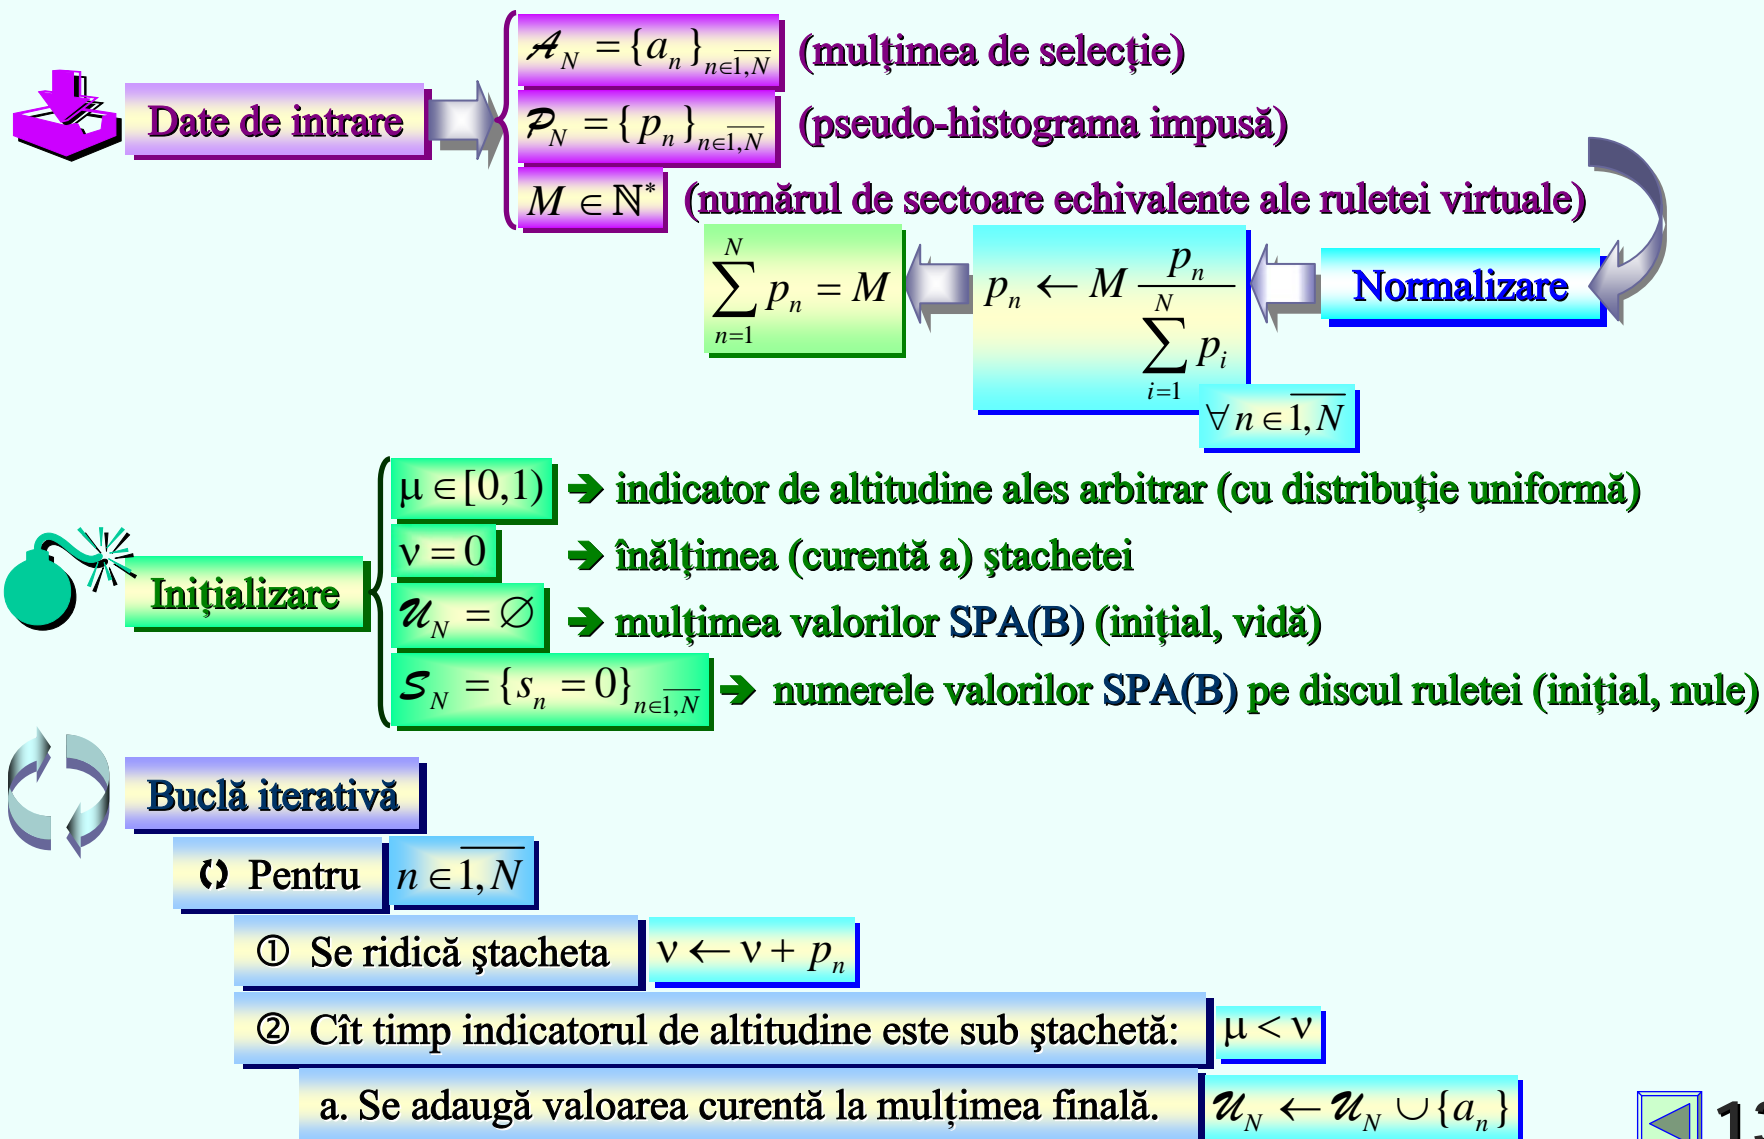


Generarea de SPA(B) cu distribuție de probabilitate dorită (continuare)

3 Semnale de stimul

3.4 Clase de semnale persistente

Algoritmul generalizat al lui Baker



Generarea de SPA(B) cu distribuție de probabilitate dorită (continuare)

3 Semnale de stimul

3.4 Clase de semnale persistente

Algoritmul generalizat al lui Baker (continuare)

Bucă iterativă

⌈ Pentru $n \in \overline{1, N}$

① Se ridică ștacheta $v \leftarrow v + p_n$

② Cît timp indicatorul de altitudine este sub ștachetă: $\mu < v$

a. Se adaugă valoarea curentă la mulțimea finală. $\mathcal{U}_N \leftarrow \mathcal{U}_N \cup \{a_n\}$

b. Se incrementează numărul corespunzător de sectoare ocupate pe ruletă. $s_n \leftarrow s_n + 1$

c. Se ridică altitudinea cu pași unitari. $\mu \leftarrow \mu + 1$

Date de ieșire

$$\mathcal{U}_N = \underbrace{\{a_1, a_1, \dots, a_1\}}_{s_1 \text{ ori}}, \underbrace{\{a_2, a_2, \dots, a_2\}}_{s_2 \text{ ori}}, \dots, \underbrace{\{a_N, a_N, \dots, a_N\}}_{s_N \text{ ori}}$$

- Se poate arăta că histograma rezultată în urma acestor algoritmi este un **aproximant** al pseudo-histogramei impuse.

Algoritmul clasic

$$\lfloor p_n N \rfloor \leq s_n \leq \lceil p_n N \rceil \quad \& \quad \forall n \in \overline{1, N}$$

$$\sum_{n=1}^N s_n = N$$

Algoritmul generalizat

$$\lfloor p_n \rfloor \leq s_n \leq \lceil p_n \rceil \quad \& \quad \forall n \in \overline{1, N}$$

(după normalizare)

$$\sum_{n=1}^N s_n = M$$

⚡ Rolul parametrului M este de a mări rezoluția ruletei, pentru ca **toate** valorile de selecție să se regăsească în mulțimea valorilor SPA(B).