

## 4 Metode de identificare și validare

### 4.1 Scurtă clasificare

#### Metode

##### Bazate pe Teoria Optimizărilor

- Metode care conduc la diferiți **algoritmi numerici** de identificare, de regulă, **eficienți** și **accesibili implementării** pe un mijloc automat de calcul.
- Metode specifice modelelor de **complexitate și precizie limitate**, de preferat **liniare în parametri**.

##### Bazate pe Teoria Estimației

- Metode **difficil de implementat**, în general **nealgoritmice**, cu caracter mai mult **teoretic**.
- Metode specifice modelelor de **complexitate și precizie ridicate**, **nu neapărat liniare în parametri**, cu **performanțe statistice determinate**.

⚡ Aceste două categorii nu sunt disjuncte, deoarece parametrii nu numai că se pot determina cu ajutorul unor proceduri numerice, dar pot fi caracterizați și din punct de vedere statistic.

#### Metode

##### Neadaptive (de tip off-line)

- Folosite ori de câte ori **parametrii modelului matematic asociat sunt constanți pe durata orizontului de măsură**, adică nu necesită adaptări succesive dictate de variațiile datelor achiziționate.

##### Adaptive (de tip on-line)

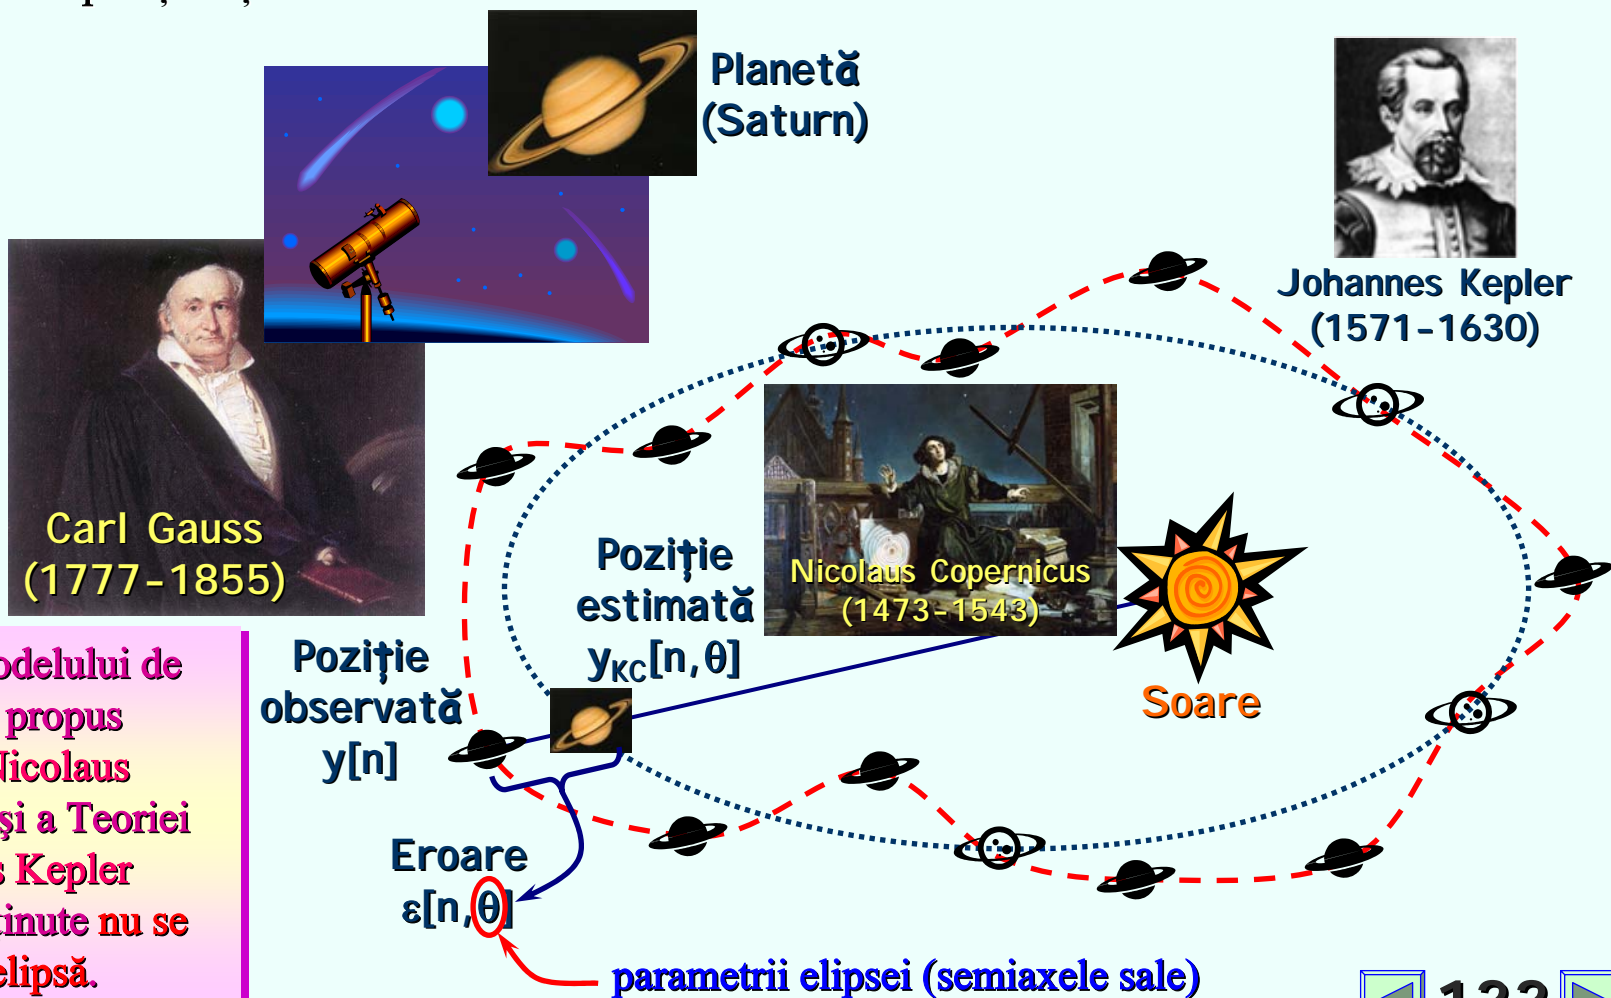
- Conduc, de regulă, la algoritmi de timp real și se adresează **proceselor/sistemelor cu caracteristici variabile în timp**, cărora trebuie să li se asocieze modele cu parametri variabili, adaptați la variațiile datelor achiziționate.



# 4 Metode de identificare și validare

## 4.2 Metoda Celor Mai Mici Pătrate (MCMMP)

- MCMMP se bazează pe **Teoria regresiei liniare** inițiată de **Carl Gauss**.
- Beneficiind de un telescop destul de performant pentru acea epocă, Carl Gauss a observat și notat timp de câțiva ani pozițiile mai multor planete față de Pamânt, calculînd apoi coordonatele acestor poziții față de Soare.



✎ În pofida modelului de sistem solar propus intuitiv de Nicolaus Copernicus și a Teoriei lui Johannes Kepler pozițiile obținute nu se situau pe o elipsă.

# 4 Metode de identificare și validare

## 4.2 Metoda Celor Mai Mici Pătrate

- Verificarea **legilor lui Kepler-Copernicus** impune ca **toate pozițiile observate ale planetei** (în număr de  $N$ ) **să se situeze pe o anumită elipsă**.

$$y[n] = y_{KC}[n, \theta]$$

$$\forall n \in \overline{1, N}$$

← Sistem de ecuații din care ar trebui să rezulte parametrii elipsei.

Ce se poate face?

Se încearcă determinarea elipsei care trece **cel mai bine** printre toate pozițiile observate.

Adică elipsa ai cărei parametri **minimizează un criteriu pătratic**.

$$\mathcal{V}(\theta) \stackrel{\text{def}}{=} \sum_{n=1}^N \varepsilon^2[n, \theta] = \sum_{n=1}^N (y[n] - y_{KC}[n, \theta])^2$$

(eroarea pătratică totală)

$$\hat{\theta} = \underset{\theta \in \mathbb{R}^{n_\theta}}{\operatorname{argmin}} \mathcal{V}(\theta)$$

De aici rezultă numele metodei.


- Pentru rezolvarea problemei pătratice de optimizare, se poate apela la **gradient** (dacă funcția criteriu este derivabilă și gradientul ei se exprimă printr-o relație explicită sau cel puțin implicită) sau **la alte mijloace** (dacă, dintr-un motiv sau altul, aceasta nu permite evaluarea gradientului).
- Această tehnică (propusă de Gauss) se poate extinde și pentru găsirea altor modele optime în raport cu criteriul pătratic, plecând de la un set de date măsurate.

# 4 Metode de identificare și validare

## 4.2 Metoda Celor Mai Mici Pătrate

### Exemplu

Evaluarea dreptei de regresie liniară prin metoda gradientului



$an+b$



Cum pot fi determinați cei 2 parametri ai dreptei?



Prin minimizarea erorii pătratice totale.

$$\hat{\theta} = \underset{\theta \in \mathbb{R}^2}{\operatorname{argmin}} \mathcal{V}(\theta) = \underset{a \in \mathbb{R}^*, b \in \mathbb{R}}{\operatorname{argmin}} \left\{ \sum_{n=1}^N \varepsilon^2[n, a, b] \right\} =$$

$$= \underset{a \in \mathbb{R}^*, b \in \mathbb{R}}{\operatorname{argmin}} \left\{ \sum_{n=1}^N (y_n - an - b)^2 \right\}$$

paraboloid de rotație

$$\nabla \mathcal{V}(a, b) = 0 \Leftrightarrow \begin{cases} \frac{\partial}{\partial a} \mathcal{V}(a, b) = 0 \\ \frac{\partial}{\partial b} \mathcal{V}(a, b) = 0 \end{cases}$$

Soluția problemei de optimizare se găsește anulând valorile gradientului.

$$\begin{cases} -2 \sum_{n=1}^N n(y_n - an - b) = 0 \\ -2 \sum_{n=1}^N (y_n - an - b) = 0 \end{cases}$$

$$\begin{cases} \hat{a} = \frac{6}{N(N^2 - 1)} \left[ 2 \sum_{n=1}^N ny_n - (N + 1) \sum_{n=1}^N y_n \right] \\ \hat{b} = \frac{2}{N(N - 1)} \left[ (2N + 1) \sum_{n=1}^N y_n - 3 \sum_{n=1}^N ny_n \right] \end{cases}$$

# 4 Metode de identificare și validare

## 4.2 Metoda Celor Mai Mici Pătrate

**Soluția generală a MCMMP în cazul modelelor de regresie liniară**

$$y_{\mathcal{M}}[n, \theta] \stackrel{\text{def}}{=} \varphi^T[n] \theta \quad \forall n \in \mathbb{N}^*$$

$$y_{\mathcal{M}}[n, \theta] \stackrel{\text{def}}{=} \varphi^T[n] \theta$$

model

$\forall n \in \mathbb{N}^*$

$$\mathcal{D}_N = \{(\varphi[n], y[n])\}_{n \in \overline{1, N}}$$

date

**Criteriul pătratic**

☞ Tot un paraboloid de rotație, dar generalizat.

$$\mathcal{V}(\theta) \stackrel{\text{def}}{=} \sum_{n=1}^N \varepsilon^2[n, \theta] \stackrel{\text{def}}{=} \sum_{n=1}^N (y[n] - y_{\mathcal{M}}[n, \theta])^2 = \sum_{n=1}^N (y[n] - \varphi^T[n] \theta)^2 \quad \forall \theta \in \mathbb{R}^{n\theta}$$

Metode de minimizare

Minim unic.

Metoda gradientului

Metoda pătratelor perfecte

Exercițiu

Exercițiu

**Metoda matricială**

$\mathbf{Y} \stackrel{\text{def}}{=} [y[1] \ y[2] \ \cdots \ y[N]]^T \in \mathbb{R}^N \rightarrow$  Vectorul global al datelor de ieșire măsurate.

$$\Phi \stackrel{\text{def}}{=} \begin{bmatrix} \varphi^T[1] \\ \varphi^T[2] \\ \vdots \\ \varphi^T[N] \end{bmatrix} = [\phi_1 \mid \phi_2 \mid \cdots \mid \phi_{n\theta}] \in \mathbb{R}^{N \times n\theta}$$

linii

coloane

$\rightarrow$  Matricea regresorilor.

☞ De regulă, o matrice monică.

$$\text{rank}(\Phi) = n\theta < N$$

coloane liniar independente



$\varepsilon(\theta) \stackrel{\text{def}}{=} [\varepsilon[1, \theta] \ \varepsilon[2, \theta] \ \cdots \ \varepsilon[N, \theta]]^T \in \mathbb{R}^N \rightarrow$  Vectorul erorilor de măsură față de model.



# 4 Metode de identificare și validare

## 4.2 Metoda Celor Mai Mici Pătrate

### Soluția generală a MCMMP în cazul modelelor de regresie liniară (continuare)

De ce matricea regresorilor este de regulă monică?

### Metoda matricială

Mulțimea matricilor neinvertibile este **mai parsimonioasă**.

### Test

- Completați la întâmplare o matrice de ordin 3. Este această matrice inversabilă? Ce șanse sunt ca ea să nu fie inversabilă?

- Paradoxal, tocmai **perturbațiile stocastice** care afectează datele măsurate aduc matricea regresorilor în stare de **rang maxim**.

### Ecuatii matriciale

$$y_{\mathcal{M}}[n, \theta] \stackrel{\text{def}}{=} \varphi^T[n] \theta$$

$\forall n \in \overline{1, N}$

$$Y_{\mathcal{M}} \stackrel{\text{def}}{=} \Phi \theta \in \mathbb{R}^N$$

← Ecuatia globală a modelului de regresie liniară.

$$\varepsilon[n, \theta] \stackrel{\text{def}}{=} y[n] - \varphi^T[n] \theta$$

$\forall n \in \overline{1, N}$

$$\varepsilon(\theta) \stackrel{\text{def}}{=} Y - \Phi \theta \in \mathbb{R}^N$$

← Eroarea globală de model.

$$\mathcal{V}(\theta) \stackrel{\text{def}}{=} \sum_{n=1}^N \varepsilon^2[n, \theta]$$

$$\mathcal{V}(\theta) \stackrel{\text{def}}{=} \varepsilon^T(\theta) \varepsilon(\theta) = \|\varepsilon(\theta)\|^2 = (Y - \Phi \theta)^T (Y - \Phi \theta) = \|Y - \Phi \theta\|^2$$

← Criteriul pătratic.

### Teorema 1 (Soluția generală a MCMMP)

Soluția problemei pătratice de optimizare este exprimată de următoarele ecuații:

$$\hat{\theta} \stackrel{\text{def}}{=} (\Phi^T \Phi)^{-1} \Phi^T Y$$

estimație MCMMP

$$\mathcal{V}(\hat{\theta}) = Y^T Y - Y^T \Phi (\Phi^T \Phi)^{-1} \Phi^T Y$$

precizie

# 4 Metode de identificare și validare

## 4.2 Metoda Celor Mai Mici Pătrate

Soluția generală a MCMMP în cazul modelelor de regresie liniară (continuare)

Așadar

$$\hat{\theta} \stackrel{\text{def}}{=} (\Phi^T \Phi)^{-1} \Phi^T Y$$

Pseudo-inversa Moore-Penrose

Metoda matricială

$$\mathcal{V}(\hat{\theta}) = Y^T Y - Y^T \Phi (\Phi^T \Phi)^{-1} \Phi^T Y$$

- Practic, orice sistem linear incompatibil:

$$Y = \Phi \theta$$

cu matricea  $\Phi$  monică admite o

unică pseudo-soluție:

$$\Phi^T \times \begin{bmatrix} Y \\ 0 \end{bmatrix} = \Phi^T \Phi \theta \Rightarrow \Phi^T Y = (\Phi^T \Phi) \theta$$

↗ Inversabilă.

$$\hat{\theta} = (\Phi^T \Phi)^{-1} \Phi^T Y$$

Operator de deparazitare

$$Q \in \mathbb{R}^{N \times N}$$

Proprietăți elementare ale operatorului de deparazitare

→ Simetrie

$$Q^T = I_N - \Phi (\Phi^T \Phi)^{-1} \Phi^T = Q$$

→ Ortogonalitate față de matricea regresorilor

$$Q\Phi = \Phi - \Phi (\Phi^T \Phi)^{-1} (\Phi^T \Phi) = 0 = \Phi^T Q$$

→ Operatorul este și proiector

$$\begin{aligned} Q^2 &= I_N - 2\Phi (\Phi^T \Phi)^{-1} \Phi^T + \Phi (\Phi^T \Phi)^{-1} (\Phi^T \Phi) (\Phi^T \Phi)^{-1} \Phi^T = \\ &= I_N - \Phi (\Phi^T \Phi)^{-1} \Phi^T = Q. \end{aligned}$$

→ Pozitiv (semi-definire)

$$Q = Q^2 = Q^T Q \geq 0$$

⚡ Deși valoarea optimă a criteriului pătratic se exprimă printr-o diferență, ea este nenegativă (cum era de așteptat).

$$\mathcal{V}(\hat{\theta}) = Y^T Q Y \geq 0$$

# 4 Metode de identificare și validare

## 4.2 Metoda Celor Mai Mici Pătrate

Soluția generală a MCMMP în cazul modelelor de regresie liniară (continuare)

### Demonstrație geometrică a Teoremei 1

- Problema optimizării folosind criteriul pătratic se reformulează în termeni geometrici.

☞ Este practic imposibil ca vectorul global al datelor să fie generat numai de coloanele matricii regresorilor.

Se caută vectorul din hiperplanul modelului de regresie care este **cel mai apropiat de vectorul datelor**.

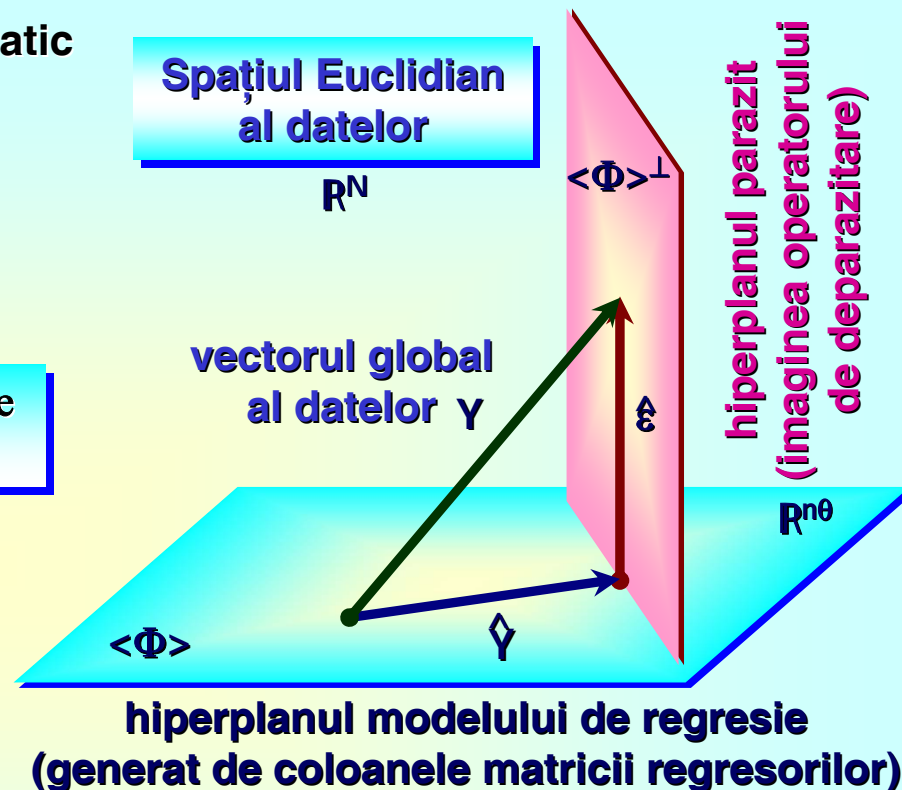
Adică **proiecția** acestuia pe hiperplanul modelului de regresie.

### Așadar

Problema revine la determinarea proiecției vectorului datelor pe hiperplanul modelului de regresie, adică la minimizarea normei erorii dintre vectorul de date și al proiecției sale.

☞ Eroarea minimă dintre cei doi vectori este un element al **hiperplanului parazit, ortogonal pe hiperplanul modelului de regresie**.

### Metoda matricială



$$\hat{\epsilon} = Y - \hat{Y} = QY$$

$$\|\hat{\epsilon}\|^2 = \hat{\epsilon}^T \hat{\epsilon} = Y^T Q^T QY = Y^T Q^2 Y = Y^T QY$$

(datorită  
proprietăților  
operatorului  $Q$ )



# 4 Metode de identificare și validare

## 4.2 Metoda Celor Mai Mici Pătrate

### Soluția generală a MCMMP în cazul modelelor de regresie liniară (continuare)

#### Demonstrație (Teorema 1)

#### Metoda matricială

- Urmează determinarea proiecției vectorului datelor.
- Acesta este un element al hiperplanului modelului de regresie:

$$\hat{Y} = \Phi \hat{\theta} = \hat{\theta}_1 \phi_1 + \hat{\theta}_2 \phi_2 + \dots + \hat{\theta}_{n\theta} \phi_{n\theta} \quad \text{(combinație liniară a coloanelor matricii de regresie liniară)}$$

coeficienți necunoscuți

- Pentru a determina coeficienții necunoscuți, este suficientă exprimarea condiției de ortogonalitate pe hiperplanul modelului de regresie, adică pe fiecare vector care îl generează:

$$\phi_i^T \hat{\varepsilon} = 0 \Leftrightarrow \phi_i^T (Y - \hat{Y}) = 0, \quad \forall i \in \overline{1, n\theta} \Leftrightarrow \hat{\theta}_1 \phi_i^T \phi_1 + \hat{\theta}_2 \phi_i^T \phi_2 + \dots + \hat{\theta}_{n\theta} \phi_i^T \phi_{n\theta} = \phi_i^T Y, \quad \forall i \in \overline{1, n\theta}.$$

- Matricial, sistemul rezultat se exprimă astfel:

$$\begin{bmatrix} \phi_1^T \phi_1 & \phi_1^T \phi_2 & \dots & \phi_1^T \phi_{n\theta} \\ \phi_2^T \phi_1 & \phi_2^T \phi_2 & \dots & \phi_2^T \phi_{n\theta} \\ \vdots & \vdots & \ddots & \vdots \\ \phi_{n\theta}^T \phi_1 & \phi_{n\theta}^T \phi_2 & \dots & \phi_{n\theta}^T \phi_{n\theta} \end{bmatrix} \begin{bmatrix} \hat{\theta}_1 \\ \hat{\theta}_2 \\ \vdots \\ \hat{\theta}_{n\theta} \end{bmatrix} = \begin{bmatrix} \phi_1^T Y \\ \phi_2^T Y \\ \vdots \\ \phi_{n\theta}^T Y \end{bmatrix} \Leftrightarrow \underbrace{\begin{bmatrix} \phi_1^T \\ \phi_2^T \\ \vdots \\ \phi_{n\theta}^T \end{bmatrix}}_{\Phi^T} \underbrace{\begin{bmatrix} \phi_1 & \phi_2 & \dots & \phi_{n\theta} \end{bmatrix}}_{\Phi} \begin{bmatrix} \hat{\theta}_1 \\ \hat{\theta}_2 \\ \vdots \\ \hat{\theta}_{n\theta} \end{bmatrix} = \underbrace{\begin{bmatrix} \phi_1^T \\ \phi_2^T \\ \vdots \\ \phi_{n\theta}^T \end{bmatrix}}_{\Phi^T} Y$$

⚡ Aceste interpretări de natură geometrică sunt valabile în condițiile în care modelele matematice pot fi exprimate în forma de regresie liniară.

$$\hat{\theta} = (\Phi^T \Phi)^{-1} \Phi^T Y$$

# 4 Metode de identificare și validare

## 4.2 Metoda Celor Mai Mici Pătrate

### Teorema fundamentală a MCMMP (modele de regresie liniară)

#### Contextul de lucru

$\mathcal{P}(\theta^*)$

$$y[n] = \varphi^T[n] \theta^* + v[n]$$

perturbație stocastică  
(zgomot de măsură)

$$\forall n \in \mathbb{N}^*$$

$\mathcal{M}(\theta)$

$$y[n] = \varphi^T[n] \theta + \varepsilon[n, \theta]$$

eroarea dintre  
proces și model

$$\forall n \in \mathbb{N}^*$$

Modelul este **conform** cu procesul

$$\varepsilon[n, \theta^*] = v[n]$$

$$\forall n \in \mathbb{N}^*$$

Modelul “perfect” diferă de proces  
numai prin zgomotul de măsură.

Problema constă în minimizarea erorii pătratice globale dintre proces și model pe durata orizontului de măsură, pentru determinarea unei estimări a vectorului parametrilor necunoscuți din date experimentale.

$$\hat{\theta} = \underset{\theta \in \mathbb{R}^{n\theta}}{\operatorname{argmin}} \mathcal{V}(\theta) = \underset{\theta \in \mathbb{R}^{n\theta}}{\operatorname{argmin}} \left\{ \sum_{n=1}^N \varepsilon^2[n, \theta] \right\} = \underset{\theta \in \mathbb{R}^{n\theta}}{\operatorname{argmin}} \left\{ \sum_{n=1}^N (y[n] - \varphi^T[n] \theta)^2 \right\}$$

$$\mathcal{D}_N = \{(\varphi[n], y[n])\}_{n \in 1, N}$$

#### Teorema 1

$$\hat{\theta} = (\Phi^T \Phi)^{-1} \Phi^T Y$$

$$\mathcal{V}(\hat{\theta}) = Y^T Y - Y^T \Phi (\Phi^T \Phi)^{-1} \Phi^T Y$$



Cum pot fi totuși implementate aceste relații?

Prin gruparea convenabilă a factorilor, astfel încât să se opereze cu vectori și matrici având **dimensiunea vectorului parametrilor**.

Relații care pot fi neimplementabile dacă  
dimensiunea orizontului de măsură este prea mare.



$$n\theta < N$$



# 4 Metode de identificare și validare

## 4.2 Metoda Celor Mai Mici Pătrate

### Teorema fundamentală a MCMMP (continuare)



$$\hat{\theta} = (\Phi^T \Phi)^{-1} \Phi^T Y$$

$$\mathcal{V}(\hat{\theta}) = Y^T Y - Y^T \Phi (\Phi^T \Phi)^{-1} \Phi^T Y$$

$$\mathbf{R} \stackrel{\text{def}}{=} \Phi^T \Phi = [\varphi[1] \mid \varphi[2] \mid \cdots \mid \varphi[N]] \begin{bmatrix} \overline{\varphi^T[1]} \\ \overline{\varphi^T[2]} \\ \vdots \\ \overline{\varphi^T[N]} \end{bmatrix} = \sum_{n=1}^N \varphi[n] \varphi^T[n] \in \mathbb{R}^{n\theta \times n\theta}$$

↑  
produsul exterior

$$N\sigma_{N,y}^2 \stackrel{\text{def}}{=} Y^T Y = \sum_{n=1}^N y^2[n]$$

dispersie estimată

### Matricea și vectorul de covarianță a datelor

$$\mathbf{r} \stackrel{\text{def}}{=} \Phi^T Y = [\varphi[1] \mid \varphi[2] \mid \cdots \mid \varphi[N]] \begin{bmatrix} \overline{y[1]} \\ \overline{y[2]} \\ \vdots \\ \overline{y[N]} \end{bmatrix} = \sum_{n=1}^N \varphi[n] y[n] \in \mathbb{R}^{n\theta}$$

$$\mathbf{R}_N \stackrel{\text{def}}{=} \frac{1}{N} \Phi^T \Phi = \frac{1}{N} \sum_{n=1}^N \varphi[n] \varphi^T[n] \cong E\{\varphi[n] \varphi^T[n]\}$$

$$\mathbf{r}_N \stackrel{\text{def}}{=} \frac{1}{N} \Phi^T Y = \frac{1}{N} \sum_{n=1}^N \varphi[n] y[n] \cong E\{\varphi[n] y[n]\}$$

$$E\{\varphi[n] \times y[n]\} = \varphi^T[n] \theta^* + v[n]$$

$$\theta^* = (E\{\varphi[n] \varphi^T[n]\})^{-1} (E\{\varphi[n] y[n]\} - E\{\varphi[n] v[n]\})$$

### Formulele de implementare ale MCMMP

$$\hat{\theta} = \mathbf{R}^{-1} \mathbf{r} = \left( \sum_{n=1}^N \varphi[n] \varphi^T[n] \right)^{-1} \left( \sum_{n=1}^N \varphi[n] y[n] \right)$$

$$\hat{\theta}_N = \mathbf{R}_N^{-1} \mathbf{r}_N = \left( \frac{1}{N} \sum_{n=1}^N \varphi[n] \varphi^T[n] \right)^{-1} \left( \frac{1}{N} \sum_{n=1}^N \varphi[n] y[n] \right)$$

$$\mathcal{V}(\hat{\theta}_N) = N\sigma_{N,y}^2 - \mathbf{r}_N^T \mathbf{R}_N^{-1} \mathbf{r}_N$$

# ④ Metode de identificare și validare

## ④.② Metoda Celor Mai Mici Pătrate

### Teorema fundamentală a MCMMP (continuare)

### Teorema 2 (Teorema fundamentală a MCMMP)

Următoarele 3 ipoteze se consideră verificate:

- matricea  $\Phi$  este perfect deterministă;
- matricea  $R$  (sau  $R_N$ ) este strict pozitiv definită (adică inversabilă) pentru toate dimensiunile orizontului de măsură suficient de mari;
- perturbația  $v$  aparține clasei  $za(0, \lambda^2)$  (adică este un zgomot alb de medie nulă și dispersie necunoscută  $\lambda^2$ ).

MCMMP oferă 3 estimări remarcabile:

$$\hat{\theta}_N = (\Phi^T \Phi)^{-1} \Phi^T Y$$

**vectorul  
parametrilor**

$$\hat{v}[n] \stackrel{\text{def}}{=} y[n] - \phi^T[n] \hat{\theta}_N \quad \forall n \in \mathbb{N}^*$$

**zgomotul  
perturbator**

$$\hat{\lambda}_{\gamma_N}^2 \stackrel{\text{def}}{=} \frac{1}{\gamma_N} \sum_{n=1}^N \hat{v}^2[n] = \frac{1}{\gamma_N} \sum_{n=1}^N (y[n] - \phi^T[n] \hat{\theta}_N)^2$$

**dispersia zgomotului perturbator**  
 $\gamma_N \in \{N - n\theta, N\}$

Acestea verifică următoarele proprietăți:

- Estimația vectorului parametrilor adevărați este **nedeviată**.
- Matricea de auto-covarianță a erorii de estimare pentru vectorul parametrilor adevărați este egală cu:

$$P(\hat{\theta}_N) = \lambda^2 R^{-1} = \lambda^2 (\Phi^T \Phi)^{-1}$$

- Estimația vectorului parametrilor adevărați este **consistentă**.

# 4 Metode de identificare și validare

## 4.2 Metoda Celor Mai Mici Pătrate

### Teorema fundamentală a MCMMP (continuare)

### Teorema 2 (Teorema fundamentală a MCMMP – continuare)

4. Fie  $\Gamma$  clasa estimațiilor nedeviate ale lui  $\theta^*$  care se pot exprima ca transformări liniare deterministe ale vectorului de date de ieșire măsurate  $Y$ . Atunci, estimația vectorului parametrilor adevărați aparține lui  $\Gamma$  și, în plus, face parte dintre cele mai eficiente estimații din această clasă.
5. Ambele estimații ale dispersiei zgomotului alb sunt consistente (deci și asimptotic nedeviate).
6. Pentru  $\gamma_N = N$ , estimația dispersiei zgomotului alb este deviată, dar, pentru  $\gamma_N = N - n\theta$ , ea este nedeviată.

### Demonstrație

- Înainte de a demonstra concluziile teoremei, sunt necesare câteva calcule preliminare.
- Va fi dedusă relația care există între vectorul parametrilor adevărați și cel al parametrilor estimați.

$\stackrel{\text{def}}{V} = [v[1] \ v[2] \ \cdots \ v[N]]^T \in \mathbb{R}^N \rightarrow \text{Vectorul global al perturbațiilor.}$

$\mathcal{P}(\theta^*)$

$$y[n] = \phi^T[n] \theta^* + v[n] \\ \forall n \in \overline{1, N}$$



$$Y = \Phi \theta^* + V$$

$$\hat{\theta}_N = (\Phi^T \Phi)^{-1} \Phi^T Y$$

$$\begin{aligned} \hat{\theta}_N &= (\Phi^T \Phi)^{-1} \Phi^T (\Phi \theta^* + V) = \\ &= \theta^* + (\Phi^T \Phi)^{-1} \Phi^T V \end{aligned}$$