

4 Metode de identificare și validare

4.5 Metoda Celor Mai Mici Pătrate Extinsă (MCMMP-E)

- Discuția care urmează vizează identificarea modelelor de regresie liniară avînd **vectorul regresorilor nemăsurabil**.
- Astfel de modele se regăsesc atît în clasa **ARMAX**, cît și (mai ales) în clasa **RSISO**.

Exemplu

ARMAX[na,nb,nc]

$$\varphi^T[n] = \begin{bmatrix} -y[n-1] - y[n-2] \cdots - y[n-na] & | & u[n-1] u[n-2] \cdots u[n-nb] & | & \dots \\ & & & & \dots e[n-1] e[n-2] \cdots e[n-nc] \end{bmatrix}$$

3 componente, ca și vectorul parametrilor

$$\theta^T = \begin{bmatrix} a_1 & a_2 & \cdots & a_{na} & | & b_1 & b_2 & \cdots & b_{nb} & | & c_1 & c_2 & \cdots & c_{nc} \end{bmatrix}$$

⊗ Ultima componentă nu este măsurabilă.

$\forall n \in \mathbb{N}^*$

- Strategia generală de identificare cu ajutorul **MCMMP-E** constă în două etape:
 - ① Estimarea zgomotului care intervine în componenta nemăsurabilă cu ajutorul unui model avînd vectorul regresorilor complet măsurabil (dar mai puțin precis).
 - ② Determinarea parametrilor originali ai modelului cu ajutorul vectorului regresorilor avînd componenta nemăsurabilă estimată în etapa precedentă.
- În ambele etape este folosită o metodă de identificare din clasa **MCMMP-MVI**, de unde atributul “**Extinsă**”.
- În cazul modelului general **ARMAX**:
 - ① Zgomotul alb este estimat cu ajutorul unui model de tip **ARX** suficient de complex.
 - ② Se aplică din nou **MCMMP**, fie **direct** (folosind vectorul estimat al regresorilor), fie **indirect** (prin determinarea pseudo-soluției unui sistem incompatibil).

4 Metode de identificare și validare

4.5 Metoda Celor Mai Mici Pătrate Extinsă

Cazul modelelor ARMAX

zgomot (eventual) colorat

$\mathcal{P}(\theta^*)$

$$A^*(q^{-1})y[n] = B^*(q^{-1})u[n] + C^*(q^{-1})v[n]$$

$\forall n \in \mathbb{N}^*$

$$y[n] = \phi^T[n]\theta^* + v[n]$$

$\forall n \in \mathbb{N}^*$

polinoame cu parametri adevărați,
avînd gradele na , nb , respectiv nc

$$n\theta = na + nb + nc$$

$$\mathcal{D}_N = \{(u[n], y[n])\}_{n \in \overline{1, N}}$$

date măsurate

Vectorul regresorilor fiind nemăsurabil, se apelează la strategia în două etape care fundamentează MCMMPPE.

① Estimarea zgomotului de proces (alb sau colorat) cu ajutorul unui model de tip ARX suficient de complex.

$$\hat{\theta}_N = \operatorname{argmin}_{\theta \in \mathbb{R}^{n\theta}} \mathcal{V}(\theta) = ?$$

Cum se poate aproxima modelul general ARMAX cu unul de tip ARX?

Prin împărțirea infinită trunchiată a ecuației de proces la polinomul componentei MA.

$$\frac{A^*(q^{-1})}{C^*(q^{-1})} = \sum_{k \geq 0} \alpha_k^* q^{-k} \cong \sum_{k=0}^{n\alpha} \alpha_k^* q^{-k} = \tilde{A}^*(q^{-1})$$

$$\frac{B^*(q^{-1})}{C^*(q^{-1})} = \sum_{k \geq 0} \beta_k^* q^{-k} \cong \sum_{k=0}^{n\beta} \beta_k^* q^{-k} = \tilde{B}^*(q^{-1})$$

indici structurali suficient de mari

$$\min\{n\alpha, n\beta\} \gg \max\{na, nb, nc\}$$

$\tilde{\mathcal{P}}(\tilde{\theta}^*)$

$$\tilde{A}^*(q^{-1})y[n] = \tilde{B}^*(q^{-1})u[n] + v[n] \quad \forall n \in \mathbb{N}^*$$

$$y[n] = \tilde{\phi}^T[n]\tilde{\theta}^* + v[n] \quad \forall n \in \mathbb{N}^*$$

4 Metode de identificare și validare

4.6 Metoda Celor Mai Mici Pătrate Extinsă

Așadar

$$\tilde{\mathcal{P}}(\tilde{\theta}^*) \quad y[n] = \tilde{\phi}^T[n] \tilde{\theta}^* + v[n]$$

(proces ARX aproximant)

$$\forall n \in \mathbb{N}^*$$

$$\begin{aligned} \tilde{\phi}^T[n] &\stackrel{\text{def}}{=} [-y[n-1] - y[n-2] \cdots - y[n-n\alpha] \mid u[n-1] u[n-2] \cdots u[n-n\beta]] \\ \tilde{\theta}^T &\stackrel{\text{def}}{=} [\tilde{a}_1 \tilde{a}_2 \cdots \tilde{a}_{n\alpha} \mid \tilde{b}_1 \tilde{b}_2 \cdots \tilde{b}_{n\beta}] \end{aligned}$$

$$\forall n \in \mathbb{N}^*$$

MCMMP sau MVI

$$\tilde{\theta}_N = \left(\frac{1}{N} \sum_{n=1}^N \tilde{\psi}[n] \tilde{\phi}^T[n] \right)^{-1} \left(\frac{1}{N} \sum_{n=1}^N \tilde{\psi}[n] y[n] \right)$$

notație unificatoare: $\begin{cases} \tilde{\phi}[n] \rightarrow \text{vectorul regresorilor} \\ \tilde{\zeta}[n] \rightarrow \text{vectorul instrumentelor} \end{cases}$

- Modelul aproximant permite estimarea zgomotului perturbator al procesului original:

$$v[n] \cong y[n] - \tilde{\phi}^T[n] \tilde{\theta}_N = \tilde{A}_N(q^{-1}) y[n] - \tilde{B}_N(q^{-1}) u[n] \stackrel{\text{def}}{=} \tilde{\varepsilon}[n, \tilde{\theta}_N]$$

eroare de predicție cu un pas

$$\begin{aligned} \hat{\phi}^T[n] &\stackrel{\text{def}}{=} [-y[n-1] - y[n-2] \cdots - y[n-na] \mid \dots \\ &\quad \dots u[n-1] u[n-2] \cdots u[n-nb] \mid \dots \\ &\quad \dots \tilde{\varepsilon}[n-1, \tilde{\theta}_N] \tilde{\varepsilon}[n-2, \tilde{\theta}_N] \cdots \tilde{\varepsilon}[n-nc, \tilde{\theta}_N]], \quad \forall n \in \mathbb{N}^*. \end{aligned}$$

(diferența dintre datele utile măsurate și cele prognozate folosind modelul de identificare)

👉 Vectorul estimat al regresorilor.

4 Metode de identificare și validare

4.5 Metoda Celor Mai Mici Pătrate Extinsă

- ② Estimarea **directă** a parametrilor modelului **ARMAX** folosind vectorul aproximativ al regresorilor (din etapa precedentă).

MCMMPPE

$$\hat{\theta}_N = \left(\frac{1}{N} \sum_{n=1}^N \hat{\phi}[n] \hat{\phi}^T[n] \right)^{-1} \left(\frac{1}{N} \sum_{n=1}^N \hat{\phi}[n] y[n] \right) \quad (\text{parametri estimați})$$

$$\mathcal{V}(\hat{\theta}_N) = \sum_{n=1}^N \left(y[n] - \hat{\phi}^T[n] \hat{\theta}_N \right)^2 \quad (1/\text{precizie})$$

$$\gamma_N \hat{\lambda}_N^2$$

➡ Dacă perturbația este un zgomot alb cu dispersie necunoscută.

$$\gamma_N \in \{N, N - na - nb - nc\}$$

- ②' Estimarea **indirectă** a parametrilor modelului **ARMAX** folosind parametrii modelului **ARX** aproximant (din etapa precedentă).

$$\begin{cases} \frac{A^*(q^{-1})}{C^*(q^{-1})} = \sum_{k \geq 0} \alpha_k^* q^{-k} \cong \sum_{k=0}^{n\alpha} \alpha_k^* q^{-k} = \tilde{A}^*(q^{-1}) \\ \frac{B^*(q^{-1})}{C^*(q^{-1})} = \sum_{k \geq 0} \beta_k^* q^{-k} \cong \sum_{k=0}^{n\beta} \beta_k^* q^{-k} = \tilde{B}^*(q^{-1}) \end{cases}$$

sugerează

$$\begin{cases} A(q^{-1}) = C(q^{-1}) \tilde{A}(q^{-1}) \\ B(q^{-1}) = C(q^{-1}) \tilde{B}(q^{-1}) \end{cases}$$

Polinoamele necunoscute A, B și C ar trebui să rezulte prin **identificarea coeficienților**.

⊗ Sistemul este însă **incompatibil** (are mai multe ecuații decât necunoscute).



$$\min\{n\alpha, n\beta\} \gg \max\{na, nb, nc\}$$

Ce se poate face?

Se caută o pseudo-soluție, folosind tot **MCMMP**.

$$\tilde{\Phi} \theta = \tilde{\rho}$$

🔥 monică

$$\in \mathbb{R}^{n\alpha + n\beta + 2nc}$$

$$\in \mathbb{R}^{(n\alpha + n\beta + 2nc) \times (na + nb + nc)}$$

$$\begin{cases} \hat{\theta} = (\tilde{\Phi}^T \tilde{\Phi})^{-1} \tilde{\Phi}^T \tilde{\rho} \quad (\text{parametri estimați}) \\ \mathcal{V}(\hat{\theta}) = \tilde{\rho}^T \tilde{Q} \tilde{\rho} \quad (1/\text{precizie}) \end{cases}$$

🔥 Teorema 1

180



4 Metode de identificare și validare

4.5 Metoda Celor Mai Mici Pătrate Extinsă

Cît de precisă este această metodă?

Precizia este **limitată** din cauza a **4 surse de eroare**:

- Trunchierea modelului **ARX** aproximant.
- Estimarea parametrilor modelului **ARX** aproximant.
- Estimarea valorilor perturbației (adică a vectorului regresorilor modelului **ARMAX**).
- Estimarea parametrilor modelului **ARMAX**.

Consistența estimațiilor?


Condițiile de consistență sunt similare celor din
Propoziția 4 (pentru modelul **ARX**):

- modelul **ARX** aproximant este ideal, adică operează cu polinoame infinite (filtre de tip IIR);
- semnalul de intrare este necorelat cu perturbația ($E\{u[n]v[m]\} = 0, \forall n, m \in \mathbb{Z}$);
- semnalul de intrare are un ordin de persistență suficient de mare, astfel încît matricea $E\{\phi[n]\phi^T[n]\}$ să fie inversabilă.

În aplicațiile practice, **MCMMPPE** este utilizată atunci cînd **nu se impune o precizie de estimare superioară** sau **ca metodă auxiliară** capabilă să furnizeze **inițializări** pentru alte metode mai precise.

4 Metode de identificare și validare

4.6 Metoda Minimizării Erorii de Predicție (MMEP)

- Aceasta este **una dintre cele mai generale** metode de identificare fundamentală.
- Ca și **MCMMPE**, ea se adresează modelelor din clasele **ARMAX** și **RSISO** care au vectorul regresorilor nemăsurabil, dar este **mult mai precisă** (și **mai complexă**).
- Strategia generală de identificare cu ajutorul **MMEP** constă (tot) în două etape:
 - ① Inițializarea algoritmului iterativ de la etapa următoare (eventual folosind **MCMMPE**).
 - ② Determinarea iterativă a parametrilor originali ai modelului cu ajutorul unei metode bazate pe TO (de exemplu: **MGN** sau, mai general, **MNR**).
- În acest curs, vor fi utilizate metodele: **MCMMPE** și **MGN**.  Dacă **MGN** este înlocuită de **MNR**

Minimizarea Erorii de Predicție?

Numele provine de la **criteriul de optimizare**, care este exprimat prin **dispersia erorii dintre model și proces pe orizontul de măsură**.

Metoda de Regresie Pseudo-Liniară (**MRPL**)

$$\mathcal{V}_N(\theta) \stackrel{\text{def}}{=} \frac{1}{N} \sum_{n=1}^N \varepsilon^2[n, \theta] \quad \forall \theta \in \mathbb{R}^{n\theta}$$

Așadar

Minimizarea criteriului pătratic revine la **minimizarea dispersiei erorii de predicție pe orizontul de măsură**.

Eroare de predicție (cu un pas)

$$\varepsilon[n, \theta] = y[n] - \phi^T[n] \theta \quad \forall n \in \mathbb{N}^*$$

Și totuși... de unde provine numele de "eroare de predicție"?

valoare prognozată (predictată) folosind modelul de identificare

👉 În cazul modelelor de regresie liniară.


Pentru a genera prin simulare **valoarea curentă** a ieșirii procesului, sunt utilizate **numai date măsurate la momente anterioare celui curent**.

👉 A se vedea cum arată vectorul regresorilor.


4 Metode de identificare și validare

4.6 Metoda Minimizării Erorii de Predicție

Algoritmul generic al Minimizării Erorii de Predicție



MMEP aplicată modelului general de tip ARMAX


$$\mathbf{R}_{N,k} \stackrel{\text{def}}{=} \sum_{n=1}^N \nabla \varepsilon[n, \hat{\boldsymbol{\theta}}_{N,k}] \left[\nabla \varepsilon[n, \hat{\boldsymbol{\theta}}_{N,k}] \right]^T$$

$$\mathbf{r}_{N,k} \stackrel{\text{def}}{=} \sum_{n=1}^N \varepsilon[n, \hat{\boldsymbol{\theta}}_{N,k}] \nabla \varepsilon[n, \hat{\boldsymbol{\theta}}_{N,k}]$$
$$\varepsilon[n, \hat{\boldsymbol{\theta}}_{N,k}] = y[n] + \hat{a}_{1,k}^N y[n-1] + \dots + \hat{a}_{na,k}^N y[n-na] -$$

$$- \hat{b}_{1,k}^N u[n-1] - \dots - \hat{b}_{nb,k}^N u[n-nb] -$$

$$- \hat{c}_{1,k}^N \varepsilon[n-1, \hat{\boldsymbol{\theta}}_{N,k}] - \dots - \hat{c}_{nc,k}^N \varepsilon[n-nc, \hat{\boldsymbol{\theta}}_{N,k}]$$

$$\forall n \in \mathbb{N}$$

🎵 Ecuatie recurentă pentru determinarea erorii de predicție.

$$\varepsilon[n, \hat{\boldsymbol{\theta}}_{N,k}] = u[n] = y[n] = 0 \quad \forall n \leq 0$$

4 Metode de identificare și validare

4.6 Metoda Minimizării Erorii de Predicție

MMEP aplicată modelului general de tip **ARMAX** (continuare)



Dar gradientul?



Nimic nu împiedică **derivarea ecuației** care produce relația recursivă a erorii de predicție.

∇

$$C_{N,k}(q^{-1}) \frac{\partial}{\partial a_i} \varepsilon[n, \hat{\theta}_{N,k}] = y[n-i]$$

$\forall i \in \overline{1, na}$

$$\hat{A}_{N,k}(q^{-1})y[n] = \hat{B}_{N,k}(q^{-1})u[n] + \hat{C}_{N,k}(q^{-1})\varepsilon[n, \hat{\theta}_{N,k}]$$

$\forall n \in \mathbb{N}^*$

$$\frac{\partial}{\partial a_i} \varepsilon[n, \hat{\theta}_{N,k}] = y[n-i] - \hat{c}_{1,k}^N \frac{\partial}{\partial a_i} \varepsilon[n-1, \hat{\theta}_{N,k}] - \dots - \hat{c}_{nc,k}^N \frac{\partial}{\partial a_i} \varepsilon[n-nc, \hat{\theta}_{N,k}]$$

$\forall i \in \overline{1, na}$

$$C_{N,k}(q^{-1}) \frac{\partial}{\partial b_j} \varepsilon[n, \hat{\theta}_{N,k}] = -u[n-j]$$

$\forall j \in \overline{1, nb}$

Ecuatii recurente pentru determinarea componentelor gradientului.

$\forall n \in \mathbb{N}^*$

$$\frac{\partial}{\partial b_j} \varepsilon[n, \hat{\theta}_{N,k}] = -u[n-j] - \hat{c}_{1,k}^N \frac{\partial}{\partial b_j} \varepsilon[n-1, \hat{\theta}_{N,k}] - \dots - \hat{c}_{nc,k}^N \frac{\partial}{\partial b_j} \varepsilon[n-nc, \hat{\theta}_{N,k}]$$

$\forall j \in \overline{1, nb}$

$$C_{N,k}(q^{-1}) \frac{\partial}{\partial c_l} \varepsilon[n, \hat{\theta}_{N,k}] = -\varepsilon[n-l, \hat{\theta}_{N,k}]$$

$\forall l \in \overline{1, nc}$



Inițializare cauzală

$$\nabla \varepsilon[n, \hat{\theta}_{N,k}] = \varepsilon[n, \hat{\theta}_{N,k}] = u[n] = y[n] = 0$$

$\forall n \leq 0$

$\forall l \in \overline{1, nc}$

$$\frac{\partial}{\partial c_l} \varepsilon[n, \hat{\theta}_{N,k}] = -\varepsilon[n-l, \hat{\theta}_{N,k}] - \hat{c}_{1,k}^N \frac{\partial}{\partial c_l} \varepsilon[n-1, \hat{\theta}_{N,k}] - \dots - \hat{c}_{nc,k}^N \frac{\partial}{\partial c_l} \varepsilon[n-nc, \hat{\theta}_{N,k}]$$

4 Metode de identificare și validare

4.6 Metoda Minimizării Erorii de Predicție

MMEP aplicată modelului general de tip **ARMAX** (continuare)

Exemplu

Primele 3 iterații ale relațiilor recursive la pasul curent de aproximare

$k \in \mathbb{N}$

$$\varepsilon[1, \hat{\theta}_{N,k}] = y[1]$$

$$\frac{\partial}{\partial a_i} \varepsilon[1, \hat{\theta}_{N,k}] = 0$$

$$\frac{\partial}{\partial b_j} \varepsilon[1, \hat{\theta}_{N,k}] = 0$$

$$\frac{\partial}{\partial c_l} \varepsilon[1, \hat{\theta}_{N,k}] = 0$$

$n = 1$

$$\begin{aligned} \varepsilon[2, \hat{\theta}_{N,k}] &= y[2] + \hat{a}_{1,k}^N y[1] - \hat{b}_{1,k}^N u[1] - \hat{c}_{1,k}^N \varepsilon[1, \hat{\theta}_{N,k}] = \\ &= y[2] + (\hat{a}_{1,k}^N - \hat{c}_{1,k}^N) y[1] - \hat{b}_{1,k}^N u[1] \end{aligned}$$

$$\frac{\partial}{\partial b_j} \varepsilon[2, \hat{\theta}_{N,k}] = -u[2-j] - \hat{c}_{1,k}^N \frac{\partial}{\partial b_j} \varepsilon[1, \hat{\theta}_{N,k}] = -u[2-j]$$

$$\frac{\partial}{\partial a_i} \varepsilon[2, \hat{\theta}_{N,k}] = y[2-i] - \hat{c}_{1,k}^N \frac{\partial}{\partial a_i} \varepsilon[1, \hat{\theta}_{N,k}] = y[2-i]$$

$$\begin{aligned} \frac{\partial}{\partial c_l} \varepsilon[2, \hat{\theta}_{N,k}] &= -\varepsilon[2-l, \hat{\theta}_{N,k}] - \hat{c}_{1,k}^N \frac{\partial}{\partial c_l} \varepsilon[1, \hat{\theta}_{N,k}] = \\ &= -\varepsilon[2-l, \hat{\theta}_{N,k}] \end{aligned}$$

$n = 2$

$$\begin{aligned} \varepsilon[3, \hat{\theta}_{N,k}] &= y[3] + \hat{a}_{1,k}^N y[2] + \hat{a}_{2,k}^N y[1] - \hat{b}_{1,k}^N u[2] - \hat{b}_{2,k}^N u[1] - \\ &- \hat{c}_{1,k}^N \varepsilon[2, \hat{\theta}_{N,k}] - \hat{c}_{2,k}^N \varepsilon[1, \hat{\theta}_{N,k}] \end{aligned}$$

$$\begin{aligned} \frac{\partial}{\partial b_j} \varepsilon[3, \hat{\theta}_{N,k}] &= -u[3-j] - \hat{c}_{1,k}^N \frac{\partial}{\partial b_j} \varepsilon[2, \hat{\theta}_{N,k}] - \hat{c}_{2,k}^N \frac{\partial}{\partial b_j} \varepsilon[1, \hat{\theta}_{N,k}] = \\ &= -u[3-j] + \hat{c}_{1,k}^N u[2-j] \end{aligned}$$

$$\begin{aligned} \frac{\partial}{\partial c_l} \varepsilon[3, \hat{\theta}_{N,k}] &= -\varepsilon[3-l, \hat{\theta}_{N,k}] - \hat{c}_{1,k}^N \frac{\partial}{\partial c_l} \varepsilon[2, \hat{\theta}_{N,k}] - \hat{c}_{2,k}^N \frac{\partial}{\partial c_l} \varepsilon[1, \hat{\theta}_{N,k}] = \\ &= -\varepsilon[3-l, \hat{\theta}_{N,k}] + \hat{c}_{1,k}^N \varepsilon[2-l, \hat{\theta}_{N,k}] \end{aligned}$$

$$\frac{\partial}{\partial a_i} \varepsilon[3, \hat{\theta}_{N,k}] = y[3-i] - \hat{c}_{1,k}^N \frac{\partial}{\partial a_i} \varepsilon[2, \hat{\theta}_{N,k}] -$$

$$- \hat{c}_{2,k}^N \frac{\partial}{\partial a_i} \varepsilon[1, \hat{\theta}_{N,k}] = y[3-i] - \hat{c}_{1,k}^N y[2-i]$$

$n = 3$

1/precizie

$$\mathcal{V}(\hat{\theta}_{N,k}) = \frac{1}{N} \sum_{n=1}^N \varepsilon^2[n, \hat{\theta}_{N,k}]$$

$$\gamma_N \hat{\lambda}_{N,k}^2 \quad v \in \mathcal{Za}(0, \lambda^2)$$

4 Metode de identificare și validare

4.6 Metoda Minimizării Erorii de Predicție

MMEP aplicată modelului general de tip ARMAX (continuare)

Cît de precisă este această metodă?

Precizia este **ridicată**, dar afectată de **2 surse importante de eroare**:

- Inițializările parametrilor și ale relațiilor recursive prin intermediul cărora se estimează eroarea de predicție și gradientul.
- Aproximarea matricii Hessiene operată în cadrul MGN.

Consistența estimațiilor?

Teorema 5 (Consistența estimației oferite de MMEP pentru modelele ARMAX)

Se consideră că modelul ARMAX[na,nb,nc] verifică următoarele ipoteze:

- modelul este parsimonios: $(A^*, B^*, C^*) = 1$ (polinoamele adevărate sunt coprime);
- intrarea u este un semnal de stimul cu ordin de persistență suficient de mare astfel încît matricea $E\{\varphi[n]\varphi^T[n]\}$ să fie inversabilă;
- perturbația v aparține clasei $za(0, \lambda^2)$ (adică este un zgomot alb de medie nulă și dispersie necunoscută λ^2), nefiind corelată cu semnalul de stimul:

$$E\{u[n]v[m]\} = 0, \quad \forall n, m \in \mathbb{N}^*.$$

Atunci estimațiile oferite de MMEP sunt convergente și consistente.

Mai precis:

$$\lim_{N \rightarrow \infty} \lim_{k \rightarrow \infty} \hat{\theta}_{N,k} = \theta^*$$
$$\lim_{N \rightarrow \infty} \lim_{k \rightarrow \infty} \hat{\lambda}_{N,k}^2 = \lambda^2$$


☞ Metoda funcționează corect și în cazul zgomotelor colorate, dacă se consideră un model separat pentru acestea (de exemplu ARMA).

4 Metode de identificare și validare

4.7 Metode bazate pe Teoria Estimației



Formularea problemei de identificare din perspectiva Teoriei Estimației



$$\stackrel{def}{P(\theta)} = E\{(\theta - \theta^*)(\theta - \theta^*)^T\} \in \mathbb{R}^{n\theta \times n\theta}$$

matricea de auto-covarianță
a erorii de estimare

$$\hat{\theta}_N = \underset{\theta \in \mathcal{S} \subseteq \mathbb{R}^{n\theta}}{\operatorname{argmin}} P(\theta)$$

♣ În sensul pozitiv (semi-)definirii.

⊗ Matricea de auto-covarianță a erorii de estimare este **difficil**, dacă nu **imposibil de evaluat**.

⊗ Chiar dacă ar putea fi evaluată (vezi **Teorema fundamentală a MCMMP**),
ea depinde de paramerii adevărați (necunoscuți).

$$P(\hat{\theta}_N) \stackrel{def}{=} \lambda^2 \left(\sum_{n=1}^N \phi[n] \phi^T[n] \right)^{-1}$$

Și atunci?...

Problema se poate relaxa prin **înlocuirea matricii de auto-covarianță cu alte criterii, corelate (direct sau indirect) cu aceasta.**

$$\mathcal{D} = \{(u[n], y[n])\}_{n \in \overline{1, N}}$$

date măsurate

$$\begin{cases} \hat{\theta}(\mathcal{D}) \\ \hat{\theta}(\bullet) \end{cases}$$

→ Estimație evaluată plecînd de la setul de date măsurate.

→ **Estimator.**

♣ Concept împrumutat și metodelor
din afara domeniului TE.

4 Metode de identificare și validare

4.2 Metode bazate pe Teoria Estimației

Metoda lui Bayes (MB)

- Aceasta este una dintre tehnicile cele mai cunoscute de **predicție a valorilor unei variabile aleatoare, folosind diferite distribuții de probabilitate asociate acestora și istoria valorilor sale.**
- În cadrul IS, variabila aleatoare ce trebuie predictată este **vectorul parametrilor necunoscuți.**
- Densități de probabilitate asociate:

$$p(\theta)$$

→ Densitatea de probabilitate a apariției vectorului θ (necondiționată de setul de date măsurate).

$$p(\mathcal{D})$$

→ Densitatea de probabilitate a obținerii setului de date \mathcal{D} (necondiționată de vectorul parametrilor).

$$p(\theta, \mathcal{D})$$

→ Densitatea de probabilitate a apariției vectorului θ și obținerii setului de date \mathcal{D} în același experiment de identificare.

$$p(\theta | \mathcal{D})$$

→ Densitatea de probabilitate a apariției vectorului θ , condiționată de setul de date \mathcal{D} (adică estimat plecând de la setul de date măsurate).

$$p(\mathcal{D} | \theta)$$

→ Densitatea de probabilitate a obținerii setului de date \mathcal{D} , condiționată de vectorul θ (adică prin simularea folosind modelul de identificare cu vectorul parametrilor).

Problema lui Bayes

$$\hat{\theta}(\mathcal{D}) = \operatorname{argmax}_{\theta \in \mathcal{S} \subseteq \mathbb{R}^{n_\theta}} p(\theta | \mathcal{D})$$

☞ Se caută acel vector de parametri care are probabilitatea maximă de a fi estimat plecând de la setul de date măsurate.