

4 Metode de identificare și validare

4.2 Metode bazate pe Teoria Estimației

Metoda lui Bayes (continuare)

- Se poate arăta (deși dificil) că, în anumite condiții, maximizarea probabilității din cadrul problemei lui Bayes conduce la minimizarea matricii de auto-covarianță a erorii de estimare.

Cum poate fi rezolvată problema lui Bayes?

Folosind o proprietate elementară de Teoria Probabilităților.

$$p(\theta, \mathcal{D}) = p(\mathcal{D} | \theta) p(\theta) = p(\theta | \mathcal{D}) p(\mathcal{D})$$

$$\hat{\theta}(\mathcal{D}) = \operatorname{argmax}_{\theta \in \mathcal{S} \subseteq \mathbb{R}^{n_\theta}} p(\theta | \mathcal{D}) = \operatorname{argmax}_{\theta \in \mathcal{S} \subseteq \mathbb{R}^{n_\theta}} \frac{p(\mathcal{D} | \theta) p(\theta)}{p(\mathcal{D})} = \operatorname{argmax}_{\theta \in \mathcal{S} \subseteq \mathbb{R}^{n_\theta}} p(\mathcal{D} | \theta) p(\theta)$$

Noua problemă se poate rezolva practic după o strategie recursivă.

Probabilitatea de a obține setul măsurat de date nu depinde de parametrii care urmează a fi estimați.

- Dacă ambele densități de probabilitate din produsul ce trebuie maximizat sunt cunoscute, se poate utiliza o tehnică de optimizare (de exemplu, de tipul MNR).

☹ Cunoașterea acestora este însă **dificilă**, dacă nu **imposibilă**.

😊 Este totuși **posibilă** cunoașterea densităților de probabilitate: $p(\mathcal{D} | \theta)$ & $p(\mathcal{D})$


Proprietatea de Teoria Probabilităților poate fi utilizată și pentru a estima recursiv $p(\theta)$, plecând de la o inițializare.

4 Metode de identificare și validare

4.2 Metode bazate pe Teoria Estimației

Metoda lui Bayes (continuare)

Algoritmul lui Bayes



4 Metode de identificare și validare


4.2 Metode bazate pe Teoria Estimației

Metoda lui Bayes (continuare)



$$p_{k+1}(\theta) \stackrel{\text{def}}{=} p_{k+1}(\theta | \mathcal{D}) = \frac{p(\mathcal{D} | \theta) p_k(\theta)}{p(\mathcal{D})} \quad \forall k \in \mathbb{N}^*$$

✦ În același timp, densitatea de probabilitate se grupează tot mai mult în jurul unei valori maxime.



Pe măsură ce procesul iterativ avansează, corelația dintre parametrii estimați și datele măsurate **trebuie să devină tot mai puternică**.

Apariția necondiționată a parametrilor este tot mai puțin probabilă, ei fiind din ce în ce **mai puternic condiționați de datele măsurate**.

- Densitatea de probabilitate a datelor achiziționate **nu depinde de valorile parametrilor necunoscuți**, astfel că relația recursivă se poate simplifica:

$$p_{k+1}(\theta) \stackrel{\text{def}}{=} p_{k+1}(\theta | \mathcal{D}) = p(\mathcal{D} | \theta) p_k(\theta) \quad \forall k \in \mathbb{N}^*$$

- Se poate arăta că acest proces iterativ este **convergent** către soluția problemei lui Bayes.

⊗ Algoritmul lui Bayes **necesită cunoașterea prealabilă** cel puțin a densității de probabilitate a setului de date \mathcal{D} , condiționate de vectorul θ , lucru care s-ar putea dovedi **difficil**.

⊗ **Viteza de convergență** a algoritmului este **în general scăzută**, dacă se pleacă de la o **inițializare uniformă**.

☺ Cu toate acestea, **algoritmul lui Bayes este unul dintre puținii algoritmi implementabili** din cadrul TE.

4 Metode de identificare și validare

1.2 Metode bazate pe Teoria Estimației

Metoda Verosimilității Maxime (MVM)

- Metodă înrudită cu MB, care propune **rezolvarea problemei de identificare în formă completă**, fără a apela la un algoritm recursiv, **pentru anumite tipuri de modele de identificare**.

Ipoteză simplificatoare

Indiferent de procesele furnizoare de date avînd structură fixată și domeniu de stabilitate comun, vectorul parametrilor adevărați poate lua orice valoare din acest domeniu, **cu aceeași probabilitate**.

$$p(\theta) \equiv \text{const.}$$

← Vectorul parametrilor necunoscuți θ este **echiprobabil** pe domeniul de stabilitate.

Problema
verosimilității

$$\hat{\theta}(\mathcal{D}) = \operatorname{argmax}_{\theta \in \mathcal{S} \subseteq \mathbb{R}^{n_\theta}} p(\mathcal{D} | \theta)$$

Verosimilitate

Cum poate fi rezolvată
problema verosimilității
maxime?

În formă completă, dacă
se folosesc **modele de
regresie liniară**.

‡ Datele măsurate nu pot fi obținute prin simulare decât dacă vectorul parametrilor modelului de identificare este **cel mai plauzibil sau verosimil**, adică produce o frecvență maximă de obținere a setului de date măsurate.

Vectorii parametrilor care nu verifică această proprietate sunt declarați **mai puțin verosimili** sau chiar **neverosimili**.

4 Metode de identificare și validare

4.2 Metode bazate pe Teoria Estimației

Metoda Verosimilității Maxime (continuare)

Exemplu Media și varianța – estimații de verosimilitate maximă

$\mathcal{P}(\theta^*)$

$$y[n] = \theta^* + v[n] \quad \leftarrow \text{zgomot alb normal distribuit}$$

$$\forall n \in \mathbb{N}^*$$

Se măsoară valorile unui parametru **în mod direct**.

$$\mathcal{D} = \{y[n]\}_{n \in \overline{1, N}}$$

$$\hat{\theta}(\mathcal{D}) = \operatorname{argmax}_{\theta \in \mathbb{R}} \mathcal{P}(\mathcal{D} | \theta, \lambda^2) = ?$$

$$\hat{\lambda}^2(\mathcal{D}) = \operatorname{argmax}_{\lambda^2 \in \mathbb{R}_+^*} \mathcal{P}(\mathcal{D} | \theta, \lambda^2) = ?$$

$$\mathcal{P}(y[n]) \stackrel{\text{def}}{=} \frac{1}{\sqrt{2\pi\lambda^*}} \exp \left[-\frac{(y[n] - \theta^*)^2}{2(\lambda^*)^2} \right]$$

$$\forall n \in \mathbb{N}^*$$

$\mathcal{M}(\theta)$

$$y[n] = \theta + \varepsilon[n, \theta, \lambda^2]$$

$$\forall n \in \mathbb{N}^*$$

$$\varepsilon[n, \theta^*, (\lambda^*)^2] = v[n]$$

(modelul de identificare corespunzător)

☞ Aceeași dispersie necunoscută.

$$v \in \mathcal{Z}\mathcal{A}(0, (\lambda^*)^2) \cap \mathcal{CN}(0, (\lambda^*)^2)$$

$$\mathcal{P}(v[n]) \stackrel{\text{def}}{=} \frac{1}{\sqrt{2\pi\lambda^*}} \exp \left[-\frac{v^2[n]}{2(\lambda^*)^2} \right]$$

$$\forall n \in \mathbb{N}^*$$

☞ zgomotul afectează direct datele măsurate

$$y \in \mathcal{Z}\mathcal{A}(\theta^*, \sigma_y^2) \cap \mathcal{CN}(\theta^*, (\lambda^*)^2)$$

Exercițiu

$$\sigma_y^2 = (\theta^*)^2 + (\lambda^*)^2$$

$$\mathcal{P}(y[n] | \theta, \lambda^2) \stackrel{\text{def}}{=} \frac{1}{\sqrt{2\pi\lambda}} \exp \left[-\frac{(y[n] - \theta)^2}{2\lambda^2} \right]$$

$$\forall n \in \mathbb{N}^*$$


☞ Verosimilitatea fiecărui eșantion.

4 Metode de identificare și validare

4.2 Metode bazate pe Teoria Estimației

Metoda Verosimilității Maxime (continuare)

Exemplu Media și varianța – estimații de verosimilitate maximă (continuare)


$$p(y[n] | \theta, \lambda^2) \stackrel{\text{def}}{=} \frac{1}{\sqrt{2\pi\lambda}} \exp \left[-\frac{(y[n] - \theta)^2}{2\lambda^2} \right] \quad \forall n \in \mathbb{N}^*$$
$$p(\mathcal{D} | \theta, \lambda^2) = p(y[1], \dots, y[N] | \theta, \lambda^2) = \prod_{n=1}^N p(y[n] | \theta, \lambda^2) \quad \forall n \in \mathbb{N}^*$$

$\forall n \in \mathbb{N}^*$

🔥 **Propoziția 2** (orice proces neautocorelat și Gaussian este independent)

$$p(\mathcal{D} | \theta, \lambda^2) = \frac{1}{(\sqrt{2\pi\lambda})^N} \prod_{n=1}^N \exp \left[-\frac{(y[n] - \theta)^2}{2\lambda^2} \right] = \frac{1}{(\sqrt{2\pi\lambda})^N} \exp \left[-\frac{1}{2\lambda^2} \sum_{n=1}^N (y[n] - \theta)^2 \right]$$

Așadar

Pentru a rezolva problema verosimilității, trebuie determinat punctul de maxim al unei **funcții Gaussiene generalizate**.

$\forall (\theta, \lambda^2) \in \mathbb{R} \times \mathbb{R}_+$

Punctul de maxim este o **rădăcină a gradientului**.

🔥 **Indefinit derivabilă în raport cu oricare dintre cei 2 parametri.**

$F(\theta, \lambda^2)$

⊗ Evaluarea gradientului este **complicată**.

Forma funcției sugerează că extremele ei coincid cu cele ale **logaritmului natural aplicat acestuia**.

$$(\hat{\theta}, \hat{\lambda}^2)(\mathcal{D}) = \operatorname{argmax}_{(\theta, \lambda^2) \in \mathbb{R} \times \mathbb{R}_+} \left\{ \ln \left[p(\mathcal{D} | \theta, \lambda^2) \right] \right\}$$

😊 **Mai simplu de derivat.**

$$F(\theta, \lambda^2) \stackrel{\text{def}}{=} -\frac{N}{2} \ln(2\pi) - \frac{N}{2} \ln \lambda^2 - \frac{1}{2\lambda^2} \sum_{n=1}^N (y[n] - \theta)^2 \quad \forall (\theta, \lambda^2) \in \mathbb{R} \times \mathbb{R}_+$$

4 Metode de identificare și validare

1.2 Metode bazate pe Teoria Estimației

Metoda Verosimilității Maxime (continuare)

Exemplu Media și varianța – estimații de verosimilitate maximă (continuare)

$$F(\theta, \lambda^2) \stackrel{\text{def}}{=} -\frac{N}{2} \ln(2\pi) - \frac{N}{2} \ln \lambda^2 - \frac{1}{2\lambda^2} \sum_{n=1}^N (y[n] - \theta)^2 \quad \forall (\theta, \lambda^2) \in \mathbb{R} \times \mathbb{R}_+^*$$

$$\frac{\partial}{\partial \theta} F(\theta, \lambda^2) = \frac{1}{\lambda^2} \sum_{n=1}^N (y[n] - \theta) = 0$$

$$\frac{\partial}{\partial \lambda^2} F(\theta, \lambda^2) = -\frac{N}{2\lambda^2} + \frac{1}{2\lambda^4} \sum_{n=1}^N (y[n] - \theta)^2 = 0$$

☞ Soluția este unică.

Medie

Varianță

$$\hat{\theta}(\mathcal{D}) = \frac{1}{N} \sum_{n=1}^N y[n] \quad (\text{parametru})$$

$$\hat{\lambda}^2(\mathcal{D}) = \frac{1}{N} \sum_{n=1}^N (y[n] - \hat{\theta}(\mathcal{D}))^2$$

+

(1/precizie)

$$\hat{v}[n] = y[n] - \hat{\theta}(\mathcal{D}) = y[n] - \frac{1}{N} \sum_{n=1}^N y[n]$$

(zgomot perturbator)

În concluzie

Media și varianța sunt cele mai verosimile (plauzibile) estimații.

☞ Estimațiile sunt consistente, datorită IE.

$$\lim_{N \rightarrow \infty} \frac{1}{N} \sum_{n=1}^N y[n] = E\{y[n]\} = E\{\theta^* + v[n]\} \uparrow \theta^*$$

$$v \in \mathcal{Z}\mathcal{A}(0, (\lambda^*)^2)$$

- Nu întâmplător **prima caracterizare statistică** a numeroase procese nedeterminate, chiar dacă este grosieră, constă în **evaluarea mediilor și varianțelor acestora**.

- **Exemplu:** media generală a unui student, calculată după 3 ani de studii, are șanse mici să varieze semnificativ după 4 ani de studii, dacă notele sale sunt grupate în jurul acesteia și șanse mari să varieze sensibil în finalul celor 4 ani, dacă notele sale sunt larg dispersate în jurul acesteia.

4 Metode de identificare și validare

1.2 Metode bazate pe Teoria Estimației

Metoda Verosimilității Maxime (continuare)

Dar în cazul modelelor de regresie liniară?

Se poate demonstra un rezultat remarcabil.



Teorema 6 (MVI și MCMMP)

În contextul modelelor de regresie liniară, următoarele două ipoteze se consideră verificate:

- matricea R (sau R_N) nu este neapărat deterministă, dar este (strict) pozitiv definită (adică inversabilă) pentru toate dimensiunile orizontului de măsură suficient de mari;
- perturbația v aparține clasei $za\left(0, (\lambda^*)^2\right) \cap \mathcal{N}\left(0, (\lambda^*)^2\right)$

(adică este un zgomot alb de medie nulă și dispersie necunoscută, cu distribuție Gaussiană centrată în zero, de varianță egală tot cu dispersia necunoscută).

Atunci estimațiile vectorului parametrilor adevărați și dispersiei zgomotului alb obținute aplicînd MCMMP sunt de verosimilitate maximă.

Demonstrație



Exercițiu

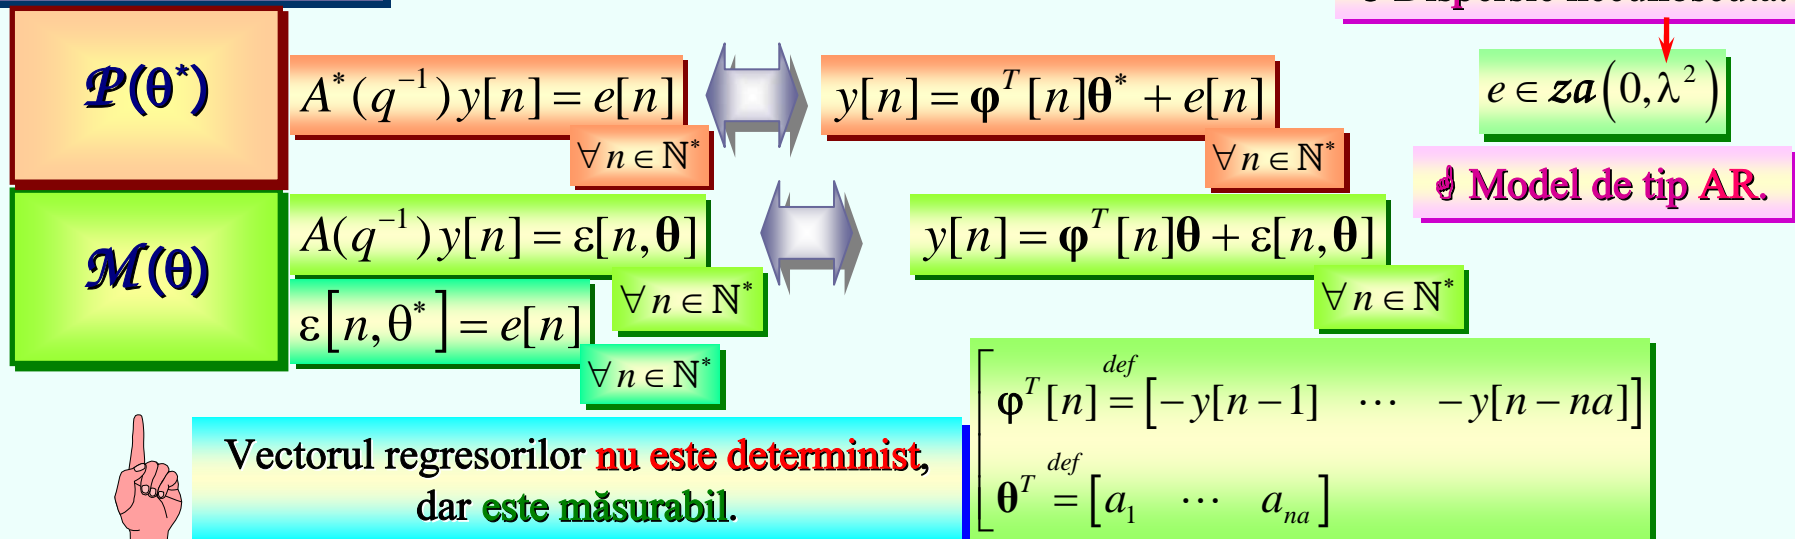
- Chiar dacă **proprietatea de consistență este dificil de verificat** în contextul **Teoremei 6** (matricea regresorilor nu mai este strict deterministă), **cel puțin rămîne proprietatea de verosimilitate maximă**.

☺ Probabilitatea de a obține setul de date măsurate prin simularea cu un model identificat folosind MCMMP este maximă.

4 Metode de identificare și validare

4.1 Identificarea și predicția proceselor auto-regresive

Contextul de lucru



- Modelul autoregresiv (**AR**) conduce la una dintre cele mai atractive și simple abordări pentru **identificarea surselor de perturbații**.
- În pofida preciziei sale limitate, modelul **AR** este adesea preferat în aplicații, în special pentru **metoda extrem de rapidă și eficientă de estimare a parametrilor săi**.
- Modelul concurent al acestuia în aplicații este **ARMA**, care, deși necesită utilizarea **MCMMPPE** sau **MMEP** pentru estimarea parametrilor săi, este tot mai des utilizat, datorită creșterii sensibile a performanțelor tehnicii de calcul automat.

$\mathcal{D} = \{y[n]\}_{n \in \overline{1, N}}$ **date măsurate**

$\hat{\theta} = \underset{\theta \in \mathbb{R}^{na}}{\operatorname{argmin}} \mathcal{V}(\theta) = \underset{\theta \in \mathbb{R}^{na}}{\operatorname{argmin}} \sum_{n=1}^N (y[n] - \phi^T[n]\theta)^2 = ?$

$\hat{\lambda}^2 = \frac{1}{\gamma_N} \mathcal{V}(\hat{\theta})$

$\gamma_N \in \{N - na, N\}$

4 Metode de identificare și validare

4.5 Identificarea și predicția proceselor autoregresive

Performanțele MCMMP în cazul modelului AR



$$\begin{aligned} \varphi^T[n] &\stackrel{\text{def}}{=} [-y[n-1] \quad \cdots \quad -y[n-na]] \\ \theta^T &\stackrel{\text{def}}{=} [a_1 \quad \cdots \quad a_{na}] \end{aligned}$$

$$\hat{\theta} = \mathbf{R}^{-1} \mathbf{r}$$

$$\hat{\lambda}^2 = \frac{1}{\gamma_N} \mathcal{V}(\hat{\theta})$$

$$\gamma_N \in \{N-na, N\}$$

Exercițiu

- Estimațiile oferite de **MCMMP** sunt **consistente**, chiar dacă vectorul regresorilor nu este perfect determinist.

$$\mathbf{R} \stackrel{\text{def}}{=} \sum_{n=1}^N \varphi[n] \varphi^T[n] = \left[\sum_{n=\max\{i,j\}+1}^N y[n-i] y[n-j] \right]_{i,j \in \overline{1,na}}$$

$$\mathbf{r} \stackrel{\text{def}}{=} \sum_{n=1}^N \varphi[n] y[n] = - \left[\sum_{n=i+1}^N y[n] y[n-i] \right]_{i \in \overline{1,na}}$$

♠ Simetrică, dar nu neapărat de tip Toeplitz (elementele de pe diagonala principală sunt diferite).



Pentru inversare, se folosește **Algoritmul (clasic al) lui Gauss**.

Efortul de calcul

Înmulțiri

Adunări

Construcția matricii **R**

$$\left[\frac{na(na+1)(3N-2na-1)}{6} \right]_{\times}$$

$$\left[\frac{na(na+1)(3N-2na-4)}{6} \right]_{+}$$

Construcția vectorului **r**

$$[N-na]_{\times}$$

$$[N-na-1]_{+}$$

Inversarea matricii **R**

$$\left[\frac{na(3na^2-3na+2)}{2} \right]_{\times}$$

$$\left[\frac{3na(na-1)^2}{2} \right]_{+}$$

Estimarea parametrilor ($\mathbf{R}^{-1} \mathbf{r}$)

$$[na^2]_{\times}$$

$$[na(na-1)]_{+}$$

Total

$$O_{\text{MCMMP}} \sim \left[\frac{na[7na^2 + 3na(N-2) + 3N + 5]}{6} \right]_{\times} + \left[\frac{na[7na^2 + 3na(N-6) + 3N - 1]}{6} \right]_{+}$$

4 Metode de identificare și validare

4.6 Identificarea și predicția proceselor autoregresive

⊗ Efortul de calcul al MCMMP cu modelul AR **este susținut**, deoarece atât numărul datelor măsurate cât și numărul de parametri au valori mari (pentru a asigura o precizie suficientă).



Obiectiv

Reducerea efortului de calcul prin metode alternative de identificare.

Metoda Yule-Walker-Wiener

Algoritmul Levinson-Durbin

Metoda Yule-Walker-Wiener (MYWW)



Ideea lui G.U. Yule & G. Walker
(anii '30)

Estimarea parametrilor necunoscuți și a dispersiei zgomotului alb se poate realiza apelînd la **secvența de auto-covarianță a ieșirii**.

- Se aplică două operații succesive asupra ecuației procesului:

E

$$y[n-k] \times \quad \textcircled{1} \quad \forall k \in \mathbb{N}$$

$$A^*(q^{-1})y[n] = e[n] \quad \textcircled{2} \quad \forall n \in \mathbb{N}^*$$



$$r_y[k] + a_1^* r_y[k-1] + \dots + a_{na}^* r_y[k-na] = r_{e,y}[k] \quad \forall k \in \mathbb{N}$$

ecuație autoregresivă deterministă

?

Împărțire infinită.



$$y[n] = e[n] + \sum_{m \geq 1} \alpha_m^* e[n-m] \quad \forall n \in \mathbb{N}^*$$

$$y[n] = \frac{1}{A^*(q^{-1})} e[n] \quad \forall n \in \mathbb{N}^*$$


$$A^*(q^{-1})y[n] = e[n] \quad \forall n \in \mathbb{N}^*$$

$$r_{e,y}[k] \stackrel{\text{def}}{=} E\{e[n]y[n-k]\} = \lambda^2 \delta_0[k] + \lambda^2 \sum_{m \geq 1} \alpha_m^* \delta_0[k+m] = \lambda^2 \delta_0[k] \quad \forall k \in \mathbb{N}$$

4 Metode de identificare și validare

4.5 Identificarea și predicția proceselor autoregresive

Metoda Yule-Walker-Wiener (continuare)


$$r_{e,y}[k] \stackrel{\text{def}}{=} E\{e[n]y[n-k]\} = \lambda^2 \delta_0[k] + \lambda^2 \sum_{m \geq 1} \alpha_m^* \delta_0[k+m] = \lambda^2 \delta_0[k] \quad \forall k \in \mathbb{N}$$

Ecuatiile Yule-Walker-Wiener

$$r_y[k] + a_1^* r_y[k-1] + \dots + a_{na}^* r_y[k-na] = \lambda^2 \delta_0[k] \quad \forall k \in \mathbb{N}$$

(similare ecuațiilor Wiener-Hopf)

⚡ Ieșirea nu este corelată cu valori viitoare ale zgomotului.

⊗ Sistemul este **inoperant**, deoarece are un **număr infinit de ecuații** și apelează la **secvența ideală de auto-covarianță a ieșirii**.

Ce se poate face?

Se renunță la **sistemul ideal** (care ar conduce la determinarea exactă a parametrilor adevărați) și se înlocuiește cu un **sistem practic, compatibil**.

$$r_y[0] + a_1^* r_y[1] + \dots + a_{na}^* r_y[na] - \lambda^2 = 0$$

$$r_y[1] + a_1^* r_y[0] + \dots + a_{na}^* r_y[na-1] = 0$$

$$r_y[2] + a_1^* r_y[1] + \dots + a_{na}^* r_y[na-2] = 0$$

⋮

$$r_y[na] + a_1^* r_y[na-1] + \dots + a_{na}^* r_y[0] = 0$$

$$\begin{bmatrix} a_1^* r_y[1] + \dots + a_{na}^* r_y[na] - \lambda^2 \\ r_y[0] & r_y[1] & \dots & r_y[na-1] \\ r_y[1] & r_y[0] & \dots & r_y[na-2] \\ \vdots & \vdots & \ddots & \vdots \\ r_y[na-1] & r_y[na-2] & \dots & r_y[0] \end{bmatrix} \begin{bmatrix} a_1^* \\ a_2^* \\ \vdots \\ a_{na}^* \end{bmatrix} = - \begin{bmatrix} r_y[0] \\ r_y[1] \\ r_y[2] \\ \vdots \\ r_y[na] \end{bmatrix}$$

r

⚡ **(na+1) ecuații.**

Sistemul Yule-Walker-Wiener

R

4 Metode de identificare și validare

4.5 Identificarea și predicția proceselor autoregresive

Metoda Yule-Walker-Wiener (continuare)



$$\begin{cases} a_1^* r_y[1] + \dots + a_{na}^* r_y[na] - \lambda^2 = -r_y[0] \\ \begin{bmatrix} r_y[0] & r_y[1] & \dots & r_y[na-1] \\ r_y[1] & r_y[0] & \dots & r_y[na-2] \\ \vdots & \vdots & \ddots & \vdots \\ r_y[na-1] & r_y[na-2] & \dots & r_y[0] \end{bmatrix} \begin{bmatrix} a_1^* \\ a_2^* \\ \vdots \\ a_{na}^* \end{bmatrix} = - \begin{bmatrix} r_y[1] \\ r_y[2] \\ \vdots \\ r_y[na] \end{bmatrix} \end{cases}$$

Soluția teoretică

$$\begin{cases} \theta^* = \mathbf{R}^{-1} \mathbf{r} \\ \lambda^2 = r_y[0] - \mathbf{r}^T \mathbf{R}^{-1} \mathbf{r} \end{cases}$$

Soluția practică

$$\begin{cases} \hat{\theta}_N = \mathbf{R}_N^{-1} \mathbf{r}_N \\ \hat{\lambda}_N^2 = r_y^N[0] - \mathbf{r}_N^T \mathbf{R}_N^{-1} \mathbf{r}_N \end{cases}$$

$$\mathbf{R}_N = \begin{bmatrix} r_y^N[0] & r_y^N[1] & \dots & r_y^N[na-1] \\ r_y^N[1] & r_y^N[0] & \dots & r_y^N[na-2] \\ \vdots & \vdots & \ddots & \vdots \\ r_y^N[na-1] & r_y^N[na-2] & \dots & r_y^N[0] \end{bmatrix}$$

Simetrică și de tip Toeplitz.

$$\mathbf{r}_N = \begin{bmatrix} r_y^N[1] \\ r_y^N[2] \\ \vdots \\ r_y^N[na] \end{bmatrix}$$

Vectorul estimat al parametrilor este de regulă **bine definit**, dar **estimația dispersiei zgomotului alb poate fi negativă**, din cauza **erorilor numerice**.

Efortul de calcul

Înmulțiri

Adunări

Efortul de calcul a scăzut.

Exemplu

$$N = 1000 \quad na = 10$$

$$O_{MCMMP} \sim [56075]_{\times} + [55865]_{+}$$

$$O_{MYWW} \sim [11505]_{\times} + [11340]_{+}$$

Total

$$O_{MYWW} \sim \left[\frac{na(3na^2 + 2N + 1)}{2} \right]_{\times} + \left[\frac{na(3na^2 - 3na + 2N - 2)}{2} \right]_{+}$$