

# ② Modele de identificare

## ②.① Modele parametrice

### Clasa ARMAX

#### Modele particulare uzuale

**ARX[na,nb,<nk>]** → Auto-Regresiv, cu control eXogen

$$\begin{cases} A(q^{-1})y[n] = B(q^{-1})u[n] + e[n] \\ E\{e[n]e[m]\} = \lambda^2 \delta_0[n-m] \end{cases} \quad \forall n, m \in \mathbb{N}$$

$$C(q^{-1}) = 1$$

- Utilizat în special în **comanda numerică a proceselor** și/sau **reglarea automată**.
- Deși nu atât de precis ca alte modele, el este adesea preferat pentru **simplitate** și pentru faptul că **nu necesită metode de identificare complicate**.

- În plus, modelul poate fi folosit și în aplicații de timp real, beneficiind de **metode de identificare adaptive extrem de eficiente**.

**AR[na]** → Auto-Regresiv

$$\begin{cases} A(q^{-1})y[n] = e[n] \\ E\{e[n]e[m]\} = \lambda^2 \delta_0[n-m] \end{cases} \quad \forall n, m \in \mathbb{N}$$

$$B(q^{-1}) = 0 \quad C(q^{-1}) = 1$$

- Utilizat în special în **predicția optimală a datelor** (fiind un **model de zgomot** și nu de date utile), în aplicații de **predicție a seriilor de timp**, de **estimare spectrală**, de **compresie a datelor**, de **prelucrare a semnalului vocal**, de **urmărire a țintelor mobile**, etc.

- În pofida preciziei sale modeste, este utilizat în atât de multe și diverse aplicații, datorită **manierei recursive în care se pot determina parametrii săi**, chiar și atunci când nu este implementat în timp real.

**Algoritmul Levinson-Durbin**

(care va fi prezentat și în acest curs)

# ② Modele de identificare

## ②.① Modele parametrice

### Clasa ARMAX

#### Modele particulare uzuale (continuare)

**MA[nc]** → Medie Alunecătoare

$$\begin{cases} y[n] = C(q^{-1})e[n] \\ E\{e[n]e[m]\} = \lambda^2 \delta_0[n-m] \end{cases} \quad \forall n, m \in \mathbb{N}$$
$$A(q^{-1}) = 1 \quad B(q^{-1}) = 0$$

- Model care se referă tot la perturbații.
- **Utilitate redusă**, din cauza **preciziei extrem de scăzute** sau a **numărului mare de parametri necesari** pentru a asigura o precizie satisfăcătoare.

**ARMA[na,nc]** → Auto-Regresiv, de Medie Alunecătoare

$$\begin{cases} A(q^{-1})y[n] = C(q^{-1})e[n] \\ E\{e[n]e[m]\} = \lambda^2 \delta_0[n-m] \end{cases} \quad \forall n, m \in \mathbb{N}$$
$$B(q^{-1}) = 0$$


- Model de perturbații mai precis, bazat pe un filtru care dispune atât de **poli**, cât și de **zerouri**.
- Masiv integrat în aplicații abia în anii '90, datorită nivelului tehnologic care a permis implementarea acestora în variante eficiente.

**OE[na,nb,<nk>]** → Output Erroare (eroare de ieșire)

$$\begin{cases} A(q^{-1})y[n] = B(q^{-1})u[n] + A(q^{-1})e[n] \\ E\{e[n]e[m]\} = \lambda^2 \delta_0[n-m] \end{cases} \quad \forall n, m \in \mathbb{N}$$
$$A(q^{-1}) = C(q^{-1})$$

date măsurate

date simulate



- Acest model este mai precis decât modelul **ARX**, dar metodele pentru determinarea parametrilor săi **sunt mult mai complexe**.

# ② Modele de identificare

## ②.① Modele parametrice

### Clasa ARMAX

#### Modele particulare uzuale (continuare)

#### FIR[nb,<nk>] → Finite Impulse Response

(cu răspuns finit la impuls / secvență pondere de durată finită)

$$\begin{cases} y[n] = B(q^{-1})u[n] + e[n] \\ E\{e[n]e[m]\} = \lambda^2 \delta_0[n-m] \end{cases} \quad \forall n, m \in \mathbb{N}$$
$$A(q^{-1}) = 1 \quad C(q^{-1}) = 1$$

$$y[n] = \sum_{k=0}^{nb-1} h[k] (q^{-nk} u)[n-k] + e[n] \quad \forall n \in \mathbb{N}$$

$$y[n] = \underbrace{b_1}_{h[0]} u[n-nk] + \underbrace{b_2}_{h[1]} u[n-nk-1] + \dots + \underbrace{b_{nb}}_{h[nb-1]} u[n-nk-nb+1] + e[n] \quad \forall n \in \mathbb{N}$$

- Precizia modelului este redusă, dar el este adesea utilizat pentru a detecta **ordinul minim de persistență** al intrării necesar pentru obținerea de **date corecte și consistente** (cu ajutorul **ecuației Wiener-Hopf**).
- Modelele din clasa **ARMAX** se pot exprima și cu ajutorul secvențelor pondere (prin **tehnica împărțirii infinite**).

⚡ Deși modelul **ARX** este de tip **IIR**, el nu necesită decât un număr finit de parametri.

$$H(q^{-1}) = \frac{B(q^{-1})}{A(q^{-1})} = \sum_{n \geq 0} h[n] q^{-n}$$

$$G(q^{-1}) = \frac{C(q^{-1})}{A(q^{-1})} = \sum_{n \geq 0} g[n] q^{-n}$$

- Acestea pot fi de tip:

**FIR**

→ **Finite Impulse Response**  
(cu răspuns finit la impuls)

**IIR**

→ **Infinite Impulse Response**  
(cu răspuns infinit la impuls)

# ② Modele de identificare

## ②.① Modele parametrice

### Clase uzuale de modele liniare

ARMAX

RSISO

De stare

#### Clasa RSISO

#### Modele de tip SISO Rationale

RSISO[na,nb,nc,nd,nf,<nk>]

indici  
structurali

întârziere  
intrinsecă

#### Reprezentare sistemică

Filtru de zgomot

$G \equiv C/(AD)$

Filtru de sistem

$H \equiv B/(AF)$

$v$

$y$

$$\begin{cases} A(q^{-1})y[n] = \frac{B(q^{-1})}{F(q^{-1})}u[n] + \frac{C(q^{-1})}{D(q^{-1})}e[n] \\ E\{e[n]e[m]\} = \lambda^2 \delta_0[n-m] \end{cases} \quad \forall n, m \in \mathbb{N}$$

$$A(q^{-1}) = 1 + a_1 q^{-1} + \dots + a_{na} q^{-na}$$

$$B(q^{-1}) = (b_1 q^{-1} + \dots + b_{nb} q^{-nb}) q^{1-nk}$$

$$C(q^{-1}) = 1 + c_1 q^{-1} + \dots + c_{nc} q^{-nc}$$

polinoame

+

$$D(q^{-1}) = 1 + d_1 q^{-1} + \dots + d_{nd} q^{-nd}$$

$$F(q^{-1}) = 1 + f_1 q^{-1} + \dots + f_{nf} q^{-nf}$$

polinoame

coprime

$$(D, F) = 1$$

(cmmdc)

$$H(q^{-1}) \stackrel{\text{def}}{=} \frac{B(q^{-1})}{A(q^{-1})F(q^{-1})}$$

$$G(q^{-1}) \stackrel{\text{def}}{=} \frac{C(q^{-1})}{A(q^{-1})D(q^{-1})}$$

- Se elimină restricția impusă în cadrul clasei ARMAX ca ambele filtre (de sistem și de zgomot) să aibă aceiași poli.

Pot exista, însă, poli comuni.


# ② Modele de identificare

## ②.① Modele parametrice

### Clasa RSISO

#### Modele particulare uzuale

**ARMAX[na,nb,nc,<nk>]**



**RSISO[na,nb,nc,0,0,<nk>]**

$$D(q^{-1}) = 1 \quad F(q^{-1}) = 1$$

✦ Clasa **RSISO** include clasa **ARMAX**, fiind mai generală (bogată) decât aceasta.

Modelele clasei **ARMAX** sunt și modele ale clasei **RSISO**.

- În aplicații sunt însă utilizate și modele de tip **RSISO** care nu fac parte din clasa **ARMAX**.

**FIFN[nb,nc,nd,nf,<nk>]**

→ **Filtered Input Filtered Noise**  
(intrare și zgomot filtrate independent)

**BJ[nb,nc,nd,nf,<nk>]**

→ **Box Jenkins** (denumire echivalentă)

$$\begin{cases} y[n] = \frac{B(q^{-1})}{F(q^{-1})} u[n] + \frac{C(q^{-1})}{D(q^{-1})} e[n] \\ E\{e[n]e[m]\} = \lambda^2 \delta_0[n-m] \end{cases} \quad \forall n, m \in \mathbb{N}$$

$$A(q^{-1}) = 1$$

- Filtrul de sistem și filtrul de zgomot **nu au poli comuni**, fapt care justifică prima denumire a modelului.
- Decuplarea dintre partea utilă și cea parazită este necesară în aplicațiile unde sursa de zgomot este **independentă** de proces.

- În mod normal, acest model de identificare ar fi cel mai recomandat în majoritatea aplicațiilor, dacă implementarea sa nu ar fi atât de dificilă, din cauza complexității ridicate.

# ② Modele de identificare

## ②.① Modele parametrice

### Clase uzuale de modele liniare

ARMAX

RSISO

De stare

### Clasa modelelor de stare

$$\begin{cases} \mathbf{x}[n+1] \equiv \mathbf{A}(\boldsymbol{\theta})\mathbf{x}[n] + \mathbf{B}(\boldsymbol{\theta})\mathbf{u}[n] + \mathbf{E}(\boldsymbol{\theta})\mathbf{w}[n] \\ \mathbf{y}[n] \equiv \mathbf{C}(\boldsymbol{\theta})\mathbf{x}[n] + \mathbf{F}(\boldsymbol{\theta})\mathbf{e}[n] \\ E\{\mathbf{e}[n]\mathbf{e}^T[m]\} = \boldsymbol{\Lambda}_e(\boldsymbol{\theta})\delta_0[n-m] \\ E\{\mathbf{w}[n]\mathbf{w}^T[m]\} = \boldsymbol{\Lambda}_w(\boldsymbol{\theta})\delta_0[n-m] \\ E\{\mathbf{e}[n]\mathbf{w}^T[m]\} = \boldsymbol{\Lambda}_{e,w}(\boldsymbol{\theta})\delta_0[n-m] \end{cases}$$

$\forall n, m \in \mathbb{N}$

- **Vectorul parametrilor necunoscuți** include **coeficienții matricilor** implicate în ecuațiile modelului.
- Rareori zgomotul intern ( $w$ ) și cel extern ( $e$ ) apar împreună într-un model de stare.
- În general **modelele cu două surse de zgomot sunt evitate**, încercându-se **echivalarea** lor cu ajutorul unor **modele avînd o singură sursă de zgomot**.

- Dacă este totuși necesară prezența ambelor zgomote, se presupune că ele sunt **necorelate**.
- **Complexitatea** modelelor de stare este, în general, **ridicată**.

$$\boldsymbol{\Lambda}_{e,w}(\boldsymbol{\theta}) \equiv \mathbf{0}$$

Este acesta un caz particular al modelului general de identificare?



TS

$$\overset{def}{H}(q^{-1}, \boldsymbol{\theta}) = \mathbf{C}(\boldsymbol{\theta})(q\mathbf{I} - \mathbf{A}(\boldsymbol{\theta}))^{-1}\mathbf{B}(\boldsymbol{\theta})$$

$$\mathbf{G}(q^{-1}, \boldsymbol{\theta})$$

Factorizare spectrală +  
Predicție de stare prin filtrare Kalman



# 2 Modele de identificare

## 2.1 Modele parametrice

### Forma de regresie liniară

$$y[n] = \varphi^T[n] \theta + e[n]$$

$\forall n \in \mathbb{N}^*$

☞ Ieșirea depinde liniar de vectorul parametrilor necunoscuți.

Vectorul regresorilor

### ARMAX[na,nb,nc]

Format din date măsurate și, eventual, estimate.

$$\varphi^T[n] \stackrel{\text{def}}{=} \begin{bmatrix} -y[n-1] & -y[n-2] & \dots & -y[n-na] & | & u[n-1] & u[n-2] & \dots & u[n-nb] & | & \dots & e[n-1] & e[n-2] & \dots & e[n-nc] \end{bmatrix}$$

3 componente, ca și vectorul parametrilor

$$\theta^T \stackrel{\text{def}}{=} \begin{bmatrix} a_1 & a_2 & \dots & a_{na} & | & b_1 & b_2 & \dots & b_{nb} & | & c_1 & c_2 & \dots & c_{nc} \end{bmatrix}$$

☞ Ultima componentă nu este măsurabilă.

$\forall n \in \mathbb{N}^*$

### Exercițiu

- Să se indice toate modelele din clasa **ARMAX** pentru care vectorul regresorilor conține numai componente măsurabile.

Dar poate fi **estimată**, fapt care **complică metoda de identificare** și **reduce precizia modelului**.

### Stabilitatea modelelor parametrice raționale

- Testarea stabilității revine adesea la verificarea proprietății unui polinom de a avea zerourile în interiorul discului unitar din planul complex.

$$A(z^{-1}) = 1 + a_{M,1}z^{-1} + \dots + a_{M,M}z^{-M} = z^{-M} (z^M + a_{M,1}z^{M-1} + \dots + a_{M,M})$$

- Acest lucru se poate realiza cu ajutorul **Criteriului de stabilitate Schür-Cohn**.

### Polinomul reciproc

$$\tilde{A}(z^{-1}) \stackrel{\text{def}}{=} z^{-M} A(z^+1) = z^{-M} + a_{M,1}z^{1-M} + \dots + a_{M,M}$$

Coeficient de reflexie

$$\stackrel{\text{def}}{k_M} = a_{M,M}$$

# 2 Modele de identificare

## 2.1 Modele parametrice

### Criteriul de stabilitate Schür-Cohn

(Sisteme discrete)

Date de intrare

$$A(z^{-1}) = 1 + a_{M,1}z^{-1} + \dots + a_{M,M}z^{-M} \quad (\text{coeficienții polinomului})$$

Inițializare

$$m = M \quad (\text{primul indice})$$

$$k_M = a_{M,M} \quad (\text{primul coeficient de reflexie})$$

$$A_M(z^{-1}) = A(z^{-1}) \quad (\text{primul polinom furnizor de coeficient de reflexie})$$

Bucă iterativă

Cît timp

$$|k_m| < 1 \quad \& \quad m > 0$$

① Dacă  $m > 1$ 

a. Se evaluează polinomul următor, care folosește atât polinomul curent, cât și polinomul reciproc asociat:

$$A_{m-1}(z^{-1}) = \frac{A_m(z^{-1}) - k_m \tilde{A}_m(z^{-1})}{1 - k_m^2} = a_{m-1,0} + a_{m-1,1}z^{-1} + \dots + a_{m-1,m-1}z^{1-m}$$



$$a_{m-1,0} = 1$$

b. Se extrage coeficientul următor de reflexie:

$$k_{m-1} = a_{m-1,m-1}$$

② Se decrementează indicele curent:

$$m \leftarrow m - 1$$

Test final

$$m > 0 \Rightarrow |k_m| \geq 1 \Rightarrow \text{⊗ Polinomul este instabil.}$$

$$m = 0 \Rightarrow \{ |k_i| \}_{i \in \overline{1, M}} \subset [0, 1) \Rightarrow \text{☺ Polinomul este stabil.}$$

☞ Toți coeficienții de reflexie se situează în discul unitar.