

# 4 Metode de identificare și validare

## 4.2 Metoda Celor Mai Mici Pătrate

### Teorema fundamentală a MCMMP (continuare)

#### Demonstrație (Teorema 2)

- În continuare, va fi exprimată estimția vectorului perturbației, în vederea determinării unei expresii adecvate și pentru dispersia estimată a zgomotului alb.

$\hat{\mathbf{V}} \stackrel{\text{def}}{=} [\hat{v}[1] \ \hat{v}[2] \ \dots \ \hat{v}[N]]^T \in \mathbb{R}^N \rightarrow$  Vectorul global estimat al perturbațiilor.

$$\hat{\mathbf{V}} = \mathbf{Y} - \Phi \hat{\boldsymbol{\theta}} = \mathbf{Y} - \Phi (\Phi^T \Phi)^{-1} \Phi^T \mathbf{Y} = \mathbf{QY}$$

Vectorul perturbației se poate estima proiectând vectorul datelor de ieșire pe hiperplanul parazit.

- Operatorul de deparazitare fiind ortogonal pe cel reprezentat de matricea regresorilor, estimția perturbației se poate obține prin proiecția perturbației necunoscute pe hiperplanul parazit.

$$\hat{\mathbf{V}} = \mathbf{QY} = \mathbf{Q}(\Phi \boldsymbol{\theta}^* + \mathbf{V}) = \mathbf{QV}$$

$$\mathbf{Y} = \Phi \boldsymbol{\theta}^* + \mathbf{V}$$

- Rezultă imediat că:  $\hat{\lambda}_{\gamma_N}^2 = \frac{1}{\gamma_N} \hat{\mathbf{V}}^T \hat{\mathbf{V}} = \frac{1}{\gamma_N} \mathbf{V}^T \mathbf{Q}^T \mathbf{QV} = \frac{1}{\gamma_N} \mathbf{V}^T \mathbf{Q}^2 \mathbf{V} = \frac{1}{\gamma_N} \mathbf{V}^T \mathbf{QV}$

(datorită proprietăților operatorului  $\mathbf{Q}$ )

- Acum, se pot demonstra concluziile teoremei.

#### 1. Nedevierea estimărilor parametrilor necunoscuți

$$E\{\hat{\boldsymbol{\theta}}_N\} = \boldsymbol{\theta}^* + E\left\{(\Phi^T \Phi)^{-1} \Phi^T \mathbf{V}\right\} = \boldsymbol{\theta}^* + (\Phi^T \Phi)^{-1} \Phi^T E\{\mathbf{V}\} = \boldsymbol{\theta}^*.$$

$$\hat{\boldsymbol{\theta}}_N = \boldsymbol{\theta}^* + (\Phi^T \Phi)^{-1} \Phi^T \mathbf{V}$$

a.

c.

# 4 Metode de identificare și validare

## 4.2 Metoda Celor Mai Mici Pătrate

### Teorema fundamentală a MCMMP (continuare)

#### Demonstrație (Teorema 2)

#### 2. Matricea de auto-covarianță a erorii de estimare

$$\begin{aligned} P(\hat{\theta}_N) &\stackrel{\text{def}}{=} E\left\{(\hat{\theta}_N - \theta^*)(\hat{\theta}_N - \theta^*)^T\right\} \stackrel{\text{a.}}{=} E\left\{(\Phi^T \Phi)^{-1} \Phi^T \mathbf{V} \mathbf{V}^T \Phi (\Phi^T \Phi)^{-1}\right\} \stackrel{\text{c.}}{=} \\ &\quad \hat{\theta}_N = \theta^* + (\Phi^T \Phi)^{-1} \Phi^T \mathbf{V} \\ &= (\Phi^T \Phi)^{-1} \Phi^T \underbrace{E\{\mathbf{V} \mathbf{V}^T\}}_{\lambda^2 \mathbf{I}_N} \Phi (\Phi^T \Phi)^{-1} = \lambda^2 (\Phi^T \Phi)^{-1} \cancel{(\Phi^T \Phi)} \cancel{(\Phi^T \Phi)^{-1}} = \lambda^2 (\Phi^T \Phi)^{-1}. \end{aligned}$$

#### 3. Consistența estimațiilor parametrilor necunoscuți

$$\begin{aligned} \lim_{N \rightarrow \infty} \hat{\theta}_N &\stackrel{\text{a.}}{=} \theta^* + \lim_{N \rightarrow \infty} \left\{ \left( \frac{1}{N} \sum_{n=1}^N \varphi[n] \varphi^T[n] \right)^{-1} \left( \frac{1}{N} \sum_{n=1}^N \varphi[n] v[n] \right) \right\} \stackrel{\text{a. \& b.}}{=} \theta^* + \langle \varphi \varphi^T \rangle^{-1} E\{\varphi[n] v[n]\} \stackrel{\text{a.}}{=} \\ &\quad \hat{\theta}_N = \theta^* + (\Phi^T \Phi)^{-1} \Phi^T \mathbf{V} \\ &= \theta^* + \langle \varphi \varphi^T \rangle^{-1} \varphi[n] \cancel{E\{v[n]\}} \stackrel{\text{c.}}{=} \theta^*. \end{aligned}$$

**media aritmetică  
ideală a produselor**  $\varphi[n] \varphi^T[n]$

☞ Consistența este cea mai importantă proprietate statistică.

Demonstrația s-a bazat pe faptul că limita șirului matricilor  $\mathbf{R}_N$  continuă să fie inversabilă cel puțin pentru o realizare infinită a procesului furnizor de date.

# 4 Metode de identificare și validare

## 4.2 Metoda Celor Mai Mici Pătrate

### Teorema fundamentală a MCMMP (continuare)

#### Demonstrație (Teorema 2)

#### 4. Eficiența estimațiilor parametrilor necunoscuți

- Pentru simplitate, indicele  $N$  va fi omis din notația vectorului parametrilor necunoscuți.
- Fie  $\tilde{\theta} = \tilde{A}Y \in \Gamma$  o altă estimație nedeviată din clasa  $\Gamma$ , eventual diferită de cea oferită de **MCMMP**.

$$\hat{\theta} = (\Phi^T \Phi)^{-1} \Phi^T Y \Rightarrow \hat{\theta} = \hat{A}Y \in \Gamma$$

$\hat{A} \in \mathbb{R}^{n\theta \times N}$

**a.**

Estimația oferită de **MCMMP** face parte din clasa de estimații definită în enunțul teoremei.

**Nedeviere**

$$E\{\tilde{\theta}\} = \theta^* \Leftrightarrow E\{\tilde{A}(\Phi\theta^* + V)\} = \tilde{A}(\Phi\theta^* + E\{V\}) = \tilde{A}\Phi\theta^* = \theta^*$$

$$\Leftrightarrow \tilde{A}\Phi = I_{n\theta}$$

**a.**

**c.**

- Conform definiției, estimația  $\hat{\theta}$  este cel puțin tot atât de eficientă ca estimația  $\tilde{\theta}$  dacă:  

$$P(\hat{\theta}) \leq P(\tilde{\theta}) \Leftrightarrow P(\tilde{\theta}) - P(\hat{\theta}) \geq 0.$$
- Pentru a demonstra această inegalitate, se pleacă de la operatorul liniar  $\Delta = \tilde{A} - \hat{A}$ , care verifică proprietatea remarcabilă de a fi ortogonal pe operatorul reprezentat de matricea regresorilor (ca și operatorul  $Q$ ):

$$\Delta\Phi = \tilde{A}\Phi - \hat{A}\Phi = I_{n\theta} - I_{n\theta} = 0.$$

- Cu ajutorul operatorului  $\Delta$ , se poate determina o relație între cele două estimații:

$$\tilde{\theta} = \tilde{A}Y = (\Delta + \hat{A})Y = \Delta Y + \hat{\theta} = \Delta(\Phi\theta^* + V) + \hat{\theta} = \hat{\theta} + \Delta V.$$

$$Y = \Phi\theta^* + V$$

# 4 Metode de identificare și validare

## 4.2 Metoda Celor Mai Mici Pătrate

### Teorema fundamentală a MCMMP (continuare)

#### Demonstrație (Teorema 2)

#### 4. Eficiența estimațiilor parametrilor necunoscuți (continuare)

**Așadar**  $\tilde{\theta} - \theta^* = \hat{\theta} - \theta^* + \Delta V$

$$\begin{aligned} P(\tilde{\theta}) &\stackrel{\text{def}}{=} E\left\{(\tilde{\theta} - \theta^*)(\tilde{\theta} - \theta^*)^T\right\} = E\left\{(\hat{\theta} - \theta^* + \Delta V)(\hat{\theta} - \theta^* + \Delta V)^T\right\} = \\ &= P(\hat{\theta}) + E\left\{(\hat{\theta} - \theta^*)V^T \Delta^T\right\} + E\left\{\Delta V(\hat{\theta} - \theta^*)^T\right\} + E\left\{\Delta V V^T \Delta^T\right\} \end{aligned}$$

- Termenii încrucișați (transpuși unul altuia) se anulează:

$$\begin{aligned} E\left\{(\hat{\theta} - \theta^*)V^T \Delta^T\right\} &\stackrel{\text{a.}}{=} E\left\{(\Phi^T \Phi)^{-1} \Phi^T V V^T \Delta^T\right\} \stackrel{\text{c.}}{=} (\Phi^T \Phi)^{-1} \Phi^T E\{V V^T\} \Delta^T = \\ &\hat{\theta} = \theta^* + (\Phi^T \Phi)^{-1} \Phi^T V \\ &= \lambda^2 (\Phi^T \Phi)^{-1} \underbrace{\Phi^T \Delta^T}_{0} = 0. \end{aligned}$$

☞ O demonstrație alternativă a eficienței utilizează un raționament bazat pe un rezultat din Teoria Matricilor.

- Rezultă atunci că:

$$P(\tilde{\theta}) = P(\hat{\theta}) + E\left\{\Delta V V^T \Delta^T\right\} \stackrel{\text{c.}}{=} P(\hat{\theta}) + \lambda^2 \Delta \Delta^T$$

&  $\Delta \rightarrow$  deterministă

$$P(\tilde{\theta}) - P(\hat{\theta}) = \lambda^2 \Delta \Delta^T \geq 0$$

# 4 Metode de identificare și validare

## 4.2 Metoda Celor Mai Mici Pătrate

### Teorema fundamentală a MCMMP (continuare)

#### Demonstrație (Teorema 2)

#### 5. Consistența estimațiilor dispersiei zgomotului alb

$$\hat{\lambda}_{\gamma_N}^2 = \frac{1}{\gamma_N} \mathbf{V}^T \mathbf{Q} \mathbf{V}$$

Proprietatea rezultă după câteva calcule elementare, ținând cont de ipotezele teoremei.

Exercițiu

#### 6. Proprietăți de nedeviare ale estimațiilor dispersiei zgomotului alb

$$\hat{\lambda}_N^2 \stackrel{\text{def}}{=} \frac{1}{N} \sum_{n=1}^N \left( y[n] - \boldsymbol{\varphi}^T[n] \hat{\boldsymbol{\theta}}_N \right)^2 \quad \otimes \text{ Deviată}$$

$$\hat{\lambda}_{N-n\theta}^2 \stackrel{\text{def}}{=} \frac{1}{N-n\theta} \sum_{n=1}^N \left( y[n] - \boldsymbol{\varphi}^T[n] \hat{\boldsymbol{\theta}}_N \right)^2 \quad \odot \text{ Nedeviată}$$

- Ambele aserțiuni vor fi demonstrate simultan, folosind operatorul numit **urmă a unei matrici (trace)**.

#### Proprietăți elementare ale operatorului Tr

→ Liniaritate

$$\text{Tr}(\alpha \mathbf{A} + \beta \mathbf{B}) = \alpha \text{Tr}(\mathbf{A}) + \beta \text{Tr}(\mathbf{B}) \quad \forall n \in \mathbb{N}^*$$

→ Invarianță la comutarea matricilor

$$\text{Tr}(\mathbf{AB}) = \text{Tr}(\mathbf{BA})$$

⚡ Proprietate care se verifică indiferent dacă produsul celor două matrici este sau nu comutativ.

$$\text{Tr}(\mathbf{A}) \stackrel{\text{def}}{=} \sum_{i=1}^n a_{ii}$$

suma elementelor de pe diagonală

$$\begin{aligned} E \left\{ \hat{\lambda}_{\gamma_N}^2 \right\} &= \frac{1}{\gamma_N} E \left\{ \underbrace{\mathbf{V}^T \mathbf{Q} \mathbf{V}}_{\in \mathbb{R}} \right\} = \frac{1}{\gamma_N} E \left\{ \text{Tr}(\mathbf{V}^T \mathbf{Q} \mathbf{V}) \right\} \\ &= \frac{1}{\gamma_N} E \left\{ \text{Tr}(\mathbf{Q} \mathbf{V} \mathbf{V}^T) \right\} \end{aligned}$$

# 4 Metode de identificare și validare

## 4.2 Metoda Celor Mai Mici Pătrate

### Teorema fundamentală a MCMMP (continuare)

#### Demonstrație (Teorema 2)

#### 6. Proprietăți de nedeviere ale estimațiilor dispersiei zgomotului alb (continuare)

**Așadar**

$$E\left\{\hat{\lambda}_{\gamma_N}^2\right\} = \frac{1}{\gamma_N} E\left\{\text{Tr}(\mathbf{Q}\mathbf{V}\mathbf{V}^T)\right\}$$

$$E\left\{\hat{\lambda}_{\gamma_N}^2\right\} \stackrel{\text{a.}}{=} \frac{1}{\gamma_N} \text{Tr}\left(\mathbf{Q}E\left\{\mathbf{V}\mathbf{V}^T\right\}\right) \stackrel{\text{c.}}{=} \frac{\lambda^2}{\gamma_N} \text{Tr}(\mathbf{Q}) = \frac{\lambda^2}{\gamma_N} \text{Tr}\left[\mathbf{I}_N - \Phi\left(\Phi^T\Phi\right)^{-1}\Phi^T\right] =$$

$$= \frac{\lambda^2}{\gamma_N} \left\{ N - \text{Tr}\left[\Phi\left(\Phi^T\Phi\right)^{-1}\Phi^T\right] \right\} = \frac{\lambda^2}{\gamma_N} \left\{ N - \text{Tr}\left[\left(\Phi^T\Phi\right)^{-1}\Phi^T\Phi\right] \right\} =$$

$$= \frac{\lambda^2}{\gamma_N} \left[ N - \text{Tr}(\mathbf{I}_{n\theta}) \right] = \frac{N - n\theta}{\gamma_N} \lambda^2$$

- Egalitatea obținută demonstrează proprietatea de deviere/nedeviere a estimațiilor dispersiei zgomotului alb și justifică alegerea constantei  $\gamma_N$ .

Ipotezele teoremei au fost alese cu grijă, astfel încât atât **consistența** cât și **nedevierea** estimațiilor să fie verificate.

☞ Dacă ipoteza **b.** din enunțul Teoremei este necesară pentru buna definire a estimației parametrilor necunoscuți, ipotezele **a.** și **c.** sunt destul de restrictive.



# 4 Metode de identificare și validare

## 4.2 Metoda Celor Mai Mici Pătrate



### Sumarul relațiilor matriciale din contextul MCMMP

#### Contextul de lucru

$\mathcal{P}(\theta^*)$

$$Y = \Phi \theta^* + V$$

$$E\{V\} = 0$$

$$E\{VV^T\} = \lambda^2 I_N$$

$\mathcal{M}(\theta)$

$$Y = \Phi \theta + \varepsilon(\theta)$$

$$\varepsilon(\theta^*) = V$$

Extracția datelor utile din date afectate de zgomot **nu este însă perfectă**, calitatea ei depinzând de matricea regresorilor.

#### Criteriul pătratic

$$\mathcal{V}(\theta) \stackrel{\text{def}}{=} \|\varepsilon(\theta)\|^2 = \|Y - \Phi \theta\|^2$$


#### Estimațiile oferite de MCMMP

$$\hat{\theta}_N = (\Phi^T \Phi)^{-1} \Phi^T Y = \theta^* + (\Phi^T \Phi)^{-1} \Phi^T V$$

$$\hat{V} = Y - \Phi \hat{\theta}_N = QY = QV$$


$$\hat{\lambda}_{\gamma_N}^2 = \frac{1}{\gamma_N} \hat{V}^T \hat{V} = \frac{1}{\gamma_N} V^T QV$$

$$\mathcal{V}(\hat{\theta}_N) = Y^T QY = V^T QV = \hat{V}^T \hat{V} = \gamma_N \hat{\lambda}_{\gamma_N}^2$$

  $\text{SNR}(\Phi \hat{\theta}) \geq \text{SNR}(Y)$

MCMMP induce o tehnică de **extragere a datelor utile din datele măsurate**, cu ajutorul proiecțiilor ortogonale, adică **neredundante**.

👉 Zgomotul estimat se obține prin proiectarea datelor de ieșire măsurate pe hiperplanul parazit.



# 4 Metode de identificare și validare

## 4.2 Metoda Celor Mai Mici Pătrate


### Nerespectarea condițiilor Teoremei fundamentale

Cum pot fi relaxate condițiile restrictive din cadrul Teoremei fundamentale fără a afecta consistența estimațiilor?

Condiția a. (**determinismul matricii regresorilor**) este adesea înlocuită prin condiția ca **perturbația și vectorul regresorilor să nu fie corelate**.

$$E\{\varphi[n]v[m]\} = 0 \\ \forall n, m \in \mathbb{N}^*$$

- Se poate arăta (deși este mai complicat), că noua condiție **nu conduce la pierderea consistenței**.
- Condiția este sugerată de **expresia ideală aparametrilor adevărați**.



$$\theta^* = \left( E\{\varphi[n]\varphi^T[n]\} \right)^{-1} \left( E\{\varphi[n]y[n]\} - \cancel{E\{\varphi[n]v[n]\}} \right)$$

$$\theta^* = \left( E\{\varphi[n]\varphi^T[n]\} \right)^{-1} \left( E\{\varphi[n]y[n]\} \right) = \underbrace{\left[ \lim_{N \rightarrow \infty} \left( \frac{1}{N} \sum_{n=1}^N \varphi[n]\varphi^T[n] \right)^{-1} \right]}_{\cong \hat{\theta}_N} \left[ \lim_{N \rightarrow \infty} \left( \frac{1}{N} \sum_{n=1}^N \varphi[n]y[n] \right) \right]$$

- Mai mult, datorită timpului mort intrinsec al procesului, în anumite cazuri este posibilă verificarea condiției de necorelare chiar și în cazul **identificării în buclă închisă**.

Condiția b. (**inversabilitatea matricii de covarianță**) este **indispensabilă** pentru **buna definire a estimației vectorului parametrilor necunoscuți**.

Dealtfel, aceasta nu este o condiție restrictivă.


$$\hat{\theta}_N = \mathbf{R}_N^{-1} \mathbf{r}_N = \left( \frac{1}{N} \sum_{n=1}^N \varphi[n]\varphi^T[n] \right)^{-1} \left( \frac{1}{N} \sum_{n=1}^N \varphi[n]y[n] \right)$$



# 4 Metode de identificare și validare

## 4.2 Metoda Celor Mai Mici Pătrate

### Nerespectarea condițiilor Teoremei fundamentale (continuare)



Condiția c. (perturbația este un zgomot alb) se verifică rareori în practică.

Pentru relaxarea ei, există **două abordări**.

**Cazul zgomotelor colorate, de medie nulă**

**Estimatorul Markov**

**Erori sistematice de măsură**

☞ Cazuri frecvent întâlnite în aplicații.

**Cazul zgomotelor albe de medie nenulă**

**Centrarea datelor pe medie**

**Cazul zgomotelor colorate, de medie nulă. Estimatorul Markov.**

$$E\{VV^T\} = \Lambda > 0$$

matrice de auto-covarianță nu neapărat diagonală, dar simetrică și strict pozitiv definită



Deoarece media zgomotului continuă să fie nulă, atât **nedevierea** cât și **consistența** estimațiilor oferite de **MCMMP se conservă**.

⊗ Se pierde eficiența estimației.

**Cum se poate remedia acest efect?**

**Exercițiu**  $P(\hat{\theta}) = (\Phi^T \Phi)^{-1} \Phi^T \Lambda \Phi (\Phi^T \Phi)^{-1}$

Estimatorul **CMMP** se poate înlocui cu **estimatorul Markov**, care se construiește plecând de la **descompunerea Cholesky a matricii  $\Lambda$** .

$$\Lambda = C^T C > 0$$



$$C^{-T} \times [Y = \Phi \theta^* + V] \Leftrightarrow C^{-T} Y = C^{-T} \Phi \theta^* + C^{-T} V \Leftrightarrow \tilde{Y} = \tilde{\Phi} \theta^* + \tilde{V}$$

**Transformare echivalentă a ecuației procesului**

$\tilde{Y}$

$\tilde{\Phi}$

$\tilde{V}$

# 4 Metode de identificare și validare

## 4.2 Metoda Celor Mai Mici Pătrate

Nerespectarea condițiilor Teoremei fundamentale (continuare)

Cazul zgomotelor colorate, de medie nulă. Estimatorul Markov. (continuare)

Așadar

$$\tilde{\mathbf{Y}} = \tilde{\Phi} \theta^* + \tilde{\mathbf{V}}$$

$$\begin{matrix} \uparrow & \uparrow & \uparrow \\ \mathbf{C}^{-T} \mathbf{Y} & \mathbf{C}^{-T} \Phi & \mathbf{C}^{-T} \mathbf{V} \end{matrix}$$

Este alb noul zgomot?

DA

Estimația Markov

$$\tilde{\theta} = (\tilde{\Phi}^T \tilde{\Phi})^{-1} \tilde{\Phi}^T \tilde{\mathbf{Y}} = (\Phi^T \Lambda^{-1} \Phi)^{-1} \Phi^T \Lambda^{-1} \mathbf{Y}$$

$$\begin{aligned} E\{\tilde{\mathbf{V}}\tilde{\mathbf{V}}^T\} &= E\{\mathbf{C}^{-T} \mathbf{V} \mathbf{V}^T \mathbf{C}^{-1}\} \\ &= \mathbf{C}^{-T} E\{\mathbf{V} \mathbf{V}^T\} \mathbf{C}^{-1} \\ &= \mathbf{C}^{-T} \Lambda \mathbf{C}^{-1} = \mathbf{C}^{-T} \mathbf{C}^T \mathbf{C} \mathbf{C}^{-1} = \mathbf{I}_N \end{aligned}$$

☞ Cea mai eficientă din clasa  $\Gamma$ .

Exercițiu

$$\mathbf{P}(\tilde{\theta}) = (\Phi^T \Lambda^{-1} \Phi)^{-1}$$

Markov

CMMP

$$\mathbf{P}(\tilde{\theta}) \leq \mathbf{P}(\hat{\theta}) \iff \Phi^T \left[ \Lambda^{-1} - \Phi (\Phi^T \Lambda \Phi)^{-1} \Phi^T \right] \Phi \geq 0$$

☞ Și are chiar dispersie unitară.

Este acest estimator implementabil?

În general, **nu**, din două motive:

- ➔ Matricea de auto-covarianță a zgomotului colorat **nu este cunoscută**.
- ➔ Chiar dacă matricea de auto-covarianță a zgomotului colorat ar fi estimată în prealabil, dimensiunea acesteia este egală cu a orizontului de măsură, astfel că inversarea este o operație consumatoare de timp.

În cazul zgomotelor colorate de medie nulă, se utilizează tot **MCMP**, chiar dacă nu este cea mai eficientă.

# 4 Metode de identificare și validare

## 4.2 Metoda Celor Mai Mici Pătrate

Nerespectarea condițiilor Teoremei fundamentale (continuare)

Cazul zgomotelor albe, de medie nenulă. Centrarea datelor pe medie.

$$E\{v[n]\} = \langle v \rangle \neq 0$$

eroare sistematică de măsură  
(necunoscută)

Exercițiu ⊗ Consistența și nedevierea estimăției se pierd.

Cum se poate remedia acest efect?

Există două strategii.

În acest curs ♡

Centrarea datelor pe medie  
(staționarizarea datelor)

Exercițiu

Metoda Celor Mai Mici Pătrate cu  
Parametri Extinși (MCMMPPE)

- Se pleacă de la observația că **zgomotul staționarizat** are **medie nulă**.

$$\stackrel{\text{def}}{\tilde{v}} \equiv v - E\{v[n]\} = v - \langle v \rangle$$

$$E\{\tilde{v}[n]\} = \langle v \rangle - \langle v \rangle = 0$$

- De notat că zgomotul staționarizat **nu mai este alb**, ci **colorat**.

Exercițiu  $E\{\tilde{v}[n]\tilde{v}[m]\} = E\{(v[n] - \langle v \rangle)(v[m] - \langle v \rangle)\} = \lambda^2 \delta_0[n - m] - \langle v \rangle^2$

$\forall n, m \in \mathbb{N}^*$

- Conform cazului anterior, zgomotele colorate nu produc pierderea consistenței, dacă au media nulă.

$$y[n] = \varphi^T[n]\theta^* + v[n] \quad \forall n \in \mathbb{N}^*$$

$$y[n] = \varphi^T[n]\theta^* + \langle v \rangle + \tilde{v}[n] \quad \forall n \in \mathbb{N}^*$$

parametru necunoscut  
suplimentar

Transformare echivalentă a ecuației procesului

# 4 Metode de identificare și validare

## 4.2 Metoda Celor Mai Mici Pătrate

### Nerespectarea condițiilor Teoremei fundamentale (continuare)

### Cazul zgomotelor albe, de medie nenulă. Centrarea datelor pe medie. (continuare)

**Așadar**

$$y[n] = \boldsymbol{\varphi}^T[n] \boldsymbol{\theta}^* + \langle v \rangle + \tilde{v}[n]$$

$$\forall n \in \mathbb{N}^*$$

- Se poate aplica operatorul de mediere statistică:
- Ecuția mediilor se scade din cea a procesului:

$$y[n] - \langle y \rangle = (\boldsymbol{\varphi}^T[n] - \langle \boldsymbol{\varphi} \rangle^T) \boldsymbol{\theta}^* + \tilde{v}[n]$$

$$\tilde{y}[n]$$

$$\tilde{\boldsymbol{\varphi}}^T[n]$$

👉 Date staționarizate  
(centrate pe medie).

$$E\{y[n]\} = E\{\boldsymbol{\varphi}^T[n]\} \boldsymbol{\theta}^* + E\{v[n]\}$$

$$\langle y \rangle$$

$$\langle \boldsymbol{\varphi} \rangle^T$$

$$\langle v \rangle$$

$$\langle y \rangle = \langle \boldsymbol{\varphi} \rangle^T \boldsymbol{\theta}^* + \langle v \rangle$$

ecuația mediilor

👉 Medii ale datelor măsurate.

$$\tilde{y}[n] = \tilde{\boldsymbol{\varphi}}^T[n] \boldsymbol{\theta}^* + \tilde{v}[n]$$

$$\forall n \in \mathbb{N}^*$$

Zgomotul noii ecuații de proces are **medie nulă**,  
dar este **colorat**.

Se poate folosi fie Estimatorul Markov,  
fie Estimatorul **CMMP**.

$$\tilde{\boldsymbol{\theta}}_N = \left( \sum_{n=1}^N \tilde{\boldsymbol{\varphi}}[n] \tilde{\boldsymbol{\varphi}}^T[n] \right)^{-1} \left( \sum_{n=1}^N \tilde{\boldsymbol{\varphi}}[n] \tilde{y}[n] \right)$$

$$\tilde{\lambda}_{\gamma_N}^2 = \frac{1}{\gamma_N} \sum_{n=1}^N \left( \tilde{y}[n] - \tilde{\boldsymbol{\varphi}}^T[n] \tilde{\boldsymbol{\theta}}_N \right)^2$$

**Exercițiu**

- Să se dezvolte **MCMMPPE** plecând de la exprimarea ecuației procesului cu ajutorul **vectorului extins de parametri**.

- Se poate arăta că estimațiile oferite de **MCMMPPE** sunt aceleași ca în cazul staționarizării datelor.

$$\boldsymbol{\theta}_e^* \stackrel{\text{def}}{=} \begin{bmatrix} \boldsymbol{\theta}^* \\ \langle v \rangle \end{bmatrix}$$

medii  
temporale  
estimate

$$\langle \tilde{v} \rangle_N = \langle \tilde{y} \rangle_N - \langle \tilde{\boldsymbol{\varphi}} \rangle_N^T \tilde{\boldsymbol{\theta}}_N$$

➔ Eroarea  
sistematică  
estimată.