

# 4 Metode de identificare și validare

## 4.2 Metoda Celor Mai Mici Pătrate

Analiza estimației oferite de MCMMP pentru modelele **ARX**

➡ Cele mai folosite în Automatică.

$\mathcal{P}(\theta^*)$

$$A^*(q^{-1})y[n] = B^*(q^{-1})u[n] + v[n]$$

$\forall n \in \mathbb{N}^*$

polinoame cu parametri adevărați,  
având gradele  $na$ , respectiv  $nb$

$$n\theta = na + nb$$

$$y[n] = \phi^T[n]\theta^* + v[n]$$

$\forall n \in \mathbb{N}^*$

$$\mathcal{D}_N = \{(u[n], y[n])\}_{n \in \overline{1, N}}$$

date măsurate

$$\phi^T[n] \stackrel{\text{def}}{=} [-y[n-1] - y[n-2] \cdots - y[n-na] \mid u[n-1] u[n-2] \cdots u[n-nb]]$$

☞ vectorul regresorilor

$$\theta^T \stackrel{\text{def}}{=} [a_1 \ a_2 \ \cdots \ a_{na} \mid b_1 \ b_2 \ \cdots \ b_{nb}]$$

☞ vectorul parametrilor necunoscuți

☞ Acești vectori au câte două componente.

$$\mathbf{R}_N = \begin{bmatrix} \underbrace{\frac{1}{N} \sum_{n=1}^N y[n-i]y[n-j]}_{i,j \in \overline{1,na}} & \underbrace{-\frac{1}{N} \sum_{n=1}^N y[n-i]u[n-j]}_{\substack{i \in \overline{1,na} \\ j \in \overline{1,nb}}} \\ \underbrace{-\frac{1}{N} \sum_{n=1}^N u[n-i]y[n-j]}_{\substack{i \in \overline{1,nb} \\ j \in \overline{1,na}}} & \underbrace{\frac{1}{N} \sum_{n=1}^N u[n-i]u[n-j]}_{i,j \in \overline{1,nb}} \end{bmatrix}$$

$-r_{y,u}^N[i-j]$        $r_u^N[i-j]$

$$\mathbf{r}_N = \begin{bmatrix} \underbrace{-\frac{1}{N} \sum_{n=1}^N y[n-i]y[n]}_{i \in \overline{1,na}} \\ \underbrace{\frac{1}{N} \sum_{n=1}^N u[n-j]y[n]}_{j \in \overline{1,nb}} \end{bmatrix}$$

$-r_y^N[i]$        $r_{y,u}^N[j]$

☞ Matricea nu este neapărat simetrică.

- În cadrul matricii  $\mathbf{R}_N$ , indicele  $i$  parcurge liniile, iar indicele  $j$  parcurge coloanele.
- Pentru a evalua elementele matricii și ale vectorului se apelează la **convenția prelungerii cu zerouri** a secvențelor de date măsurate.

# 4 Metode de identificare și validare

## 4.2 Metoda Celor Mai Mici Pătrate

Analiza **estimației oferite de MCMMP** pentru modelele **ARX** (continuare)

$$\hat{\theta}_N = \mathbf{R}_N^{-1} \mathbf{r}_N = \begin{bmatrix} \left[ r_y^N[i-j] \right]_{i,j \in \overline{1,na}} & \left[ -r_{u,y}^N[i-j] \right]_{\substack{i \in \overline{1,na} \\ j \in \overline{1,nb}}} \\ \left[ -r_{y,u}^N[i-j] \right]_{\substack{i \in \overline{1,nb} \\ j \in \overline{1,na}}} & \left[ r_u^N[i-j] \right]_{i,j \in \overline{1,nb}} \end{bmatrix}^{-1} \begin{bmatrix} \left[ -r_y^N[i] \right]_{i \in \overline{1,na}} \\ \left[ r_{y,u}^N[j] \right]_{j \in \overline{1,nb}} \end{bmatrix}$$

$$\hat{\lambda}_N^2 = \frac{1}{\gamma_N} \sum_{n=1}^N \left( y[n] - \boldsymbol{\varphi}^T[n] \hat{\theta}_N \right)^2 = \frac{1}{\gamma_N} \sum_{n=1}^N \left( y[n] - \boldsymbol{\varphi}^T[n] \mathbf{R}_N^{-1} \mathbf{r}_N \right)^2$$

← Dacă perturbația este un **zgomot alb** de medie nulă și dispersie necunoscută.

⊗ Vectorul regresorilor nu este perfect determinist.

⊗ Mai mult, estimația vectorului parametrilor necunoscuți este deviată.

Nu poate fi aplicată **Teorema fundamentală a MCMMP** pentru a testa consistența estimațiilor.

Cum poate fi testată consistența în cazul acestui model?

Prin relaxarea condiției **a.** din ipoteza **Teoremei 2.**



$$\lim_{N \rightarrow \infty} \mathbf{R}_N = \begin{bmatrix} \left[ r_y[i-j] \right]_{i,j \in \overline{1,na}} & \left[ -r_{u,y}[i-j] \right]_{\substack{i \in \overline{1,na} \\ j \in \overline{1,nb}}} \\ \left[ -r_{y,u}[i-j] \right]_{\substack{i \in \overline{1,nb} \\ j \in \overline{1,na}}} & \left[ r_u[i-j] \right]_{i,j \in \overline{1,nb}} \end{bmatrix} = E\{\boldsymbol{\varphi}[n] \boldsymbol{\varphi}^T[n]\}$$

$$\lim_{N \rightarrow \infty} \mathbf{r}_N = \begin{bmatrix} \left[ -r_y[i] \right]_{i \in \overline{1,na}} \\ \left[ r_{y,u}[j] \right]_{j \in \overline{1,nb}} \end{bmatrix} = E\{\boldsymbol{\varphi}[n] y[n]\}$$

# 4 Metode de identificare și validare

## 4.2 Metoda Celor Mai Mici Pătrate



### Analiza estimației oferite de MCMMP pentru modelele ARX (continuare)

$$\theta^* = \left( \lim_{N \rightarrow \infty} E\{\varphi[n]\varphi^T[n]\} \right)^{-1} \left( \lim_{N \rightarrow \infty} E\{\varphi[n]y[n]\} - E\{\varphi[n]v[n]\} \right)$$

$$\lim_{N \rightarrow \infty} \hat{\theta}_N = \theta^* + \left( E\{\varphi[n]\varphi^T[n]\} \right)^{-1} (E\{\varphi[n]v[n]\})$$

- Mai precis, se poate demonstra rezultatul de mai jos.

O condiție suficientă de consistență

$$E\{\varphi[n]v[n]\} = 0 \quad \Leftrightarrow \quad \begin{cases} E\{v[n]y[n-i]\} = 0 & \forall i \in \overline{1, na} \\ E\{v[n]u[n-j]\} = 0 & \forall j \in \overline{1, nb} \end{cases}$$

### Propoziția 4

Pentru modelul ARX, următoarele 3 ipoteze se consideră verificate:

- semnalul de intrare are ordin de persistență suficient de mare, astfel încât matricea  $R_N$  să fie inversabilă pentru toate dimensiunile orizontului de măsură suficient de mari;
- perturbația  $v$  aparține clasei  $za(0, \lambda^2)$  (cu dispersia necunoscută  $\lambda^2$ );
- semnalul de intrare (comandă sau referință) este necorelat cu perturbația ( $E\{u[n]v[m]\} = 0, \forall n, m \in \mathbb{Z}$ ).

Atunci estimațiile oferite de MCMMP sunt consistente.

- Se observă că numai una dintre cele două condiții suficiente de consistență este precizată în cadrul propoziției.
- Intrarea ar trebui generată **artificial**, departe de sursa de perturbații care afectează ieșirea procesului, **cu ordin de persistență cât mai mare**.

⚡ Ieșirea de la momente anterioare este necorelată cu zgomotul de la momentul curent datorită  **timpului mort intrinsec al procesului**.

# 4 Metode de identificare și validare

## 4.3 Metoda Variabilelor Instrumentale (MVI)

- Condiția ca perturbația să fie un **zgomot alb** rămîne restrictivă.
- Dacă nu se dorește impunerea unei condiții asupra perturbațiilor, atunci se operează o modificare asupra estimațiilor oferite de **MCMMP**.

### Estimația oferită de Metoda Variabilelor Instrumentale (MVI)

$$\hat{\theta}_N \stackrel{def}{=} \mathbf{R}_N^{-1} \mathbf{r}_N = \left( \frac{1}{N} \sum_{n=1}^N \zeta[n] \boldsymbol{\varphi}^T[n] \right)^{-1} \left( \frac{1}{N} \sum_{n=1}^N \zeta[n] y[n] \right)$$

**vectorul variabilelor instrumentale**

$$\zeta[n] \in \mathbb{R}^{n\theta}$$

👉 Ales liber de către utilizator, astfel încât definiția să fie corectă.



**Aceasta este o definiție.**

- Nu s-a utilizat nici un raționament pentru deducerea ei.
- Definiția este corectă numai dacă matricea  $\mathbf{R}_N$  este inversabilă.

**Dar consistența?**



Această proprietate trebuie studiată în manieră riguroasă.

Se pot deduce mai întâi **condițiile generale de consistență**.

$$E \{ \zeta[n] \times y[n] \} = \boldsymbol{\varphi}^T[n] \theta^* + v[n]$$

$$\theta^* = \left( E \{ \zeta[n] \boldsymbol{\varphi}^T[n] \} \right)^{-1} \left( E \{ \zeta[n] y[n] \} - E \{ \zeta[n] v[n] \} \right)$$

$$\det \left( E \{ \zeta[n] \boldsymbol{\varphi}^T[n] \} \right) \neq 0$$

$$E \{ \zeta[n] v[n] \} = 0$$

$$\forall n \in \mathbb{N}^*$$

$$\theta^* = \lim_{N \rightarrow \infty} \hat{\theta}_N - \left( E \{ \zeta[n] \boldsymbol{\varphi}^T[n] \} \right)^{-1} \left( E \{ \zeta[n] v[n] \} \right)$$

👉 Instrumentele trebuie să fie necorelate cu perturbațiile.

# 4 Metode de identificare și validare

## 4.6 Metoda Variabilelor Instrumentale

### Analiza estimației oferite de MVI pentru modelele ARX

$\mathcal{P}(\theta^*)$

$$A^*(q^{-1})y[n] = B^*(q^{-1})u[n] + v[n]$$

$$y[n] = \phi^T[n]\theta^* + v[n]$$

$\forall n \in \mathbb{N}^*$

$$\phi^T[n] \stackrel{\text{def}}{=} [-y[n-1] \ y[n-2] \ \dots \ -y[n-na] \ | \ u[n-1] \ u[n-2] \ \dots \ u[n-nb]]$$

$$\theta^T \stackrel{\text{def}}{=} [a_1 \ a_2 \ \dots \ a_{na} \ | \ b_1 \ b_2 \ \dots \ b_{nb}]$$

Cum se poate construi vectorul variabilelor instrumentale în cazul modelelor ARX?

Pentru a realiza necorelarea cu perturbațiile, se încearcă utilizarea doar a intrării (nu și a ieșirii).

$$n\theta = na + nb$$

nefiltrat

$$\zeta[n] \stackrel{\text{def}}{=} [u[n-1] \ u[n-2] \ \dots \ u[n-na-nb]]^T$$

3 tipuri de vectori ai instrumentelor

parțial filtrat

$$\zeta[n] \stackrel{\text{def}}{=} [u_f[n-1] \ u_f[n-2] \ \dots \ u_f[n-na] \ | \ u[n-1] \ u[n-2] \ \dots \ u[n-nb]]^T;$$

Pe poziția componentei AR.

$$\zeta[n] \stackrel{\text{def}}{=} [u[n-1] \ u[n-2] \ \dots \ u[n-na] \ | \ u_f[n-1] \ u_f[n-2] \ \dots \ u_f[n-nb]]^T;$$

Pe poziția componentei X.

(total) filtrat

$$\zeta[n] \stackrel{\text{def}}{=} [u_f[n-1] \ u_f[n-2] \ \dots \ u_f[n-na-nb]]^T$$

Semnalul filtrat

$$u_f[n] \stackrel{\text{def}}{=} \frac{D(q^{-1})}{C(q^{-1})} u[n]$$

Exemple

$$\begin{cases} C(q^{-1}) = 1 \\ D(q^{-1}) = q^{-nd} \end{cases}$$

$$u_f[n] \stackrel{\text{def}}{=} -\frac{\hat{B}(q^{-1})}{\hat{A}(q^{-1})} u[n+nk]$$

$\forall n \in \mathbb{N}^*$

estimate cu MCMMP

polinoame



# 4 Metode de identificare și validare

## 4.6 Metoda Variabilelor Instrumentale

### Analiza estimăției oferite de MVI pentru modelele ARX (continuare)

$$\zeta[n] \stackrel{\text{def}}{=} [u[n-1] \ u[n-2] \ \cdots \ u[n-na-nb]]^T \quad (\text{nefiltrat})$$

$$\mathbf{R}_N \stackrel{\text{def}}{=} \begin{bmatrix} \underbrace{\left[-\frac{1}{N} \sum_{n=1}^N u[n-i]y[n-j]\right]}_{-r_{y,u}^N[i-j]}_{i,j \in \overline{1,na}} & \underbrace{\left[\frac{1}{N} \sum_{n=1}^N u[n-i]u[n-j]\right]}_{r_u^N[i-j]}_{i \in \overline{1,na}, j \in \overline{1,nb}} \\ \underbrace{\left[-\frac{1}{N} \sum_{n=1}^N u[n-na-i]y[n-j]\right]}_{-r_{y,u}^N[na+i-j]}_{i \in \overline{1,nb}, j \in \overline{1,na}} & \underbrace{\left[\frac{1}{N} \sum_{n=1}^N u[n-na-i]u[n-j]\right]}_{r_u^N[na+i-j]}_{i,j \in \overline{1,nb}} \end{bmatrix} \quad \mathbf{r}_N \stackrel{\text{def}}{=} \begin{bmatrix} \underbrace{\left[\frac{1}{N} \sum_{n=1}^N u[n-i]y[n]\right]}_{r_{y,u}^N[i]}_{i \in \overline{1,na}} \\ \underbrace{\left[\frac{1}{N} \sum_{n=1}^N u[n-na-j]y[n]\right]}_{r_{y,u}^N[na+j]}_{j \in \overline{1,nb}} \end{bmatrix}$$

$$\hat{\boldsymbol{\theta}}_N = \mathbf{R}_N^{-1} \mathbf{r}_N = \begin{bmatrix} \underbrace{\left[-r_{y,u}^N[i-j]\right]}_{i,j \in \overline{1,na}} & \underbrace{\left[r_u^N[i-j]\right]}_{i \in \overline{1,na}, j \in \overline{1,nb}} \\ \underbrace{\left[-r_{y,u}^N[na+i-j]\right]}_{i \in \overline{1,nb}, j \in \overline{1,na}} & \underbrace{\left[r_u^N[na+i-j]\right]}_{i,j \in \overline{1,nb}} \end{bmatrix}^{-1} \begin{bmatrix} \underbrace{\left[r_{y,u}^N[i]\right]}_{i \in \overline{1,na}} \\ \underbrace{\left[r_{y,u}^N[na+j]\right]}_{j \in \overline{1,nb}} \end{bmatrix}$$

$$\hat{\lambda}_N^2 = \frac{1}{\gamma_N} \sum_{n=1}^N \left( y[n] - \boldsymbol{\varphi}^T[n] \hat{\boldsymbol{\theta}}_N \right)^2 = \frac{1}{\gamma_N} \sum_{n=1}^N \left( y[n] - \boldsymbol{\varphi}^T[n] \mathbf{R}_N^{-1} \mathbf{r}_N \right)^2$$

← Dacă perturbația este un zgomot alb de medie nulă și dispersie necunoscută.

Condițiile generale de consistență

$$\left\{ \begin{array}{l} \det(E\{\zeta[n]\boldsymbol{\varphi}^T[n]\}) \neq 0 \\ E\{\zeta[n]v[n]\} = 0 \end{array} \right. \quad \forall n \in \mathbb{N}^*$$

- Datorită formei vectorului instrumentelor, a doua condiție este automat verificată dacă **intrarea este produsă departe de sursa perturbațiilor**.

☞ Nu este necesar ca zgomotul să fie alb.

# 4 Metode de identificare și validare

## 4.6 Metoda Variabilelor Instrumentale

### Analiza estimației oferite de MVI pentru modelele ARX (continuare)

Este bine definită estimația oferită de MVI?



Pentru anumite semnale de intrare, **da**.

### Teorema 3 (Teorema fundamentală a MVI pentru modelele ARX)

Pentru modelul ARX[na,nb], următoarele 3 ipoteze se consideră verificate:

- modelul este parsimonios:  $(A^*, B^*) = 1$   
(polinoamele adevărate sunt coprime) ;
- semnalul de stimul  $u$  aparține clasei  $za(0, \lambda_u^2)$   
(adică este un zgomot alb de medie nulă și dispersie cunoscută).
- perturbația  $v$  nu este corelată cu semnalul de stimul:  $E\{u[n]v[m]\} = 0, \forall n, m \in \mathbb{N}^*$ .

Dacă se alege un vector al instrumentelor de tip nefiltrat, atunci estimația oferită de MVI pentru vectorul parametrilor adevărați ai modelului este bine definită și consistentă.


- Acest rezultat arată că modelele de tip **ARX** pot fi identificate cu succes și în cazul când **perturbațiile nu pot fi caracterizate statistic**.
- Condiția de neautocorelare a perturbațiilor se transferă acum **intrării**, care **poate fi controlată**.
- În practică, intrarea de tip **zgomot alb** nu poate fi generată, dar semnalele care o aproximează (**SPAB, SPA**) sunt frecvent utilizate în conjuncție cu **MVI**, **fără a pierde buna definire a estimației aferente**.

# 4 Metode de identificare și validare

## 4.6 Metoda Variabilelor Instrumentale

### Analiza estimației oferite de MVI pentru modelele ARX (continuare)

Cît de eficientă este estimația oferită de MVI?



Pentru testarea eficienței, este necesară evaluarea matricii de auto-covarianță a erorii de estimare.

Aceasta se realizează în demonstrația rezultatului care urmează.

### Teorema 4 (Eficiența estimației oferite de MVI pentru modelele ARX)

Se consideră că modelul ARX[na,nb] verifică următoarele ipoteze:

- modelul este parsimonios:  $(A^*, B^*) = 1$  (polinoamele adevărate sunt coprime);
- intrarea  $u$  este un semnal de stimul cu ordin de persistență suficient de mare (cel puțin  $na+nb$ ) astfel încît estimațiile oferite de MVI cu vectori ai instrumentelor construiți folosind numai acest semnal să fie corect definite;
- perturbația  $v$  aparține clasei  $za(0, \lambda^2)$  (adică este un zgomot alb de medie nulă și dispersie necunoscută  $\lambda^2$ ), nefiind corelată cu semnalul de stimul:  
$$E\{u[n]v[m]\} = 0, \quad \forall n, m \in \mathbb{N}^*.$$
- perturbația  $v$  este independentă statistic de semnalul de stimul.

Atunci cea mai eficientă estimație (corect definită) oferită de MVI se obține pentru următorul vector al instrumentelor, parțial filtrat:

$$\zeta[n] \stackrel{\text{def}}{=} \begin{bmatrix} u_f[n-1] & u_f[n-2] & \cdots & u_f[n-na] & | & u[n-1] & u[n-2] & \cdots & u[n-nb] \end{bmatrix}^T,$$

unde: 
$$u_f[n] \stackrel{\text{def}}{=} -\frac{B^*(q^{-1})}{A^*(q^{-1})} u[n] \quad \forall n \in \mathbb{N}^*.$$



# 4 Metode de identificare și validare

## 4.6 Metoda Variabilelor Instrumentale

### Analiza estimației oferite de MVI pentru modelele ARX (continuare)

#### Teorema 4

O estimație cu eficiență satisfăcătoare se obține folosind un filtru determinat prin MCMMP.

$$u_f[n] \stackrel{\text{def}}{=} -\frac{\hat{B}(q^{-1})}{\hat{A}(q^{-1})} u[n] \quad \forall n \in \mathbb{N}^*$$

☞ Cele două polinoame se pot estima și folosind MVI cu un vector al instrumentelor nefiltrat.

- În cadrul **Teoremei 4**, se revine la ipoteza perturbațiilor de tip **zgomot alb**, de aceea valoarea sa este destul de limitată.
- Cu toate acestea, dacă se verifică ipotezele **Teoremei 4**, se poate arăta că estimațiile oferite de **MCMMP** și **MVI** sunt la fel de eficiente.
- În cazul zgomotelor **colorate**:
  - ⊗ Estimațiile oferite de **MCMMP** sunt mai lent convergente (mai puțin eficiente) decât cele oferite de **MVI**.

☞ Deoarece Estimatorul Markov este neimplementabil.

- ⊗ Estimațiile oferite de **MVI** pot să nu fie consistente către valorile adevărate ale parametrilor.

☞ Deoarece procesul nu poate fi stimulat cu un zgomot alb.

- În aplicațiile unde este necesară identificarea unui model de tip **ARX**:
  - ☺ Atât estimațiile oferite de **MCMMP** cât și cele oferite de **MVI** sunt **implementabile**.
  - ⊗ Asigurarea condițiilor de consistență **nu este ușor de realizat**, deoarece se bazează pe neautocorelarea fie a perturbațiilor, fie a intrărilor.
- În general, **MCMMP** este utilizată **când procesul nu poate fi stimulat cu un SPA(B)**, altfel se recurge la **MVI**.