

4 Metode de identificare și validare

4.4 Metode bazate pe optimizarea parametrilor

- Modelele din clasa **ARMAX** pot fi identificate și cu ajutorul altor metode decât **MCMMP** și **MVI**.
- Cu cât modelul este mai complex, cu atât metoda utilizată este mai laborioasă.
- O parte dintre metodele utilizate în acest scop se bazează atât pe **revizuirea/adaptarea MCMMP**, cât și pe **algoritmi care folosesc Tehnici de Optimizare**.

Proceduri recursive cu ajutorul cărora un punct de optim (maxim sau minim) al unei funcții criteriu este aproximat printr-un proces iterativ exprimat de o **ecuație cu reactualizare aditivă**.

Cum poate fi cuantificată precizia aproximației?

Folosind **norma Euclidiană**.

Aproximația următoare este **mai precisă** decât aproximația curentă dacă:

$$\|\theta_{k+1} - \theta^*\| < \|\theta_k - \theta^*\|$$

punct de optim

Necunoscut !

$$\theta_{k+1} = \theta_k + \Delta_k \quad \forall k \in \mathbb{N}$$

valori succesive
ale aproximației
(vector sau scalar)

corecție (aditivă)

Se pleacă de la o
inițializare.

θ_0

Pentru a stopa procesul iterativ, trebuie utilizată o inegalitate în care punctul de optim să nu apară explicit.

Neimplementabil.

prag minimal de precizie

Test practic
de stop

Test ideal
de stop

$$\|\theta_{k+1} - \theta_k\| = \|\Delta_k\| < \varepsilon$$

$$\|\theta_k - \theta^*\| < \varepsilon$$

Exemplu

$$\varepsilon = 10^{-4}$$

θ_k & θ_{k+1}
(scalari)

coincid pînă la a patra
zecimală inclusiv

4 Metode de identificare și validare

4.4 Metode bazate pe optimizarea parametrilor



Obiectiv

Determinarea expresiei generale a corecției în funcție de criteriul de optimizare.

\mathcal{V}

Metoda Newton-Raphson (MNR)

Metodă aplicabilă în cazul funcțiilor criteriu **derivabile de cel puțin 2 ori**.

Gradientul

funcție care trebuie
să fie **derivabilă**

$$\nabla \mathcal{V}(\theta) \stackrel{\text{def}}{=} \begin{bmatrix} \frac{\partial \mathcal{V}}{\partial \theta_1}(\theta) & \frac{\partial \mathcal{V}}{\partial \theta_2}(\theta) & \dots & \frac{\partial \mathcal{V}}{\partial \theta_{n\theta}}(\theta) \end{bmatrix}^T \in \mathbb{R}^{n\theta}$$

♣ Vector coloană.

Matricea Hessiană


funcție care trebuie
să fie **continuă**

$$\diamond \mathcal{V}(\theta) \stackrel{\text{def}}{=} \nabla(\nabla \mathcal{V})(\theta) = \left[\frac{\partial^2 \mathcal{V}}{\partial \theta_i \partial \theta_j}(\theta) \right]_{i,j \in \overline{1, n\theta}} \in \mathbb{R}^{n\theta \times n\theta}$$

Jacobianul
gradientului

♣ Matrice simetrică.

Exemplu



Principiul metodei

- În jurul punctului de optim, **prima derivată** (sau norma sa) este **aproximativ nulă**, iar **derivata a doua** este **strict pozitiv/negativ definită**.
- Se construiește **parabola (paraboloidul)** care trece prin punctul curent $(\theta_k, \mathcal{V}(\theta_k))$ și are **aceeași tangentă și derivată secundă ca funcția criteriu**.
- **Punctul de minim/maxim al parabolei** este θ_{k+1} .

4 Metode de identificare și validare

4.4 Metode bazate pe optimizarea parametrilor

Metoda Newton-Raphson (continuare)

Așadar

Trebuie construit **paraboloidul** care verifică **3 proprietăți de coincidență** cu funcția criteriu în punctul curent.

$$\mathcal{V}_k$$

Cum poate fi construit?

Ar trebui exploatată proprietatea funcției criteriu de a fi de 2 ori derivabilă.

$$\mathcal{V}_k(\theta_k) = \mathcal{V}(\theta_k)$$

(derivata 0)

$$\nabla \mathcal{V}_k(\theta_k) = \nabla \mathcal{V}(\theta_k)$$

(derivata 1)

$$\diamond \mathcal{V}_k(\theta_k) = \diamond \mathcal{V}(\theta_k)$$

(derivata 2)

Dezvoltare în serie Taylor pînă la ordinul 2

Paraboloidul Taylor

$$\mathcal{V}_k(\theta) = \mathcal{V}(\theta_k) + [\nabla \mathcal{V}(\theta_k)]^T (\theta - \theta_k) + \frac{1}{2} (\theta - \theta_k)^T [\diamond \mathcal{V}(\theta_k)] (\theta - \theta_k)$$

$\forall \theta \in \mathbb{R}^{n\theta}$

Exercițiu

- Arătați că paraboloidul Taylor verifică cele 3 proprietăți de coincidență.

Pentru a determina **punctul de optim** al paraboloidului Taylor, se va anula gradientul acestuia.

Reguli de derivare

$$\nabla(\mathbf{r}^T \theta) = \mathbf{r}$$

$$\nabla(\theta^T \mathbf{R} \theta) = (\mathbf{R} + \mathbf{R}^T) \theta$$

$$\theta_{k+1} = \theta_k - [\diamond \mathcal{V}(\theta_k)]^{-1} \nabla \mathcal{V}(\theta_k)$$

$\forall k \in \mathbb{N}$

$$+\Delta_k$$

$$\nabla \mathcal{V}_k(\theta) = \nabla \mathcal{V}(\theta_k) + [\diamond \mathcal{V}(\theta_k)] (\theta - \theta_k) = \mathbf{0}$$

Matricea Hessiană este simetrică și inversabilă în vecinătatea optimului.

4 Metode de identificare și validare

4.4 Metode bazate pe optimizarea parametrilor

Metoda Newton-Raphson (continuare)

$$\Delta_k \stackrel{\text{def}}{=} - \left[\diamond \mathcal{V}'(\theta_k) \right]^{-1} \nabla \mathcal{V}(\theta_k) \quad \forall k \in \mathbb{N}$$


minus

Termenul corector are **semn opus gradientului**, deoarece matricea Hessiană este strict pozitiv/negativ definită.

Ce semnificație are acest rezultat?




Exemplu



- Semnul primei derivate **obligă** aproximația curentă **să se deplaseze către optimul criteriului**.
- Aproximația curentă fiind inferioară optimului, iar **derivata fiind negativă**, corecția **se adaugă** aproximației pentru a se apropia mai mult de optim.
- Dacă este adăugată **o cantitate prea mare**, se ajunge în zona de **derivată pozitivă** și următorul factor de corecție **se va scădea** din aproximația curentă, superioară optimului.

Convergența la punctul de optim poate fi realizată fie printr-un șir monoton de aproximații, fie prin intermediul unui oscilant.



Testul de stop

$$\|\Delta_k\| = \left\| \left[\diamond \mathcal{V}'(\theta_k) \right]^{-1} \nabla \mathcal{V}(\theta_k) \right\| < \varepsilon$$

- Eficiența se măsoară prin **numărul de iterații necesar verificării testului de stop**.

În vecinătatea optimului, norma gradientului este aproximativ nulă.

4 Metode de identificare și validare

4.4 Metode bazate pe optimizarea parametrilor

Metoda Newton-Raphson (continuare)

Algoritmul Newton-Raphson cu pas constant



Date de intrare

$\mathcal{V} : \mathbb{R}^{n_\theta} \rightarrow \mathbb{R}$ (funcție criteriu, de 2 ori derivabilă)
 $\varepsilon > 0$ (prag de precizie)



Inițializare

$\theta_0 \in \mathbb{R}^{n_\theta} \rightarrow$ ales fie arbitrar, fie cu ajutorul unui algoritm specific
 $\nabla \mathcal{V}(\theta_0) \rightarrow$ gradientul inițial
 $\diamond \mathcal{V}(\theta_k) \rightarrow$ matricea Hessiană inițială
 $k = 0 \rightarrow$ indicele iterativ inițial



Bucă iterativă

⌚ Cît timp

$$\left\| [\diamond \mathcal{V}(\theta_k)]^{-1} \nabla \mathcal{V}(\theta_k) \right\| \geq \varepsilon$$



Concept definit
în continuare.

① Se reactualizează aproximația optimului

$$\theta_{k+1} = \theta_k - [\diamond \mathcal{V}(\theta_k)]^{-1} \nabla \mathcal{V}(\theta_k)$$

② Se reactualizează gradientul și matricea Hessiană

$$\nabla \mathcal{V}(\theta_k) \leftarrow \nabla \mathcal{V}(\theta_{k+1})$$

③ Se trece la pasul următor

$$k \leftarrow k + 1$$

$$\diamond \mathcal{V}(\theta_k) \leftarrow \diamond \mathcal{V}(\theta_{k+1})$$



Date de ieșire

$\theta_k \rightarrow$ aproximația de precizie ε
 $k \rightarrow$ numărul de iterații pentru atingerea preciziei dorite

⚡ Algoritmul este sensibil la inițializare, în sensul că, în general, va converge către optimul cel mai apropiat de aceasta.

4 Metode de identificare și validare

4.4 Metode bazate pe optimizarea parametrilor

Metoda Newton-Raphson (continuare)

- ⊗ Utilizarea MNR (cu pas constant) este **deficitară** în următoarele cazuri principale:
- Funcția criteriu are o **regularitate slabă** în vecinătatea optimului vizat (adică prezintă **oscilații mari** în acea vecinătate).
 - Funcția criteriu este **afectată de zgomote importante** în vecinătatea optimului vizat.
 - Optimul vizat al funcției criteriu este **situat pe un platou**.
- De regulă, în primele 2 cazuri, se renunță la MNR și se adoptă o **strategie evoluționistă**.
 - În ultimul caz, MNR conduce la un **număr imens de iterații**, din cauza faptului că, pe platou, **atât norma gradientului cât și spectrul matricii Hessiene sunt aproximativ nule**.

⚡ Corecția este **imprecis determinată**, în special din cauza problemelor de natură numerică induse de **inversarea matricii Hessiene**.

Ce se poate face?

Termenul corector poate fi **ajustat adaptiv cu un scalar**, astfel încât viteza de convergență să crească prin **efectuarea unui salt peste platou**.

$$\theta_{k+1} = \theta_k - [\diamond \mathcal{V}(\theta_k)]^{-1} \nabla \mathcal{V}(\theta_k) \quad \forall k \in \mathbb{N}$$

1 pas constant

$$\theta_{k+1} = \theta_k - \alpha_k [\diamond \mathcal{V}(\theta_k)]^{-1} \nabla \mathcal{V}(\theta_k) \quad \forall k \in \mathbb{N}$$

pas variabil

Cum poate fi reactualizat pasul variabil?

Prin utilizarea MNR cu **pas constant** pentru optimizarea unei **funcții criteriu scalare adaptive**.

$$\mathcal{F}_k(\alpha) = \mathcal{V}(\theta_k - \alpha [\diamond \mathcal{V}(\theta_k)]^{-1} \nabla \mathcal{V}(\theta_k)) \quad \forall \alpha \in \mathbb{R}$$

4 Metode de identificare și validare

4.4 Metode bazate pe optimizarea parametrilor

Metoda Newton-Raphson (continuare)

Algoritmul Newton-Raphson cu pas variabil

Date de intrare

$\mathcal{V} : \mathbb{R}^{n_\theta} \rightarrow \mathbb{R}$ (funcție criteriu, de 2 ori derivabilă)
 $\varepsilon > 0$ (prag de precizie)

Inițializare

$\theta_0 \in \mathbb{R}^{n_\theta}$, $\alpha_0 \in \mathbb{R}^*$ → alese fie arbitrar, fie cu ajutorul unui algoritm specific
 $\nabla \mathcal{V}(\theta_0)$ → gradientul inițial
 $\diamond \mathcal{V}(\theta_k)$ → matricea Hessiană inițială
 $k = 0$ → indicele iterativ inițial

Exercițiu

- Justificați acest algoritm în manieră riguroasă.

Bucă iterativă

⌚ Cît timp

$$|\alpha_k| \cdot \left\| [\diamond \mathcal{V}(\theta_k)]^{-1} \nabla \mathcal{V}(\theta_k) \right\| \geq \varepsilon$$

👉 Se vor utiliza regulile cunoscute de derivare pentru reactualizarea pasului variabil.

① Se reactualizează aproximația optimului

$$\theta_{k+1} = \theta_k - \alpha_k [\diamond \mathcal{V}(\theta_k)]^{-1} \nabla \mathcal{V}(\theta_k)$$

② Se reactualizează pasul variabil

$$\alpha_{k+1} = \alpha_k + \frac{[\nabla \mathcal{V}(\theta_{k+1})]^T [\diamond \mathcal{V}(\theta_k)]^{-1} \nabla \mathcal{V}(\theta_k)}{[\nabla \mathcal{V}(\theta_k)]^T [\diamond \mathcal{V}(\theta_k)]^{-1} [\diamond \mathcal{V}(\theta_{k+1})] [\diamond \mathcal{V}(\theta_k)]^{-1} \nabla \mathcal{V}(\theta_k)}$$

③ Se reactualizează gradientul și matricea Hessiană

$$\nabla \mathcal{V}(\theta_k) \leftarrow \nabla \mathcal{V}(\theta_{k+1})$$

④ Se trece la pasul următor

$$k \leftarrow k + 1$$

$$\diamond \mathcal{V}(\theta_k) \leftarrow \diamond \mathcal{V}(\theta_{k+1})$$

Date de ieșire

θ_k → aproximația de precizie ε
 k → numărul de iterații pentru atingerea preciziei dorite

4 Metode de identificare și validare

4.4 Metode bazate pe optimizarea parametrilor

Metoda Newton-Raphson (continuare)

- MNR poate fi utilizată și pentru a rezolva unele ecuații transcendente sau în aproximarea unor numere transcendente cum ar fi π , e , $\ln 2$, etc.


Exemplu

$$\sin(x) = 1 \Rightarrow x = \frac{\pi}{2}$$

- Aproximarea numărului $\pi/2$ se poate realiza plecând de la funcția criteriu a cărei primă derivată este: $f'(x) = \sin(x) - 1$
- Este evident că anularea derivatei conduce la optimizarea funcției: $f(x) = -\cos(x) - x + C$

Exercițiu

- Folosind exemplul anterior, determinați numărul π cu 7 zecimale exacte.
- Pentru a diminua complexitatea metodei, se poate renunța la a doua derivată.



Exemplu

Metoda gradientului (MV)

- De această dată, aproximația următoare se determină prin intersectarea tangentei (hiperplanului tangent) care trece prin punctul curent $(\theta_k, \mathcal{V}(\theta_k))$ cu axa orizontală (hiperplanul principal).

Exercițiu

$$\theta_{k+1} = \theta_k - \nabla \mathcal{V}(\theta_k) \quad \forall k \in \mathbb{N}$$

MV cu pas constant

$$\theta_{k+1} = \theta_k - \alpha_k \nabla \mathcal{V}(\theta_k)$$

$$\alpha_{k+1} = \alpha_k + \left[\nabla \mathcal{V}(\theta_{k+1}) \right]^T \nabla \mathcal{V}(\theta_k) \quad \forall k \in \mathbb{N}$$

MV cu pas variabil

😊 MV este utilizată atunci când derivata a doua fie nu există, fie nu se poate evalua.

☹ Viteza de convergență a MV este însă modestă chiar și în cazul pasului variabil.

4 Metode de identificare și validare

4.4 Metode bazate pe optimizarea parametrilor

Metoda Gauss-Newton (MGN)

Metodă aplicabilă în cazul funcțiilor criteriu **de tip pătratic** (cum sunt și cele din IS).

$$\mathcal{V}(\theta) = \sum_{n=1}^N \varepsilon^2[n, \theta]$$

reziduu

- Dacă funcția criteriu este **de 2 ori derivabilă**, MNR poate fi adaptată astfel încât **să se evite evaluarea matricii Hessiene**.

Există 2 abordări

Aproximarea matricii Hessiene

Liniarizarea reziduurilor

Exercițiu

$$\mathcal{V}(\theta) = \sum_{n=1}^N \varepsilon^2[n, \theta]$$

$$\nabla \mathcal{V}(\theta) = 2 \sum_{n=1}^N \varepsilon[n, \theta] \nabla \varepsilon[n, \theta] \quad \forall \theta \in \mathbb{R}^{n_\theta}$$

$$\diamond \mathcal{V}(\theta) = 2 \sum_{n=1}^N \nabla \varepsilon[n, \theta] [\nabla \varepsilon[n, \theta]]^T + 2 \sum_{n=1}^N \varepsilon[n, \theta] \diamond \varepsilon[n, \theta] \quad \forall \theta \in \mathbb{R}^{n_\theta}$$

termen principal

termen parazit

- Dacă se efectuează un număr suficient de mare de iterații, **reziduurile deponderează puternic** matricea Hessiană a acestora în termenul parazit.

$$\diamond \mathcal{V}(\theta) \cong 2 \sum_{n=1}^N \nabla \varepsilon[n, \theta] [\nabla \varepsilon[n, \theta]]^T \quad \forall \theta \in \mathbb{R}^{n_\theta}$$

♣ În vecinătatea optimului, reziduul are valori neglijabile.

4 Metode de identificare și validare

4.4 Metode bazate pe optimizarea parametrilor

Metoda Gauss-Newton (continuare)

MNR

$$\theta_{k+1} = \theta_k - \alpha_k \left[\diamond \mathcal{V}(\theta_k) \right]^{-1} \nabla \mathcal{V}(\theta_k) \quad \forall k \in \mathbb{N}$$

$$\nabla \mathcal{V}(\theta) = 2 \sum_{n=1}^N \varepsilon[n, \theta] \nabla \varepsilon[n, \theta] \quad \forall \theta \in \mathbb{R}^{n\theta}$$

$$\mathcal{V}(\theta) = \sum_{n=1}^N \varepsilon^2[n, \theta]$$

$$\diamond \mathcal{V}(\theta) \cong 2 \sum_{n=1}^N \nabla \varepsilon[n, \theta] [\nabla \varepsilon[n, \theta]]^T \quad \forall \theta \in \mathbb{R}^{n\theta}$$

$$\theta_{k+1} = \theta_k - \alpha_k \left[\sum_{n=1}^N \nabla \varepsilon[n, \theta_k] [\nabla \varepsilon[n, \theta_k]]^T \right]^{-1} \left[\sum_{n=1}^N \varepsilon[n, \theta_k] \nabla \varepsilon[n, \theta_k] \right] \quad \forall k \in \mathbb{N}$$

⚡ Deși matricea Hessiană a criteriului pătratic nu a fost înlăturată din expresia iterativă principală, în calculul acesteia nu intervine decât gradientul reziduurilor.

Exercițiu

- A doua abordare se bazează pe **liniarizarea reziduurilor**, adică pe **aproximarea reziduurilor prin dezvoltarea acestora în serie Taylor de ordin I**.
- Să se arate că ecuația iterativă a **MGN** obținută din **MNR** prin liniarizarea reziduurilor, coincide cu cea din abordarea anterioară.

$$\varepsilon[n, \theta] \cong \varepsilon[n, \theta_k] + [\nabla \varepsilon[n, \theta_k]]^T (\theta - \theta_k)$$

$$\forall n \in \overline{1, N} \quad \forall \theta \in \mathbb{R}^{n\theta}$$

4 Metode de identificare și validare

4.4 Metode bazate pe optimizarea parametrilor

Caracteristici ale tehnicilor de optimizare în IS

- Majoritatea covârșitoare a metodelor de optimizare **nu pot garanta că optimul aproximat este cel global**, ci, eventual **cel mai apropiat de inițializarea procesului iterativ**.
- Metodele de optimizare funcționează numai pentru **funcțiile criteriu cărora li se poate evalua gradientul (prima derivată) și, eventual, matricea Hessiană (derivata a doua)**.

🕯 În multe aplicații, această exigență este imposibil de satisfăcut.

- Pentru a asigura **eficiența** algoritmilor bazați pe TO, este de dorit ca **funcțiile criteriu să fie cât mai netede, cu oscilații puține în jurul optimului vizat și fără paliere**.

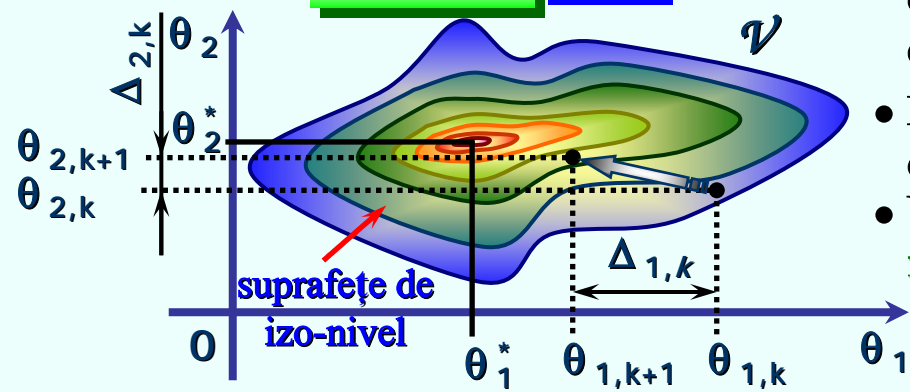
🕯 Din cauza perturbațiilor care corup datele măsurate, funcțiile criteriu din cadrul IS sunt în general extrem de neregulate.

Tehnicile de optimizare ca MNR sau MGN sunt utilizate în IS mai mult ca **instrumente auxiliare integrate în alte metode mai precise**.

- Parametrii care pot fi identificați cu ajutorul tehnicilor de optimizare au, de regulă, **precizii diferite**.

Exemplu

$$n\theta = 2$$



- Aproximația de ordin $k+1$ se obține din aproximația de ordin k prin contribuția a două componente de corecție diferite: una **mai mare** și alta **mai mică**.
- Parametrul θ_1 este **mai puțin sensibil (identificabil)** decât parametrul θ_2 .
- Un **nou test de stop** poate asigura **precizia minimă a fiecărei componente (cu scăderea vitezei de convergență)**:

$$\max_{i \in \{1, n\theta\}} |\theta_{i,k+1} - \theta_{i,k}| < \frac{\varepsilon}{n\theta}$$