


4 Metode de identificare și validare

4.9 Metode adaptive de identificare

- Majoritatea proceselor furnizoare de date **sunt neliniare** și/sau **posedă parametri variabili în timp**.
- Identificarea proceselor cu parametri variabili în timp se realizează cu ajutorul **modelelor și metodelor adaptive (recursive)**.
- Prin **identificarea adaptivă**, se urmărește **asigurarea unui compromis între două caracteristici opuse** ale estimației parametrilor necunoscuți (variabili pe orizontul de măsură):



Principiul metodelor adaptive

Estimația vectorului parametrilor necunoscuți se reactualizează folosind datele măsurate pe orizontul de adaptare.

$$\hat{\theta}_{K\left[\frac{k}{K}\right]} = \hat{\theta}_{K\left[\frac{k-1}{K}\right]} + \Delta_{K\left[\frac{k}{K}\right]} \quad \forall k \in \mathbb{N}^*$$

Corecție

Adaptabilitatea scade, în timp ce **precizia crește** odată cu dimensiunea orizontului de adaptare.

Cu cât se achiziționează **mai multe date** între momentele de reactualizare, cu atât **adaptarea se efectuează mai rar**, modelul fiind incapabil să surprindă variațiile caracteristicilor procesului între aceste momente.

În schimb, **precizia modelului crește**, deoarece parametrii săi sunt determinați cu ajutorul unui set mai bogat de date.


4 Metode de identificare și validare

4.9 Metode adaptive de identificare

⊗ Asigurarea compromisului precizie-adaptabilitate este dificilă.

Exemplu

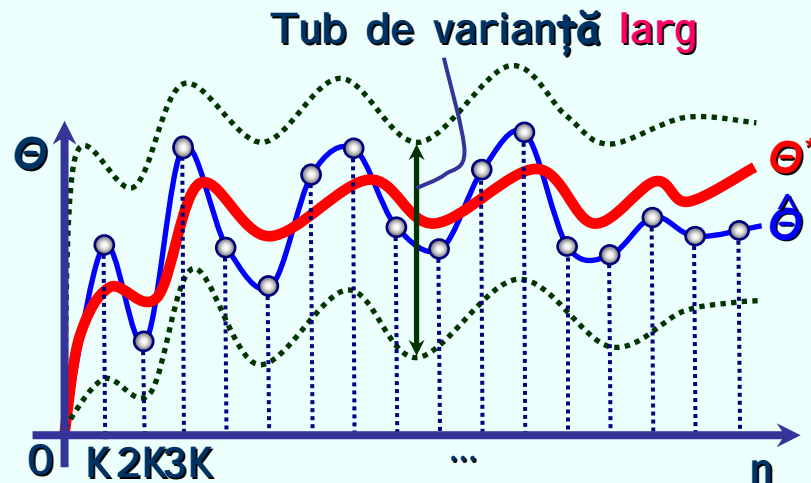
Cazul parametrului scalar, variabil în timp.



Orizont de adaptare larg

⊙ Valorile estimate ale parametrului sunt relativ apropiate de cele adevărate și tubul de varianță este relativ îngust.

⊗ Graficul parametrului estimat este neted, deci modelul sesizează mai puțin variațiile locale ale parametrului adevărat.



Orizont de adaptare îngust

⊗ Valorile estimate ale parametrului sunt relativ depărtate de cele adevărate și tubul de varianță este relativ larg.

⊙ Graficul parametrului estimat urmărește variațiile locale ale parametrului adevărat, cu o anumită acuratețe.



$K = ?$



Se sacrifică precizia în favoarea adaptabilității.

$K = 1$

$$\hat{\theta}_k = \hat{\theta}_{k-1} + \Delta_k \quad \forall k \in \mathbb{N}^*$$

④ Metode de identificare și validare

④.② Metode adaptive de identificare

Metodele abordate în acest curs

Metoda Celor Mai Mici Pătrate
Recursivă (MCMMP-R)

MCMMP-R cu fereastră
exponențială (MCMMP-R λ)

MCMMP-R cu fereastră
dreptunghiulară (MCMMP-R \square)

MCMMP-R bazată pe descompunerea QR
(MCMMPQR-R)

Metoda Variabilelor Instrumentale
Recursivă (MVI-R)

MVI-R cu fereastră exponențială
(MVI-R λ)

MVI-R cu fereastră
dreptunghiulară (MVI-R \square)

Alte metode adaptive (de precizie și complexitate ridicate)

Metode de Gradient
Recursive (M ∇ -R)

MCMMP-E Recursivă
(MCMMP-E-R)

MMEP Recursivă
(MMEP-R)

MRPL Recursivă
(MRPL-R)

Metoda Kalman-Bucy
(MKB)

🔔 Va fi descrisă în
finalul cursului de IS.

Strategia
generală

Expresia generală a corecției pentru metoda recursivă (on-line) va fi dedusă plecînd de la expresia finală a estimației din metoda nerecursivă (off-line).

4 Metode de identificare și validare

4.9 Metode adaptive de identificare

De ce corecția aplicată vectorului curent al parametrilor estimați este aditivă?



Acest rezultat remarcabil se datorează în realitate **IE**, care permite aproximarea mediei statistice cu o medie temporală **exprimată prin intermediul unei sume**.



$$\hat{\theta}_k = \hat{\theta}_{k-1} + \Delta_k$$

$\forall k \in \mathbb{N}^*$

De asemenea

Eficiența crescută a algoritmilor adaptivi de identificare se datorează unui rezultat din **Teoria Matricilor**.

Lema 1 (Inversarea matricilor modificate aditiv de un produs exterior)

Fie $A \in \mathbb{R}^{n \times n}$ o matrice inversabilă și $b \in \mathbb{R}^n$, $c \in \mathbb{R}^n$ doi vectori cu dimensiunile egale (compatibili dimensional cu matricea A), avînd proprietatea: $c^T A^{-1} b \neq -1$. Atunci matricea $A + bc^T$ este inversabilă, inversa acesteia avînd exprimarea:

$$(A + bc^T)^{-1} = A^{-1} - \frac{A^{-1}bc^T A^{-1}}{1 + c^T A^{-1}b}.$$

Demonstrație




Exercițiu

(prin verificare directă)

Caz particular

$$b = c$$



$$(A + bb^T)^{-1} = A^{-1} - \frac{A^{-1}bb^T A^{-1}}{1 + b^T A^{-1}b}$$

Dacă inversa unei matrici este deja evaluată, prin adăugarea unui produs exterior la matricea originală, rezultă o nouă matrice a cărei inversă poate fi evaluată **fără a efectua inversarea explicită a acesteia** (se efectuează **doar inversarea unui scalar**).



4 Metode de identificare și validare

4.9 Metode adaptive de identificare

MCMMP-R – varianta de bază

MCMMP nerecursivă (off-line)

🔥 Pentru orice model de regresie liniară.

$$\hat{\theta}_k = \left(\sum_{n=1}^k \varphi[n] \varphi^T[n] \right)^{-1} \left(\sum_{n=1}^k \varphi[n] y[n] \right) \quad \forall k \in \mathbb{N}^*$$

$$\mathbf{P}(\hat{\theta}_N) = \lambda^2 \left(\sum_{n=1}^N \varphi[n] \varphi^T[n] \right)^{-1}$$

matricea de auto-covarianță a erorii de estimare

\mathbf{P}_k

← Notăție sugerată de **Teorema fundamentală a MCMMP**.

- Inversele matricilor \mathbf{P}_k verifică o relație recurentă evidentă:

$$\mathbf{P}_k^{-1} \stackrel{\text{def}}{=} \sum_{n=1}^k \varphi[n] \varphi^T[n] = \sum_{n=1}^{k-1} \varphi[n] \varphi^T[n] + \varphi[k] \varphi^T[k] = \mathbf{P}_{k-1}^{-1} + \varphi[k] \varphi^T[k], \quad \forall k \in \mathbb{N}^*.$$

\mathbf{P}_{k-1}^{-1}

$\mathbf{P}_0 \in \mathbb{R}^{n\theta \times n\theta}$

➔ Matrice inițială care trebuie să verifice proprietățile tuturor matricilor succesive: **inversabilitate, simetrie, pozitiv (semi-definire).**

- Folosind același artificiu, estimația off-line se poate de asemenea exprima recursiv:

$$\begin{aligned} \hat{\theta}_k &= \mathbf{P}_k \left(\sum_{n=1}^k \varphi[n] y[n] \right) = \mathbf{P}_k \left(\underbrace{\sum_{n=1}^{k-1} \varphi[n] y[n]}_{\mathbf{P}_{k-1}^{-1} \hat{\theta}_{k-1}} + \varphi[k] y[k] \right) = \mathbf{P}_k \left(\mathbf{P}_{k-1}^{-1} \hat{\theta}_{k-1} + \varphi[k] y[k] \right) \\ &= \mathbf{P}_k \left[\left(\mathbf{P}_k^{-1} - \varphi[k] \varphi^T[k] \right) \hat{\theta}_{k-1} + \varphi[k] y[k] \right] = \hat{\theta}_{k-1} + \mathbf{P}_k \varphi[k] \left(y[k] - \varphi^T[k] \hat{\theta}_{k-1} \right), \quad \forall k \in \mathbb{N}^*. \end{aligned}$$

$\theta_0 \in \mathbb{R}^{n\theta}$

inițializare prestabilită

4 Metode de identificare și validare

4.9 Metode adaptive de identificare

MCMMP-R – varianta de bază (continuare)

Așadar

$$\hat{\theta}_k = \hat{\theta}_{k-1} + \underbrace{\mathbf{P}_k \varphi[k]}_{\Delta_k} \left(y[k] - \varphi^T[k] \hat{\theta}_{k-1} \right)$$

➡ O primă relație recursivă.

Δ_k

Corecție

$\forall k \in \mathbb{N}^*$

⊗ Ineficientă, deoarece la fiecare pas trebuie inversată o matrice.

- Corecția este formată din 2 factori:

$\varepsilon[k] \stackrel{\text{def}}{=} y[k] - \varphi^T[k] \hat{\theta}_{k-1}$ ➡ Eroarea de predicție cu un pas.

$\gamma_k \stackrel{\text{def}}{=} \mathbf{P}_k \varphi[k]$ ➡ Cîștig (de sensibilitate), cu rolul de a pondera eroarea de predicție pentru fiecare componentă a vectorului parametrilor estimați.

$$\hat{\theta}_k = \hat{\theta}_{k-1} + \gamma_k \varepsilon[k]$$

$\forall k \in \mathbb{N}^*$

⚡ Nu toți parametrii sunt la fel de sensibili la reactualizare.

Cum poate fi mărită eficiența metodei?

Metoda ar fi mult mai eficientă dacă inversarea matricilor s-ar putea efectua **tot de o manieră recursivă**.

Lema 1

$$\mathbf{P}_k = \left(\mathbf{P}_{k-1}^{-1} + \varphi[k] \varphi^T[k] \right)^{-1} = \mathbf{P}_{k-1} - \frac{\mathbf{P}_{k-1} \varphi[k] \varphi^T[k] \mathbf{P}_{k-1}}{1 + \varphi^T[k] \mathbf{P}_{k-1} \varphi[k]}$$

$\forall k \in \mathbb{N}^*$

Efortul de calcul efectuat inițial pentru inversare este **conservat** de-a lungul procesului recursiv, adaptarea inverselor necesitînd **numai împărțirea la un scalar**.

4 Metode de identificare și validare

4.9 Metode adaptive de identificare

MCMMP-R – varianta de bază (continuare)



Mai mult, eficiența metodei poate crește și printr-o **organizare judicioasă a memoriei**.

- Folosind lema de inversare matricială se poate evalua și **cîștigul de sensibilitate**:

$$\begin{aligned} \gamma_k &\stackrel{\text{def}}{=} \mathbf{P}_k \boldsymbol{\varphi}[k] = \mathbf{P}_{k-1} \boldsymbol{\varphi}[k] - \frac{\mathbf{P}_{k-1} \boldsymbol{\varphi}[k] \boldsymbol{\varphi}^T[k] \mathbf{P}_{k-1} \boldsymbol{\varphi}[k]}{1 + \boldsymbol{\varphi}^T[k] \mathbf{P}_{k-1} \boldsymbol{\varphi}[k]} \quad \text{se aduce la același numitor} \\ &\quad \text{Lema 1} \\ &= \frac{\mathbf{P}_{k-1} \boldsymbol{\varphi}[k] + \cancel{\mathbf{P}_{k-1} \boldsymbol{\varphi}[k] \boldsymbol{\varphi}^T[k] \mathbf{P}_{k-1} \boldsymbol{\varphi}[k]} - \cancel{\mathbf{P}_{k-1} \boldsymbol{\varphi}[k] \boldsymbol{\varphi}^T[k] \mathbf{P}_{k-1} \boldsymbol{\varphi}[k]}}{1 + \boldsymbol{\varphi}^T[k] \mathbf{P}_{k-1} \boldsymbol{\varphi}[k]} = \frac{\mathbf{P}_{k-1} \boldsymbol{\varphi}[k]}{1 + \boldsymbol{\varphi}^T[k] \mathbf{P}_{k-1} \boldsymbol{\varphi}[k]}, \quad \forall k \in \mathbb{N}^*. \end{aligned}$$

Sumarul relațiilor MCMMP-R (on line)

Eroarea de predicție

$$\varepsilon[k] = y[k] - \boldsymbol{\varphi}^T[k] \hat{\boldsymbol{\theta}}_{k-1}$$

Cîștigul de sensibilitate

$$\gamma_k = \frac{\mathbf{P}_{k-1} \boldsymbol{\varphi}[k]}{1 + \boldsymbol{\varphi}^T[k] \mathbf{P}_{k-1} \boldsymbol{\varphi}[k]}$$

Matricea de auto-covarianță a erorii de estimare

$$\mathbf{P}_k = \mathbf{P}_{k-1} - \gamma_k \boldsymbol{\varphi}^T[k] \mathbf{P}_{k-1}$$

Vectorul parametrilor estimați

$$\hat{\boldsymbol{\theta}}_k = \hat{\boldsymbol{\theta}}_{k-1} + \gamma_k \varepsilon[k]$$

$\forall k \in \mathbb{N}^*$

Inițializare?

➔ Informații preliminare **absente**:

$$\boldsymbol{\theta}_0 \in \mathbb{R}^{n_\theta}$$

$$\mathbf{P}_0 = \alpha \mathbf{I}_{n_\theta} > 0$$

arbitrar (eventual nul)

➔ Informații preliminare **disponibile** sub forma unui **set redus de date**:

$$\hat{\boldsymbol{\theta}}_0 = \left(\sum_{n=1}^{N_0} \boldsymbol{\varphi}[n] \boldsymbol{\varphi}^T[n] \right)^{-1} \left(\sum_{n=1}^{N_0} \boldsymbol{\varphi}[n] y[n] \right)$$

MCMMP off-line

\mathbf{P}_0

231



4 Metode de identificare și validare

4.9 Metode adaptive de identificare

Algoritmul adaptiv al Celor Mai Mici Pătrate



Date de intrare

$\mathcal{D}_{N_0} = \{\varphi[n]\}_{n \in \overline{1, N_0}} \cup \{y[n]\}_{n \in \overline{1, N_0}}$ (un set redus de date măsurate, dacă este posibil)
 $n\theta$ (indicele structural al modelului de identificare)



Inițializare

$\mathbf{P}_0 \in \mathbb{R}^{n\theta \times n\theta}$ $\mathbf{\theta}_0 \in \mathbb{R}^{n\theta} \rightarrow$ neutră sau personalizată, după caz
 $k = 0 \rightarrow$ indicele iterativ inițial



Bucă iterativă

⌚ Pentru $k \geq 1$

① Se evaluează eroarea de predicție curentă: $\varepsilon[k] = y[k] - \varphi^T[k] \hat{\mathbf{\theta}}_{k-1}$

② Se evaluează vectorul auxiliar: $\xi_k = \mathbf{P}_{k-1} \varphi[k]$

③ Se evaluează câștigul de senzitivitate: $\gamma_k = \frac{\xi_k}{1 + \varphi^T[k] \xi_k}$

④ Se reactualizează matricea de auto-covarianță a erorii de estimare: $\mathbf{P}_k = \mathbf{P}_{k-1} - \gamma_k \xi_k^T$

⑤ Se reactualizează vectorul parametrilor estimați: $\hat{\mathbf{\theta}}_k = \hat{\mathbf{\theta}}_{k-1} + \gamma_k \varepsilon[k]$

⑥ Se incrementează indicele curent: $k \leftarrow k + 1$



Date de ieșire

$\{\hat{\mathbf{\theta}}_k\}_{k \in \mathbb{N}}$

Parametrii modelului reactualizați
la fiecare pas de adaptare.

4 Metode de identificare și validare

4.9 Metode adaptive de identificare

MCMMP-R – varianta de bază (continuare)

Cum poate fi caracterizată precizia estimației adaptive?



Tot prin intermediul **conceptului de consistență**, dar adaptat la anumite procese cu parametri variabili.

Ipoteză

$$\theta_{\infty}^* \stackrel{\text{def}}{=} \lim_{n \rightarrow \infty} \left[E \left\{ \varphi[n] \varphi^T[n] \right\} \right]^{-1} \left[E \left\{ \varphi[n] y[n] \right\} \right]$$

Parametrii adevărați se stabilizează la valori constante.

- Se va arăta că parametrii estimați folosind **MCMMP-R** tind, la rîndul lor, la valorile constante, **indiferent de inițializarea utilizată**.
- Se pleacă de la următoarea identitate evidentă:
- Apoi, se deduc relații recurente pentru fiecare din cei **2 factori**.

$$\hat{\theta}_k = \hat{\theta}_k \iff \hat{\theta}_k = (kP_k) \left(\frac{1}{k} P_k^{-1} \hat{\theta}_k \right) \quad \forall k \in \mathbb{N}^*$$

$$kP_k = \left(\frac{1}{k} P_k^{-1} \right)^{-1} = \left[\frac{1}{k} \left(P_{k-1}^{-1} + \varphi[k] \varphi^T[k] \right) \right]^{-1} = \dots = \left[\frac{1}{k} \left(P_0^{-1} + \sum_{n=1}^k \varphi[n] \varphi^T[n] \right) \right]^{-1}, \quad \forall k \in \mathbb{N}^*.$$

$$\begin{aligned} \frac{1}{k} P_k^{-1} \hat{\theta}_k &= \frac{1}{k} P_k^{-1} \left[\hat{\theta}_{k-1} + P_k \varphi[k] \left(y[k] - \varphi^T[k] \hat{\theta}_{k-1} \right) \right] = \\ &= \frac{1}{k} \left[\left(P_{k-1}^{-1} + \varphi[k] \varphi^T[k] \right) \hat{\theta}_{k-1} + \varphi[k] y[k] - \varphi[k] \varphi^T[k] \hat{\theta}_{k-1} \right] = \frac{1}{k} \left(P_{k-1}^{-1} \hat{\theta}_{k-1} + \varphi[k] y[k] \right) = \\ &= \dots = \frac{1}{k} \left(P_0^{-1} \hat{\theta}_0 + \sum_{n=1}^k \varphi[n] y[n] \right), \quad \forall k \in \mathbb{N}^*. \end{aligned}$$

4 Metode de identificare și validare

4.9 Metode adaptive de identificare

MCMMP-R – varianta de bază (continuare)

Așadar

$$\hat{\theta}_k = \left[\frac{1}{k} \left(\mathbf{P}_0^{-1} + \sum_{n=1}^k \varphi[n] \varphi^T[n] \right) \right]^{-1} \left[\frac{1}{k} \left(\mathbf{P}_0^{-1} \hat{\theta}_0 + \sum_{n=1}^k \varphi[n] y[n] \right) \right]$$

☞ Contribuția inițializării se atenuează după o lege hiperbolică.

$\forall k \in \mathbb{N}^*$

Algoritmul recursiv de bază **funcționează și în cazul unei inițializări necorespunzătoare** (de exemplu, dacă matricea \mathbf{P}_0 nu este pozitiv definită), **dar viteza de convergență scade**.

Rezultă

$$\begin{aligned} \lim_{k \rightarrow \infty} \hat{\theta}_k &= \left\{ \lim_{k \rightarrow \infty} \left[\frac{1}{k} \left(\mathbf{P}_0^{-1} + \sum_{n=1}^k \varphi[n] \varphi^T[n] \right) \right]^{-1} \right\} \left\{ \lim_{k \rightarrow \infty} \frac{1}{k} \left(\mathbf{P}_0^{-1} \hat{\theta}_0 + \sum_{n=1}^k \varphi[n] y[n] \right) \right\} = \\ &= \underbrace{\left[\lim_{k \rightarrow \infty} \frac{\mathbf{P}_0^{-1}}{k} + \lim_{k \rightarrow \infty} \frac{1}{k} \sum_{n=1}^k \varphi[n] \varphi^T[n] \right]^{-1}}_0 \underbrace{\left[\lim_{k \rightarrow \infty} \frac{\mathbf{P}_0^{-1} \hat{\theta}_0}{k} + \lim_{k \rightarrow \infty} \frac{1}{k} \sum_{n=1}^k \varphi[n] y[n] \right]}_0 = \\ &= \lim_{n \rightarrow \infty} \left[E \{ \varphi[n] \varphi^T[n] \} \right]^{-1} \left[E \{ \varphi[n] y[n] \} \right] = \theta_{\infty}^* . \end{aligned}$$

IE

☞ În general, însă, sunt dificil de cuantificat atât precizia, cât și mai ales adaptabilitatea (capacitatea de urmărire a) estimației parametrilor necunoscuți.

Exercițiu

- Să se refacă raționamentele anterioare pentru a proiecta și analiza **Algoritmul recursiv al Variabilelor Instrumentale**.

4 Metode de identificare și validare

4.9 Metode adaptive de identificare


MCMMP-R – variante cu fereastră

- Există situații (în special în cazul proceselor rapid variabile) în care contribuția datelor anterioare momentului curent de reactualizare **trebuie atenuată cu rapiditate controlată**.
- Istoria comportamentului procesului poate distorsiona rezultatul operației de adaptare curentă **dacă** datele achiziționate **devin rapid învechite** și **tind să nu mai corespundă comportamentului actual al procesului**.

Cum poate fi controlată atenuarea istoriei datelor?



Prin intermediul **ferestrelor culisante** fie de-a lungul setului de date, fie de-a lungul erorilor de predicție.



- În acest curs, va fi abordată problema estimării recursive a parametrilor prin **minimizarea** unui **criteriu pătratic** în care **pătratul erorii de predicție curente este ponderat de o fereastră culisantă nenegativă**.

- Selecția datelor are loc prin înmulțirea valorilor ferestrei (**ponderilor**) cu valorile omoloage ale datelor.

♣ În cazul modelelor de regresie liniară, datele sunt ponderate de **radicalul ferestrei**.

$$\mathcal{V}(\theta) = \sum_{n=1}^N w_N[n] \varepsilon^2[n, \theta]$$

4 Metode de identificare și validare


4.9 Metode adaptive de identificare

MCMMP-R – variante cu fereastră (continuare)

- Deponderarea **prea drastică** a datelor implică **deteriorarea sensibilă** a preciziei modelului de identificare, astfel că **fereastra trebuie aleasă cu atenție**.
- Aplicarea ferestrelor de ponderare asupra datelor este o **operație frecvent întâlnită** în aplicațiile de PS.
- Spre deosebire de ferestrele din aplicațiile de PS (care, de regulă, sunt **simetrice pe orizontul de măsură**), ferestrele utilizate în aplicațiile de IS pot fi **asimetrice**.

Ferestre de culisare frecvent utilizate în aplicațiile de IS

Exponențială




$$w_N[n] \stackrel{\text{def}}{=} \lambda^{N-n} \quad \forall k \in \mathbb{N}$$

Factor de uitare

De regulă

$$\lambda \in [0.95, 1]$$

Dreptunghiulară



$$w_{M,N}[n] \stackrel{\text{def}}{=} \begin{cases} 1 & , n \in \overline{N-M+1, N} \\ 0 & , n \in \overline{1, N-M} \end{cases} \quad \forall k \in \mathbb{N}$$

4 Metode de identificare și validare

4.9 Metode adaptive de identificare

MCMMP-R – variante cu fereastră (continuare)

Exerciții

MCMMP-R λ

MVI-R λ

(deducerea relațiilor recursive, algoritmul eficient, inițializare, consistență)

MCMMP-R cu fereastră dreptunghiulară (MCMMP-R \square)

- Dacă apare **problema înlăturării complete a datelor învechite**, mai utilă este **fereastra dreptunghiulară**, care permite aplicarea unui **factor de uitare totală** asupra datelor situate în afara deschiderii sale.



$$w_{M,N}[n] \stackrel{\text{def}}{=} \begin{cases} 1 & , n \in \overline{N-M+1, N} \\ 0 & , n \in \overline{1, N-M} \end{cases} \quad \forall k \in \mathbb{N}$$

$$\mathcal{V}(\theta) \stackrel{\text{def}}{=} \sum_{n=1}^N w_N[n] \varepsilon^2[n, \theta] = \sum_{n=N-M+1}^N \varepsilon^2[n, \theta]$$

MCMMP
off-line

- Pentru a deduce expresia corecției, se adoptă aceeași strategie ca în cazul MCMMP-R.
- Relația recurentă a inverselor matricilor \mathbf{P}_k :

$$\hat{\theta}_k = \left(\sum_{n=k-M+1}^k \varphi[n] \varphi^T[n] \right)^{-1} \left(\sum_{n=k-M+1}^k \varphi[n] y[n] \right) \quad \forall k \geq M$$

\mathbf{P}_k ← Simetrică și strict pozitiv definită.

$$\mathbf{P}_k^{-1} \stackrel{\text{def}}{=} \sum_{n=k-M+1}^k \varphi[n] \varphi^T[n] = \sum_{n=k-M}^{k-1} \varphi[n] \varphi^T[n] - \varphi[k-M] \varphi^T[k-M] + \varphi[k] \varphi^T[k] =$$

\mathbf{P}_{k-1}^{-1}

$$= \mathbf{P}_{k-1}^{-1} - \varphi[k-M] \varphi^T[k-M] + \varphi[k] \varphi^T[k], \quad \forall k \geq M+1.$$

4 Metode de identificare și validare

4.9 Metode adaptive de identificare

MCMMP-R – variante cu fereastră: MCMMP-R□ (continuare)

- Urmează deducerea expresiei corecției:

$$\begin{aligned}
 \hat{\theta}_k &= \mathbf{P}_k \left(\sum_{n=k-M+1}^k \varphi[n] y[n] \right) = \mathbf{P}_k \left(\underbrace{\sum_{n=k-M}^{k-1} \varphi[n] y[n]}_{\mathbf{P}_{k-1}^{-1} \hat{\theta}_{k-1}} - \varphi[k-M] y[k-M] + \varphi[k] y[k] \right) = \\
 &= \mathbf{P}_k \left(\mathbf{P}_{k-1}^{-1} \hat{\theta}_{k-1} - \varphi[k-M] y[k-M] + \varphi[k] y[k] \right) \stackrel{\mathbf{P}_{k-1}^{-1} = \mathbf{P}_k^{-1} + \varphi[k-M] \varphi^T[k-M] - \varphi[k] \varphi^T[k]}{=} \\
 &= \mathbf{P}_k \left[\left(\mathbf{P}_k^{-1} + \varphi[k-M] \varphi^T[k-M] - \varphi[k] \varphi^T[k] \right) \hat{\theta}_{k-1} - \varphi[k-M] y[k-M] + \varphi[k] y[k] \right] = \\
 &= \hat{\theta}_{k-1} - \mathbf{P}_k \varphi[k-M] \left(y[k-M] - \varphi^T[k-M] \hat{\theta}_{k-1} \right) + \mathbf{P}_k \varphi[k] \left(y[k] - \varphi^T[k] \hat{\theta}_{k-1} \right), \quad \forall k \geq M+1.
 \end{aligned}$$

Așadar

$$\hat{\theta}_k = \hat{\theta}_{k-1} - \underbrace{\mathbf{P}_k \varphi[k-M] \left(y[k-M] - \varphi^T[k-M] \hat{\theta}_{k-1} \right)}_{\Delta_b[k]} + \underbrace{\mathbf{P}_k \varphi[k] \left(y[k] - \varphi^T[k] \hat{\theta}_{k-1} \right)}_{\Delta_f[k]}, \quad \forall k \geq M+1$$

☞ Corecția este formată din 2 termeni.

$\Delta_b[k]$

**Corecție
a priori**

backward

**Corecție
a posteriori**

$\Delta_f[k]$

forward

- Pentru a putea determina corecțiile, trebuie evaluate:

$$\varepsilon_b[k-M] \stackrel{\text{def}}{=} y[k-M] - \varphi^T[k-M] \hat{\theta}_{k-1}$$

→ Eroarea de predicție **a priori**
(prognoză în trecut).

$$\varepsilon_f[k] \stackrel{\text{def}}{=} y[k] - \varphi^T[k] \hat{\theta}_{k-1}$$

→ Eroarea de predicție **a posteriori**
(prognoză în viitor).

☞ Folosind numai datele delimitate de fereastra dreptunghiulară.