



# Sumar

✓ Bibliografie

✓ 0 Organizarea temelor de laborator

☞ 8 Modelarea și predicția seriilor de timp

☞ 8.1 Estimarea modelului polinomial al tendinței

8.2 Estimarea componentei sezoniere

8.3 Estimarea componentei nedeterministe (aleatoare)

8.4 Predicția seriei de timp

# Modelarea și predicția seriilor de timp

## Notatii și definiții de bază

Serie de timp

Șir de date înregistrat în urma evoluției unui proces, fără a putea cuantifica sau cunoaște cauzele acelei evoluții.

Eșantionare uniformă

$$\mathcal{D} = \{y[n] = y(nT_s)\}_{n=1, \overline{N}}$$


perioadă de eşantionare

Eșantionare neuniformă

$$\mathcal{D} = \{y(t_n)\}_{n=1, \overline{N}}$$

$$t_1 < t_2 < \dots < t_n < \dots < t_N$$

momente de eşantionare



Orizontul de măsură este limitat.

$T_{\max}$

Predicția/Prognostica  
seriei de timp.

Obiectivul  
modelării

8.1.2



Convenție: perioada de eşantionare este egală cu **minimul** duratei dintre oricare două momente de eşantionare succesive.

$$t_n \geq nT_s$$

$$\forall t \in \mathbb{N}^*$$

# Modelarea și predicția seriilor de timp

## 8.1 Estimarea modelului polinomial al tendinței

**Tendință**

**Model determinist asociat orientării generale a seriei de timp.**


$$y_T(t) = a_0 + a_1 t + \dots + a_p t^p \quad \forall t \in \mathbb{R}$$

De tip polinomial.

$$y_M \equiv y_T + y_S + y_{AR}$$

parametri (necunoscuți)

ordinul modelului (necunoscut)



**Eșantionare uniformă**

$$y_T(nT_s) = a_0 + a_1 nT_s + \dots + a_p n^p T_s^p \quad \leftarrow \text{dacă se cunoaște perioada de eșantionare} \quad \forall n \in \mathbb{Z}$$

$$y_T(nT_s) = a_0 + a_1 n + \dots + a_p n^p \quad \leftarrow \text{dacă nu se cunoaște perioada de eșantionare sau este considerată unitară} \quad \forall n \in \mathbb{Z}$$

**Eșantionare neuniformă**

$$y_T(nT_s) = a_0 + a_1 t_n + \dots + a_p t_n^p \quad \leftarrow \text{pentru orice colecție de momente de eșantionare} \quad \forall n \in \mathbb{Z}$$

vectorul parametrilor necunoscuți  
indicele structural necunoscut

$$\theta = \begin{bmatrix} a_0 \\ a_1 \\ \vdots \\ a_p \end{bmatrix} \stackrel{\text{def}}{=} \in \mathbb{R}^{p+1}$$

**Cum poate fi determinat modelul?**

inclusiv uniforme

domeniul de stabilitate

$$\hat{\theta}_N = \arg \min_{\theta \in \mathcal{S}} \mathcal{V}_N(\theta)$$

$$\mathcal{V}_N(\theta) = \sum_{n=1}^N (y(t_n) - y_T(t_n))^2$$

$$\forall \theta \in \mathcal{S}$$

Folosind **Metoda Celor Mai Mici Pătrate (MCMMP)**.

Curs IS →



# 8 Modelarea și predicția seriilor de timp

## 8.1 Estimarea modelului polinomial al tendinței



Estimație consistentă

$$\hat{\theta}_N = \mathbf{R}_N^{-1} \mathbf{r}_N$$

$$\mathbf{r}_N \stackrel{\text{def}}{=} \left[ \frac{1}{N} \sum_{n=1}^N t_n^i y(t_n) \right]_{i \in \overline{0, p}}$$

vector de covarianțe

$$\mathbf{R}_N \stackrel{\text{def}}{=} \left[ \frac{1}{N} \sum_{n=1}^N t_n^{i+j} \right]_{i, j \in \overline{0, p}}$$

matrice simetrică

☛ poate fi construită recursiv

☛ poate fi construit recursiv

$$\mathbf{R}_{N,p} = \begin{bmatrix} \mathbf{R}_{N,0} & \frac{1}{N} \sum_{n=1}^N t_n & \frac{1}{N} \sum_{n=1}^N t_n^2 & \dots & \frac{1}{N} \sum_{n=1}^N t_n^p \\ \frac{1}{N} \sum_{n=1}^N t_n & \frac{1}{N} \sum_{n=1}^N t_n^2 & \frac{1}{N} \sum_{n=1}^N t_n^3 & \dots & \frac{1}{N} \sum_{n=1}^N t_n^{p+1} \\ \vdots & \vdots & \vdots & \ddots & \vdots \\ \frac{1}{N} \sum_{n=1}^N t_n^{p-1} & \dots & \frac{1}{N} \sum_{n=1}^N t_n^{2p-3} & \frac{1}{N} \sum_{n=1}^N t_n^{2p-2} & \frac{1}{N} \sum_{n=1}^N t_n^{2p-1} \\ \frac{1}{N} \sum_{n=1}^N t_n^p & \dots & \frac{1}{N} \sum_{n=1}^N t_n^{2p-1} & \frac{1}{N} \sum_{n=1}^N t_n^{2p} & \frac{1}{N} \sum_{n=1}^N t_n^{2p+1} \end{bmatrix}$$

$$\mathbf{r}_{N,p} = \begin{bmatrix} \mathbf{r}_{N,0} \\ \mathbf{r}_{N,1} \\ \vdots \\ \mathbf{r}_{N,p} \end{bmatrix} \quad \text{where} \quad \mathbf{r}_{N,i} = \left[ \frac{1}{N} \sum_{n=1}^N t_n^i y(t_n) \right]$$

1/Precizie  $\hat{\lambda}_{N,p}^2 = \frac{1}{N-p} \mathcal{V}_N(\hat{\theta}_{N,p})$


# Modelarea și predicția seriilor de timp

## 8.1 Estimarea modelului polinomial al tendinței

Este matricea simetrică inversabilă?

Exemplu

Momente de eșantionare uniforme, de la 1 la 100 și polinom de gradul 2.



⊗ Cu toate acestea, matricea este **puternic dezechilibrată numeric** (avînd un **număr de condiționare numerică extrem de mare**).

raportul dintre valoarea proprie de modul maxim și cea de modul minim

$$\kappa(\mathbf{R}_{N,p})$$



Se observă **diferența sensibilă** de ordin de mărime dintre elementele matricii.

⚠ Inversarea numerică poate introduce erori semnificative!

$$\kappa(\mathbf{R}_{100,2}) = 1.9245 \cdot 10^8 !$$

$$\mathbf{R}_{N,2} = \begin{bmatrix} 1 & \frac{N+1}{2} & \frac{1}{N} \sum_{n=1}^N n^2 \\ \frac{N+1}{2} & \frac{1}{N} \sum_{n=1}^N n^2 & \frac{1}{N} \sum_{n=1}^N n^3 \\ \frac{1}{N} \sum_{n=1}^N n^2 & \frac{1}{N} \sum_{n=1}^N n^3 & \frac{1}{N} \sum_{n=1}^N n^4 \end{bmatrix} = \begin{bmatrix} 1 & 50.5 & 3383.5 \\ 50.5 & 3383.5 & 255025 \\ 3383.5 & 255025 & 20503333.3 \end{bmatrix}$$

Ce se poate face?

$$M \stackrel{\text{def}}{=} \left[ \frac{T_{\max}}{T_s} \right]$$

Se poate aplica o tehnică de **echilibrare numerică** (a se vedea cursul de **Metode Numerice**).

Formula de implementare

$$\hat{\theta}_N = \mathbf{B}_M \left( \mathbf{B}_M \mathbf{R}_N \mathbf{B}_M \right)^{-1} \mathbf{B}_M \mathbf{r}_N$$

⚡ Echilibrată numeric.

Se construiește o **matrice de balansare**.

$$\mathbf{B}_M \stackrel{\text{def}}{=} \text{diag} \left[ \frac{1}{\sqrt{MT_s}}, \frac{1}{MT_s \sqrt{MT_s}}, \dots, \frac{1}{M^p T_s^p \sqrt{MT_s}} \right]$$



# Modelarea și predicția seriilor de timp

## 8.1 Estimarea modelului polinomial al tendinței

### Exemplu

Momente de eșantionare uniforme, de la 1 la 100 și polinom de gradul 2.

$$R_{100,2} = \begin{bmatrix} 1 & 50.5 & 3383.5 \\ 50.5 & 3383.5 & 255025 \\ 3383.5 & 255025 & 20503333.3 \end{bmatrix}$$

$$v(R_{100,2}) = 1.9245 \cdot 10^8$$



### Balansare

$$B_{100} R_{100,2} B_{100} =$$

$$B_{100}^{def} = \text{diag}[0.1 \quad 0.001 \quad 0.00001]$$

$$= \begin{bmatrix} 0.1 & 0.00505 & 0.0033835 \\ 0.00505 & 0.0033835 & 0.00255025 \\ 0.0033835 & 0.00255025 & 0.0020503333 \end{bmatrix}$$

$$v(B_{100} R_{100,2} B_{100}) = 5.336 \cdot 10^2$$



Condiționarea numerică poate fi îmbunătățită cu ajutorul unor tehnici de balansare mai sofisticate.

**Dar indicele structural? Cum se poate determina?**

Se apelează la strategia generală prezentată în cursul de **IS**.

Pentru fiecare structură de model din ce în ce mai bogată ( $m \in \{1, 2, \dots, M\}$ ):

- se determină parametrii modelului ales,  $\theta_m$ ;
- se evaluează precizia modelului ( $\mathcal{V}(\theta_m)$ ).

Alegerea modelului adecvat datelor achiziționate

**Gradul maxim al modelului.**

$$P_{\max} = 10$$

**Teste (criterii) de adecvanță**

Modele de identificare de același tip sunt **comparate** între ele în vederea alegerii celui **adecvat**.

# 8 Modelarea și predicția seriilor de timp

## 8.1 Estimarea modelului polinomial al tendinței

Criteriul utilizat în alegerea structurii modelului tendinței

**Calitatea predicției**  $PQ_K[p, P, na]$

Definit în final, pentru toate cele 3 modele componente.

Care este tema de laborator?

Implementarea algoritmului de estimare a coeficienților modelului polinomial al tendinței, bazat pe **MCMMP**.

### Pași principali ai algoritmului de modelare

Date de intrare

$\mathcal{D}$

(seria de timp)

$p$

(gradul polinomului; implicit:  $p = 0$ )

Inițializare

Determinarea lungimii seriei de timp.

$N$

Evaluarea perioadei de eșantionare.

$T_s$

Unitară, pentru seriile eșantionate uniform.

Evaluarea numărului de balansare.

$M$

Egal cu lungimea seriei de timp, pentru seriile eșantionate uniform.



# 8 Modelarea și predicția seriilor de timp

## 8.1 Estimarea modelului polinomial al tendinței

### ➡ Pași principali ai algoritmului de modelare (continuare)

Se estimează vectorul parametrilor necunoscuți prin implementarea MCMMP cu balansare.

$$\hat{\theta}_{N,p}$$

Se evaluează modelul efectiv al tendinței pe orizontul de măsură.

🔥 **Recursiv!**

$$y_T(t_n) = \hat{a}_0 + \hat{a}_1 t_n + \dots + \hat{a}_p t_n^p \quad \forall n \in \overline{1, N}$$

Se evaluează seria de timp staționarizată.

$$y_{sta}(t_n) = y(t_n) - y_T(t_n) \quad \forall n \in \overline{1, N}$$

$$\langle y_{sta} \rangle \stackrel{def}{=} \frac{1}{N} \sum_{n=1}^N y_{sta}(t_n)$$

media datelor staționarizate

Se corectează modelului tendinței și al seriei de timp staționarizate cu media.

$$y_{sta} \leftarrow y_{sta} - \langle y_{sta} \rangle$$

$$\hat{a}_0 \leftarrow \hat{a}_0 + \langle y_{sta} \rangle$$

Date de ieșire

$y_{sta}$

$y_T$

$\hat{\theta}_{N,p}$

Rutină ce trebuie proiectată

```
>> [ysta,yT,theta] = trend(y,p);
```

vectorul datelor  
staționarizate

vectorul tendinței pe  
orizontul de măsură

vectorul  
parametrilor  
modelului

vectorul de date  
care conține  
seria de timp

gradul  
polinomului  
tendință



8<sub>1</sub>.8





# ⑧ Modelarea și predicția seriilor de timp

## ⑧.① Estimarea modelului polinomial al tendinței

Programul de test al rutinei trend

ISLAB\_8A

### 👉 Pași principali

Se introduce numărul fișierului care conține seria de timp.

nts

Se introduce gradul polinomului tendință.

p

Se încarcă seria de timp în spațiul de lucru.

• cu ajutorul funcției:

eval

Se apelează rutina trend.

Se trasează graficele seriei de timp și al tendinței (în aceeași fereastră).

Se trasează graficul seriei de timp staționarizate (cu precizarea mediei pe grafic).

👉 Graficele trebuie trasate cu axele corect scalate și marcate, cu titluri sugestive și legendă de discriminare (dacă este cazul).

Fișiere de date?

Mini-programe  
MATLAB.

STnts.M

### ➤ Parametrii încărcăți în spațiul de lucru:

y	← seria de timp
ntime	← suportul seriei de timp (momentele de timp normalizate)
Ts	← perioada de eșantionare
unit	← unitatea de măsură a perioadei de eșantionare
yunit	← unitatea de măsură a valorilor seriei de timp
label	← text care arată ce reprezintă seria de timp

$nts \in \{1, 2, 3, \dots, 15\}$

Punctaj?

10 p



8<sub>1</sub>.9

