

①⑥ Metode neparametrice de estimare spectrală



Metoda lui Blackman & Tukey

Ideea lui Blackman & Tukey

(1958)

Fereastra de ponderare ar trebui aplicată direct secvenței de autocovarianță estimate, deoarece, pentru pivoți depărtați, aceasta este mai puțin precisă.

$$\hat{r}_x[k] = \frac{1}{N} \sum_{n=0}^{N-1} x[n]x[n-k] \quad \forall k \in \overline{1-N, N-1}$$

Fereastra are rolul de a **depondera** valorile **imprecise** ale autocovarianței estimate.

$$w \hat{r}_x$$

Pentru $|k|$ depărtat de origine, suma conține un număr mic de termeni, fiind **imprecisă**.

$$\text{Supp}(w) \subseteq \overline{1-N, N-1}$$

- Alte proprietăți impuse:

$$w[-n] = w[n] \quad \forall n \in \mathbb{Z}$$

(simetrie)

$$\mathcal{W}(e^{j\omega}) = \mathcal{F}(w)(e^{j\omega}) \geq 0 \quad \forall \omega \in \mathbb{R}$$

(ne-negativitate)

👉 Pentru a conserva ne-negativitatea densității spectrale estimate.

👉 Nu toate ferestrele verifică proprietatea.
Exemplu: Hamming, Hanning – **NU**.

Periodograma estimată a lui Blackman & Tukey

$$\hat{\Phi}_{w,x}(\omega) \stackrel{\text{def}}{=} \mathcal{F}(w \hat{r}_x)(\omega) = \sum_{n=1-N}^{N-1} w[n] \hat{r}_x[n] e^{-j\omega n} \quad \forall \omega \in \mathbb{R} \quad (\text{TCFD})$$

$$\hat{\Phi}_{w,x}(\omega) \stackrel{\text{def}}{=} \sum_{n \in \mathbb{Z}} w[n] \hat{r}_x[n] e^{-j\omega n} \quad \forall \omega \in \mathbb{R}$$

👉 Teorema **inversă** de convoluție periodică

$$\hat{\Phi}_{w,x}(\omega) = \frac{1}{2\pi} \int_{-\pi}^{+\pi} \hat{\Phi}_x(\mu) \mathcal{W}(e^{j(\omega-\mu)}) d\mu \quad \forall \omega \in \mathbb{R}$$

16 Metode neparametrice de estimare spectrală

Metoda lui Blackman & Tukey (continuare)

Performanțele metodei


- Se evaluează **media** periodogramei estimate (**TCFD**).

$$E\{\hat{\Phi}_{w,x}(\omega)\} = \frac{1}{2\pi} \int_{-\pi}^{+\pi} E\{\hat{\Phi}_x(\mu)\} \mathcal{W}(e^{j(\omega-\mu)}) d\mu \quad \forall \omega \in \mathbb{R}$$



$$E\{\hat{\Phi}_x(\mu)\} = \frac{1}{2\pi} \int_{-\pi}^{+\pi} \Phi_x(\nu) \mathcal{W}_{\Delta,N}(e^{j(\mu-\nu)}) d\nu \quad \forall \omega \in \mathbb{R}$$

Triangular (Bartlett)



$$E\{\hat{\Phi}_{w,x}(\omega)\} = \frac{1}{4\pi^2} \int_{-\pi-\pi}^{+\pi+\pi} \Phi_x(\nu) \mathcal{W}_{\Delta,N}(e^{j(\mu-\nu)}) \mathcal{W}(e^{j(\omega-\mu)}) d\mu d\nu \quad \forall \omega \in \mathbb{R}$$

$$E\{\hat{\Phi}_{w,x}(\omega)\} = \frac{1}{4\pi^2} \int_{-\pi}^{+\pi} \Phi_x(\nu) \left(\int_{-\pi}^{+\pi} \mathcal{W}_{\Delta,N}(e^{j(\mu-\nu)}) \mathcal{W}(e^{j(\omega-\mu)}) d\mu \right) d\nu \quad \forall \omega \in \mathbb{R}$$

$$2\pi(\mathcal{W} \tilde{*} \mathcal{W}_{\Delta,N})(e^{j(\omega-\nu)})$$

(convoluție periodică)

$$\cong 2\pi \mathcal{W}(e^{j(\omega-\nu)})$$

Pentru a obține o creștere a regulatității periodogramei, este necesar ca lungimea ferestrei w să fie **mult mai mică** decât cea a ferestrei Bartlett.

$$\text{Supp}(w) = 1 - M, M - 1$$

$$\text{Supp}(w_{\Delta,N}) = 1 - N, N - 1$$

$$M \ll N$$

$$E\{\hat{\Phi}_{w,x}(\omega)\} \cong \frac{1}{2\pi} \int_{-\pi}^{+\pi} \Phi_x(\mu) \mathcal{W}(e^{j(\omega-\mu)}) d\mu \quad \forall \omega \in \mathbb{R}$$

Similară mediei periodogramei Bartlett.

TCFD a ferestrei Bartlett se comportă aproximativ ca un **impuls Dirac** în convoluție cu **TCFD** a ferestrei w .

①⑥ Metode neparametrice de estimare spectrală



Metoda lui Blackman & Tukey (continuare)

Performanțele metodei (continuare)

- Se evaluează **varianța** periodogramei estimate (**TCFD**).

$$E\{\hat{\Phi}_{w,x}(\omega)\} \cong \frac{1}{2\pi} \int_{-\pi}^{+\pi} \Phi_x(\mu) \mathcal{W}(e^{j(\omega-\mu)}) d\mu \quad \forall \omega \in \mathbb{R}$$

$$\sigma_{\hat{\Phi}_{w,x}}^2(\omega) = E\{\hat{\Phi}_{w,x}^2(\omega)\} - \left(E\{\hat{\Phi}_{w,x}(\omega)\}\right)^2 \rightarrow \left(E\{\hat{\Phi}_{w,x}(\omega)\}\right)^2 \cong \frac{1}{2\pi} \int_{-\pi}^{+\pi} \int_{-\pi}^{+\pi} \Phi_x(\mu) \Phi_x(\nu) \mathcal{W}(e^{j(\omega-\mu)}) \mathcal{W}(e^{j(\omega-\nu)}) d\mu d\nu \quad \forall \omega \in \mathbb{R}$$

$$E\{\hat{\Phi}_{w,x}^2(\omega)\} = \frac{1}{4\pi^2} \int_{-\pi}^{+\pi} \int_{-\pi}^{+\pi} E\{\hat{\Phi}_x(\mu) \hat{\Phi}_x(\nu)\} \mathcal{W}(e^{j(\omega-\mu)}) \mathcal{W}(e^{j(\omega-\nu)}) d\mu d\nu \quad \forall \omega \in \mathbb{R}$$

$$E\{\hat{\Phi}_x(\mu) \hat{\Phi}_x(\nu)\} = \Phi_x(\mu) \Phi_x(\nu) \left[1 + \frac{\left(\sin \frac{N(\mu+\nu)}{2}\right)^2}{N \sin^2 \frac{\mu+\nu}{2}} + \frac{\left(\sin \frac{N(\mu-\nu)}{2}\right)^2}{N \sin^2 \frac{\mu-\nu}{2}} \right] \quad \forall \mu, \nu \in \mathbb{R}$$

$$\sigma_{\hat{\Phi}_{w,x}}^2(\omega) \cong \frac{1}{4\pi^2} \int_{-\pi}^{+\pi} \int_{-\pi}^{+\pi} \Phi_x(\mu) \Phi_x(\nu) \left[\frac{\left(\sin \frac{N(\mu+\nu)}{2}\right)^2}{N \sin^2 \frac{\mu+\nu}{2}} + \frac{\left(\sin \frac{N(\mu-\nu)}{2}\right)^2}{N \sin^2 \frac{\mu-\nu}{2}} \right] \mathcal{W}(e^{j(\omega-\mu)}) \mathcal{W}(e^{j(\omega-\nu)}) d\mu d\nu \quad \forall \omega \in \mathbb{R}$$

👉 Se poate observa simetria perfectă a integralelor în μ și ν .

①⑥ Metode neparametrice de estimare spectrală

Metoda lui Blackman & Tukey (continuare)

Performanțele metodei (continuare)



$$\sigma_{\hat{\Phi}_{w,x}}^2(\omega) \cong \frac{1}{4\pi^2} \int_{-\pi}^{+\pi} \int_{-\pi}^{+\pi} \Phi_x(\mu) \Phi_x(\nu) \left[\left(\frac{\sin \frac{N(\mu+\nu)}{2}}{N \sin \frac{\mu+\nu}{2}} \right)^2 + \left(\frac{\sin \frac{N(\mu-\nu)}{2}}{N \sin \frac{\mu-\nu}{2}} \right)^2 \right] \mathcal{W}(e^{j(\omega-\mu)}) \mathcal{W}(e^{j(\omega-\nu)}) d\mu d\nu$$

$\forall \omega \in \mathbb{R}$



$$M \ll N$$

TCFD a ferestrei Bartlett se comportă aproximativ ca un **impuls Dirac** în convoluție cu **TCFD** a ferestrei w .

$$\begin{aligned} \int_{-\pi}^{+\pi} \Phi_x(\nu) \left[\left(\frac{\sin \frac{N(\mu+\nu)}{2}}{N \sin \frac{\mu+\nu}{2}} \right)^2 + \left(\frac{\sin \frac{N(\mu-\nu)}{2}}{N \sin \frac{\mu-\nu}{2}} \right)^2 \right] \mathcal{W}(e^{j(\omega-\nu)}) d\nu &\cong \\ &\cong \frac{2\pi}{N} \left[\Phi_x(-\mu) \mathcal{W}(e^{j(\omega+\mu)}) + \Phi_x(\mu) \mathcal{W}(e^{j(\omega-\mu)}) \right] \end{aligned}$$

$\forall \omega, \mu \in \mathbb{R}$

$$\sigma_{\hat{\Phi}_{w,x}}^2(\omega) \cong \frac{1}{2\pi N} \int_{-\pi}^{+\pi} \Phi_x(\mu) \Phi_x(-\mu) \mathcal{W}(e^{j(\omega+\mu)}) \mathcal{W}(e^{j(\omega-\mu)}) d\mu + \frac{1}{2\pi N} \int_{-\pi}^{+\pi} \Phi_x^2(\mu) \mathcal{W}^2(e^{j(\omega-\mu)}) d\mu$$

$\forall \omega \in \mathbb{R}$


Produsul versiunilor întârziată și anticipată ale **TCFD** corespunzătoare ferestrei w este neglijabil în raport cu pătratul **TCFD**.



16 Metode neparametrice de estimare spectrală

Metoda lui Blackman & Tukey (continuare)

Performanțele metodei (continuare)


$$\sigma_{\hat{\Phi}_{w,x}}^2(\omega) \cong \frac{1}{2\pi N} \int_{-\pi}^{+\pi} \Phi_x(\mu) \Phi_x(-\mu) \cancel{\mathcal{W}(e^{j(\omega+\mu)})} \mathcal{W}(e^{j(\omega-\mu)}) d\mu + \frac{1}{2\pi N} \int_{-\pi}^{+\pi} \Phi_x^2(\mu) \mathcal{W}^2(e^{j(\omega-\mu)}) d\mu \quad \forall \omega \in \mathbb{R}$$

$$\sigma_{\hat{\Phi}_{w,x}}^2(\omega) \cong \frac{1}{2\pi N} \int_{-\pi}^{+\pi} \Phi_x^2(\mu) \mathcal{W}^2(e^{j(\omega-\mu)}) d\mu \quad \forall \omega \in \mathbb{R}$$



Rezoluția în frecvență este stabilită practic de către **TCFD** a fereastrei, care are o deschidere a lobului principal **inferioară** lărgimii de bandă a densității spectrale adevărate.

Exercițiu

- Deduceți expresiile performanțelor periodogramei Blackman-Tukey folosind **TFD**.

$$\sigma_{\hat{\Phi}_{w,x}}^2(\omega) \cong \frac{\Phi_x^2(\omega)}{2\pi N} \int_{-\pi}^{+\pi} \mathcal{W}^2(e^{j\mu}) d\mu \stackrel{\uparrow}{=} \Phi_x^2(\omega) \left[\frac{1}{N} \sum_{m=1-M}^{M-1} w^2[n] \right] \quad \forall \omega \in \mathbb{R}$$

Proprietatea lui Parseval

Factorul de calitate



$$Q(\omega) \stackrel{\text{def}}{=} \frac{\left(E\{\hat{\Phi}_x(\omega)\} \right)^2}{\sigma_{\hat{\Phi}_x}^2(\omega)} \cong \frac{1}{\left[\frac{1}{N} \sum_{m=1-M}^{M-1} w^2[n] \right]} \quad \forall \omega \in \mathbb{R}$$



👉 Cu cât fereastra are energie mai scăzută, cu atât factorul de calitate este mai mare.

Metoda lui Blackman-Tukey oferă un foarte bun control al compromisului rezoluție-regularitate.

① ⑦ Metode parametrice de estimare spectrală



Metodele neparametrice **nu pot conduce la atenuarea sensibilă a gradului de fractalitate** din spectrul estimat.



Cum pot fi atenuate neregularitățile locale din spectrul estimat?


Prin utilizarea unui **model de identificare** asociat semnalului original.

Modelele parametrice din clasa **ARMAX**

Rezultatul fundamental

Transferul densității spectrale prin sisteme liniare


$\hat{\Phi}_Y^P$



$$\Phi_Y(\omega) = |H(e^{j\omega})|^2 \Phi_X(\omega) \quad \forall \omega \in \mathbb{R}$$

• Modelele cele mai utilizate în PS:

→ AR → MA → ARMA



① Metode parametrice de estimare spectrală



Cum se poate obține spectrul estimat folosind un model parametric?

Cu ajutorul următoarei strategii naturale.

Algoritm

① Se identifică un model parametric asociat semnalului original (y).

→ AR
→ MA
→ ARMA


$$\hat{A}(q^{-1}) y[n] = \hat{C}(q^{-1}) \hat{e}[n] \quad \forall n \in 0, N-1$$

O estimatie a zgomotului alb care a stimulat sistemul generator al semnalului original.

$$\hat{A}(q^{-1}) \stackrel{\text{def}}{=} 1 + \hat{a}_1 q^{-1} + \hat{a}_2 q^{-2} + \dots + \hat{a}_{na} q^{-na}$$

$$\hat{C}(q^{-1}) \stackrel{\text{def}}{=} 1 + \hat{c}_1 q^{-1} + \hat{c}_2 q^{-2} + \dots + \hat{c}_{nc} q^{-nc}$$

parametrii estimați
ai modelului



② Se estimează zgomotul alb care a stimulat sistemul generator al semnalului original.

③ Se estimează densitatea spectrală de putere a zgomotului alb.

$$\Phi_{\hat{e}}(\omega) \stackrel{\text{def}}{=} \hat{\lambda}^2 \stackrel{\text{def}}{=} \frac{1}{N} \sum_{n=1}^N \hat{e}^2[n] \quad \forall \omega \in \mathbb{R}$$

Măsură a preciziei
modelului parametric.

Lucrările de
laborator




① ⑦ Metode parametrice de estimare spectrală

Algoritm (continuare)

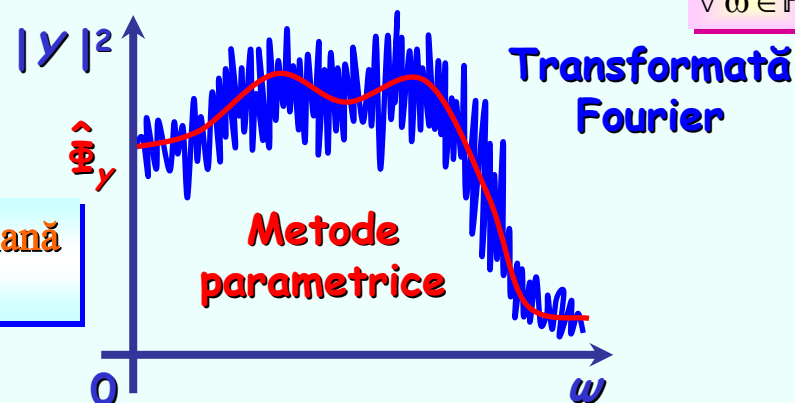
④ Se estimează densitatea spectrală a semnalului original.

Transferul densității spectrale
prin sisteme liniare



Spectrul estimat apare ca o **curbă mediană**
a spectrului original.

$$\hat{\Phi}_y(\omega) = \left| \frac{\hat{C}(e^{j\omega})}{\hat{A}(e^{j\omega})} \right|^2 \quad \Phi_{\hat{e}}(\omega) = \hat{\lambda}^2 \left| \frac{\hat{C}(e^{j\omega})}{\hat{A}(e^{j\omega})} \right|^2 \quad \forall \omega \in \mathbb{R}$$



Caracteristici generale ale metodelor parametrice de estimare spectrală

- ☺ Atenuarea comportamentului fractal se datorează filtrării importante a zgomotelor care corup semnalul, cu ajutorul modelului parametric.
- ☺ Rezoluția în frecvență poate fi aleasă liber, independent de durata semnalului.
- ☺ Regularitatea spectrului estimat poate fi (parțial) controlată prin intermediul indicilor structurali ai modelului parametric.
- ☺ Liniile spectrale dominante pot fi puse în evidență mai ușor.
- ☹ Compromisul rezoluție-regularitate este sensibil la variația indicilor structurali.

☞ Gradul de netezime al spectrului estimat **nu** constituie o măsură a regularității sale.

1 § Metode moderne de estimare spectrală



Două categorii {
 → Metode de varianță minimă
 → Metode de extracție a liniilor spectrale dominante

Metode de varianță minimă

Ideea varianței minime
 (Capon & Lacoss)

(1969)

(1971)

Modelul de identificare ar trebui determinat astfel încât varianța zgomotului alb estimat să fie minimă și răspunsul în frecvență să fie unitar pentru o pulsație precizată.

Exemplu

Modelul AR ne-normalizat

$$A(q^{-1}) y[n] = e[n]$$

$$\forall n \in 0, N-1$$

$$A(q^{-1}) \stackrel{\text{def}}{=} a_0 + a_1 q^{-1} + a_2 q^{-1} + \dots + a_{na} q^{-na}$$

☞ Nu neapărat unitar.

$$\sigma_e^2(\theta) \stackrel{\text{def}}{=} E\{e^2[n]\} = E\{\theta^T \cdot y[n] \cdot y^T[n] \cdot \theta\}$$

$$y[n] \stackrel{\text{def}}{=} [y[n] \ y[n-1] \ \dots \ y[n-na]]^T \in \mathbb{R}^{na+1}$$

vector de semnal



$$R_{na+1}(y) \stackrel{\text{def}}{=} E\{y[n]y^T[n]\} \in \mathbb{R}^{(na+1) \times (na+1)}$$

matrice de autocovarianță

$$\theta \stackrel{\text{def}}{=} [a_0 \ a_1 \ \dots \ a_{na}]^T \in \mathbb{R}^{na+1}$$

vector de parametri

$$\sigma_e^2(\theta) = \theta^T R_{na+1}(y) \theta$$

$$\begin{bmatrix} 1 & e^{j\omega_0} & e^{2j\omega_0} & \dots & e^{jna\omega_0} \end{bmatrix}$$

vector armonic
 elementar

- Pentru determinarea parametrilor necunoscuți, se rezolvă o problemă de optimizare cu restricții.

pulsația pentru care va fi
 determinat modelul AR

$$\min_{\theta \in \mathbb{R}^{na+1}} \{\sigma_e^2(\theta)\}$$

$$\text{s.t. } A(e^{j\omega_0}) = 1$$

$$\min_{\theta \in \mathbb{R}^{na+1}} \{\theta^T R_{na+1}(y) \theta\}$$

$$\text{s.t. } w^T(\omega_0) \theta = 1$$

18 Metode moderne de estimare spectrală



Metode de varianță minimă (continuare)

Exemplu

Modelul AR ne-normalizat (continuare)

Soluția problemei

$$\min_{\theta \in \mathbb{R}^{n+1}} \left\{ \theta^T \mathbf{R}_{n+1}(y) \theta \right\}$$
$$\text{s.t. } \mathbf{w}^T(\omega_0) \theta = 1$$

Lacoss


$$\hat{\theta}(\omega_0) = \frac{\mathbf{R}_{n+1}^{-1}(y) \mathbf{w}(\omega_0)}{\mathbf{w}^T(\omega_0) \mathbf{R}_{n+1}^{-1}(y) \mathbf{w}(\omega_0)}$$

1

$$\sigma_e^2(\hat{\theta}(\omega_0)) \stackrel{\text{def}}{=} \lambda_{e,\min}^2(\omega_0) = \frac{\mathbf{w}^T(\omega_0) \mathbf{R}_{n+1}^{-1}(y) \mathbf{R}_{n+1}(y) \hat{\theta}(\omega_0)}{\mathbf{w}^T(\omega_0) \mathbf{R}_{n+1}^{-1}(y) \mathbf{w}(\omega_0)} = \frac{\mathbf{w}^T(\omega_0) \hat{\theta}(\omega_0)}{\mathbf{w}^T(\omega_0) \mathbf{R}_{n+1}^{-1}(y) \mathbf{w}(\omega_0)} = \frac{1}{\mathbf{w}^T(\omega_0) \mathbf{R}_{n+1}^{-1}(y) \mathbf{w}(\omega_0)}$$

- Se estimează densitatea spectrală de putere a ieșirii modelului, pentru pulsația specificată.

Transferul densității spectrale prin sisteme liniare



$$\hat{\Phi}_y(\omega) = \frac{1}{\mathbf{w}^T(\omega) \hat{\mathbf{R}}_{n+1}^{-1}(y) \mathbf{w}(\omega)} \quad \forall \omega \in \mathbb{R}$$

Se inversează o singură dată, pentru toate pulsațiile.

$$\Phi_{\hat{y}}(\omega_0) = \frac{\Phi_{\hat{e}}(\omega)}{|\hat{A}(e^{j\omega_0})|^2} = \lambda_{e,\min}^2 = \frac{1}{\mathbf{w}^T(\omega_0) \mathbf{R}_{n+1}^{-1}(y) \mathbf{w}(\omega_0)}$$

Nu depinde de vectorul parametrilor estimați, ci doar de pulsația specificată.

- Practic, **nu mai este necesar modelul AR** (altfel el ar fi trebuit reactualizat pentru fiecare pulsație).
- De remarcat că relația este implementabilă **numai dacă matricea de autocovarianță se estimează în prealabil.**

18 Metode moderne de estimare spectrală



Metode de varianță minimă (continuare)

Algoritm

① Se alege ordinul modelului AR ascuns.

na

- Acesta controlează **compromisul rezoluție-regularitate** pentru spectrul estimat.

② Se estimează și se inversează matricea de autocovarianță a semnalului.

$\hat{\mathbf{R}}_{na+1}(y)$

- Matricea este de tip **Toeplitz simetrică** (adică este determinată complet de prima linie/coloană, prin expandare pe diagonale).
- Pentru inversarea acesteia, se poate utiliza **Algoritmul Levinson-Durbin** din **IS**, care necesită un efort de calcul proporțional cu na^2 (și nu na^3 ca în cazul **Algoritmului lui Gauss**)

$$\hat{\mathbf{R}}_{na+1}(y) \stackrel{def}{=} \begin{bmatrix} \hat{r}_y[0] & \hat{r}_y[1] & \dots & \hat{r}_y[k] & \dots & \hat{r}_y[na] \\ \hat{r}_y[1] & \hat{r}_y[0] & \hat{r}_y[1] & \dots & \hat{r}_y[k] & \dots \\ & \hat{r}_y[1] & \hat{r}_y[0] & \hat{r}_y[1] & \dots & \hat{r}_y[k] \\ \hat{r}_y[k] & \hat{r}_y[1] & \hat{r}_y[0] & \hat{r}_y[1] & \dots & \hat{r}_y[k] \\ & \hat{r}_y[k] & \hat{r}_y[1] & \hat{r}_y[0] & \hat{r}_y[1] & \dots \\ \hat{r}_y[na] & \hat{r}_y[k] & \hat{r}_y[1] & \hat{r}_y[0] & \hat{r}_y[1] & \dots \end{bmatrix}$$

③ Se estimează spectrul semnalului.

$$\hat{\Phi}_y(\omega) = \frac{1}{\mathbf{w}^T(\omega) \hat{\mathbf{R}}_{na+1}^{-1}(y) \mathbf{w}(\omega)} \quad \forall \omega \in \mathbb{R}$$

$$\mathbf{w}(\omega) \stackrel{def}{=} \begin{bmatrix} 1 & e^{j\omega} & e^{2j\omega} & \dots & e^{jna\omega} \end{bmatrix}^T$$

Caracteristici generale ale metodei

- ☺ **Indicele structural al modelului parametric permite un control destul de bun al compromisului rezoluție-regularitate, cu performanțe superioare metodelor ne-parametrice.**
- ☹ **Performanțele unui model AR identificat cu același indice structural sunt superioare celor corespunzătoare modelului AR bazat pe minimizarea varianței de ieșire.**

18 Metode moderne de estimare spectrală



Metode de extracție a liniilor spectrale dominante

Ideea liniilor spectrale dominante

Pentru extracția doar a liniilor spectrale cu puteri dominante, modelul parametric ar trebui să fie constituit numai din suma armonicelor elementare corespunzătoare pulsațiilor dominante.

Orice armonică elementară poate fi generată recursiv cu ajutorul unei ecuații cu diferențe de ordin 2.

$$\begin{cases} x[n] + a_1 x[n-1] + a_2 x[n-2] = 0 \\ a_1 = -2 \cos \omega_0 \quad a_2 = 1 \end{cases} \quad \forall n \in \mathbb{N}$$

Exercițiu

- Arătați că soluțiile armonice ale ecuației cu diferențe pot fi următoarele:

$$\begin{cases} x[0] = 0 \\ x[-1] = -A \sin \omega_0 \end{cases} \Rightarrow x[n] = A \sin(n\omega_0) \quad \forall n \in \mathbb{N}$$

$$\begin{cases} x[0] = A \\ x[-1] = A \cos \omega_0 \end{cases} \Rightarrow x[n] = A \cos(n\omega_0) \quad \forall n \in \mathbb{N}$$

Dacă se dorește extragerea primelor na linii spectrale dominante, modelul matematic are forma următoare:

$$x[n] = - \sum_{i=1}^{2na} a_i x[n-i] \quad \forall n \in \mathbb{N} \quad \overset{\text{def}}{a_0} = 1$$

Armonicele trebuie extrase dintr-un semnal corupt de zgomot aditiv.


- Polinomul caracteristic al ecuației cu diferențe:

$$P(q^{-1}) \overset{\text{def}}{=} 1 + a_1 q^{-1} + a_2 q^{-2} + \dots + a_{2na} q^{-2na}$$

⚡ Rădăcinile sunt situate pe cercul unitar (nu neapărat în puncte echidistante).

$$\sum_{i=0}^{2na} a_i y[n-i] = \sum_{i=0}^{2na} a_i v[n-i] \quad \forall n \in \mathbb{N}$$

Model ARMA[2na,2na] cu polinoame identice.



18 Metode moderne de estimare spectrală



Metode de extracție a liniilor spectrale dominante (continuare)

Cum se pot determina parametrii modelului ARMA?

- Se poate considera că **semnalul parazit** este un **zgomot alb** de medie nulă, iar **semnalul util** este determinist.



Folosind Metoda Celor Mai Mici Pătrate (MCMMP).

$$y[n] = x[n] + v[n] \quad \forall n \in \mathbb{N}$$

vector de semnal util

$$\sum_{i=0}^{2na} a_i y[n-i] = \sum_{i=0}^{2na} a_i v[n-i] \quad \forall n \in \mathbb{N}$$

$$y^T[n] \theta = e^T[n] \theta \quad \forall n \in \mathbb{N}$$

e

$$e[n] = [e[n] \ e[n-1] \ \dots \ e[n-2na]]^T \in \mathbb{R}^{2na+1}$$

vector de zgomot (necunoscut)

$$\theta = [a_0 \ a_1 \ \dots \ a_{2na}]^T \in \mathbb{R}^{2na+1}$$

vector de parametri

$$E\{e[n]\} = \mathbf{0}_{2na+1} \quad (\text{medie nulă})$$

$$E\{e[n]e^T[n]\} = \lambda_e^2 \mathbf{I}_{2na+1} \in \mathbb{R}^{(na+1) \times (na+1)}$$

dispersia zgomotului (necunoscută)

$$y[n] = [y[n] \ y[n-1] \ \dots \ y[n-2na]]^T \in \mathbb{R}^{2na+1}$$

vector de semnal

$$R_{2na+1}(y) = E\{y[n]y^T[n]\} \in \mathbb{R}^{(2na+1) \times (2na+1)}$$

matrice de autocovarianță

MCMMP

$$E\{y[n]y^T[n]\} \theta = E\{y[n]e^T[n]\} \theta \quad \forall n \in \mathbb{N}$$

Ecuatie spectrală.

$$R_{2na+1}(y) \theta = \lambda_e^2 \theta$$

vector propriu

valoare proprie

! Semnalul util este determinist, iar media zgomotului este nulă.

18 Metode moderne de estimare spectrală



Metode de extracție a liniilor spectrale dominante (continuare)

Așadar

Pentru extragerea primelor na linii spectrale dominante, trebuie mai întâi rezolvată o **ecuație spectrală** al cărei principal actor este **matricea de autocovarianță estimată a semnalului original**.

$$\hat{\mathbf{R}}_{2na+1}(y) \boldsymbol{\theta} = \lambda_e^2 \boldsymbol{\theta}$$

Totuși, spectrul matricii de autocovarianță poate conține mai multe valori proprii. Care dintre acestea trebuie considerată?



Răspunsul este dat de un rezultat al lui **V. F. Pisarenko**.

(1973)

Modelul ARMA[2na,2na] care corespunde unei colecții de na sinusoide scufundate într-un zgomot alb aditiv este determinat de **valoarea proprie minimă** a matricii de autocovarianță a semnalului original.

$$\lambda_e^2 = \lambda_{\min}$$

Cum se estimează spectrul?

Parametrii modelului ARMA sunt identici cu elementele unui **vector propriu** corespunzător valorii proprii minime.

Strategia generală

$$\hat{\boldsymbol{\theta}} = [1 \ \hat{a}_1 \ \cdots \ \hat{a}_{2na}]^T$$

① Se determină pulsațiile dominante folosind rădăcinile polinomului caracteristic al modelului matematic.

$$\hat{P}(q^{-1}) \stackrel{\text{def}}{=} 1 + \hat{a}_1 q^{-1} + \hat{a}_2 q^{-2} + \cdots + \hat{a}_{2na} q^{-2na} = 0 \Rightarrow \left\{ e^{\pm j\omega_i} \right\}_{i \in \overline{1, na}}$$

② Se determină puterile spectrale corespunzătoare pulsațiilor dominante nenegative folosind autocovarianța semnalului.

18 Metode moderne de estimare spectrală



Metode de extracție a liniilor spectrale dominante (continuare)

Metoda lui Pisarenko (descompunere armonică)

Ideea lui Pisarenko

(1973)



Pentru determinarea puterilor spectrale dominante, trebuie utilizată secvența de autocovarianță a semnalului original.

Semnalul util se exprimă ca o combinație liniară de funcții armonice elementare reale cu faze stabilite în mod aleator.

$\{A_i^2\}_{i=1,na}$
puteri spectrale dominante

$$x[n] = \sum_{i=1}^{na} A_i \cos(n\omega_i + \varphi_i) \quad \forall n \in \mathbb{N}$$

faze aleatoare (necunoscute)
amplitudini deterministe (necunoscute)
pulsatii dominante (cunoscute)

$$y[n] = x[n] + e[n] = e[n] + \sum_{i=1}^{na} A_i \cos(n\omega_i + \varphi_i) \quad \forall n \in \mathbb{N}$$

Exercițiu

$$r_y[k] = E\{y[n]y[n-k]\} = \lambda_e^2 \delta_0[k] + \frac{1}{2} \sum_{i=1}^{na} A_i^2 \cos(k\omega_i) \quad \forall k \in \mathbb{Z}$$

Soluția unui sistem liniar compatibil și determinat

$$\begin{bmatrix} \hat{A}_1^2 \\ \hat{A}_2^2 \\ \vdots \\ \hat{A}_{na}^2 \end{bmatrix} = 2 \begin{bmatrix} \cos \omega_1 & \cos \omega_2 & \cdots & \cos \omega_{na} \\ \cos 2\omega_1 & \cos 2\omega_2 & \cdots & \cos 2\omega_{na} \\ \vdots & \vdots & \ddots & \vdots \\ \cos na\omega_1 & \cos na\omega_2 & \cdots & \cos na\omega_{na} \end{bmatrix}^{-1} \begin{bmatrix} \hat{r}_y[1] \\ \hat{r}_y[2] \\ \vdots \\ \hat{r}_y[na] \end{bmatrix}$$

- Pentru a demonstra această relație se poate ține cont de următoarea proprietate:

$$E\{\cos(n\omega + \theta)\} = \begin{cases} \cos \theta & , \omega = 0 \\ 0 & , \omega \neq 0 \end{cases}$$

- Se poate arăta că: $\hat{\lambda}_{\min} = \hat{\lambda}_e^2 = \hat{r}_y[0] - \frac{1}{2} \sum_{i=1}^{na} \hat{A}_i^2$

Exercițiu

- Estimați spectrul unei sinusoide afectat de un zgomot alb aditiv, prin **Metoda lui Pisarenko**, cunoscând primele 3 valori ale funcției de autocorelație.

$$\hat{r}_y[0] = 3 \quad \hat{r}_y[1] = 1 \quad \hat{r}_y[2] = 0$$